

半導体製造工程における稼働状態推定と設備故障予測

村尾 淳[†] 松原 靖子[†] 佐藤 颯[†] 渡部 達也^{††} 櫻井 保志[†]

[†] 大阪大学産業科学研究所 〒567-0047 大阪府茨木市美穂ヶ丘 8-1

^{††} ソニーセミコンダクタマニュファクチャリング株式会社 〒869-1102 熊本県菊池郡菊陽町大字原水 4000-1

E-mail: [†]{jun88,yasuko,hayato88,yasushi}@sanken.osaka-u.ac.jp, ^{††}Tatsuya.G.Watanabe@sony.com

あらまし ターボ分子ポンプは回転翼を高速回転させることにより気体を排出する真空ポンプであり、半導体製造において欠かせない設備の1つである。しかし、ターボ分子ポンプは故障により、製造ラインに大きな影響を及ぼす可能性がある。そこで、本論文では、ポンプに備え付けたセンサから取得された時系列データを統合的に解析することによってポンプの状態推定と故障予測を行う手法を提案する。提案手法は、センサの実測値で構成される大規模時系列データが与えられたとき、設備間で共通な時系列パターンを自動抽出し、稼働状態を推定する。さらに、抽出した時系列パターンごとに解析を行うことで、故障を予測する。実際に稼働したポンプから収集されたデータを用いて実験を行い、提案手法の有効性を検証した。

キーワード 時系列解析、時系列データ、深層学習

1 まえがき

電子デバイスの高度化、EV や IoT 関連技術の進展に伴って半導体に注目が集まっている。半導体製造プロセスのドライエッティングにおいて、重要な設備の1つにターボ分子ポンプ (Turbo-molecular Pump, TMP) がある。TMP は真空ポンプの1種であり、複数の動翼と静翼が交互に配置された構造をもつ。金属製の動翼が高速回転することによって気体分子に運動量を与え、気体を送り出す。TMP は軸受の構造によって、玉軸受型、磁気浮上型、玉軸受と磁気浮上併用のハイブリッド型の3種類に大別される [1]。図1に磁気浮上型 TMP の構造を示す。磁気浮上型は従来の軸受と比較して、接触や摩擦がなく、長寿命で、エネルギーの消費が少ないなどのメリットがある [2]。

しかし、半導体製造の特に高負荷なプロセスにおいては、突発的な故障が発生する可能性がある [3]。具体的には、TMP 内部への反応生成物の堆積、パーツの劣化などの影響で動翼が回転する際にローターの軸ブレが生じる。軸ブレによって動翼と静翼が接触することで、故障が引き起こされる。TMP が故障した場合、生産ラインが停止するだけでなく、修理交換に伴う費用が発生する。さらに、故障は計画外のメンテナンスとなるため、資源、生産計画、人的コストの面で計画的なメンテナンスよりも大幅にコストがかかる [3]。

また、近年では、生産性や品質管理の向上のために工場のスマート化が推し進められている。一部の工場では、大量のセンサを使用して生産ラインの稼働状況を監視することによる故障予測が行われている。収集された時系列データには隠れたルールやダイナミックスのトレンドが存在し、故障の前には何らかの兆候が観測されると考えられる [4]。TMPにおいても、センサにより収集された振動や電流、温度などを用いた制御手法・故障予測手法の研究が行われている [5]。一方で、機械学習に

基づく故障の検出手法とその効果はまだ十分に検討されていない [6]。

そこで、本論文では多次元のセンサ情報を用いた TMP のための故障予測手法を提案する。提案手法は、マハラノビス距離を用いて多次元の時系列データを低次元に圧縮する。さらに、圧縮後の時系列データに含まれる典型的な時系列パターン（レジーム）の数と変化点を多角的に捉え、TMP の状態を正確に把握することで、将来発生する故障を予測する。実際に半導体工場で稼働する TMP から収集した時系列データを用いて評価実験を行い、提案手法の有効性を確認した。

1.1 具体例

図2に稼働した TMP のデータと提案手法の出力例を示す。図2(a)は故障前における、センサデータの時間変化を表しており、5件の故障事例 (#1～#5) を縦に並べている。各故障事例のデータは22つのセンサ値（振動の固有周波数2成分、電流など）で構成される。2000ポイント以降、すなわち右端箇所の直後に故障が発生している。取得されたセンサ値をそのまま

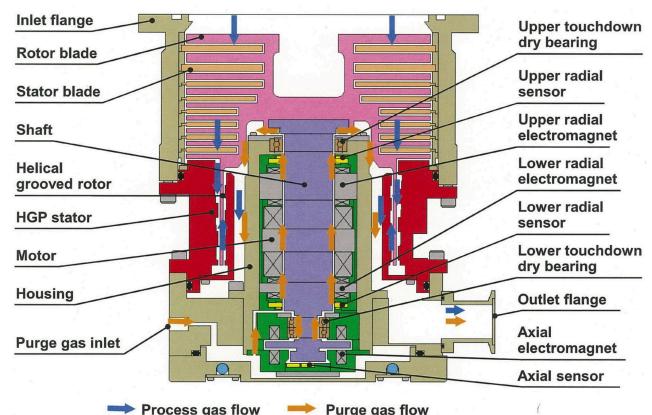


図1: 磁気浮上型 TMP の構造 [1]

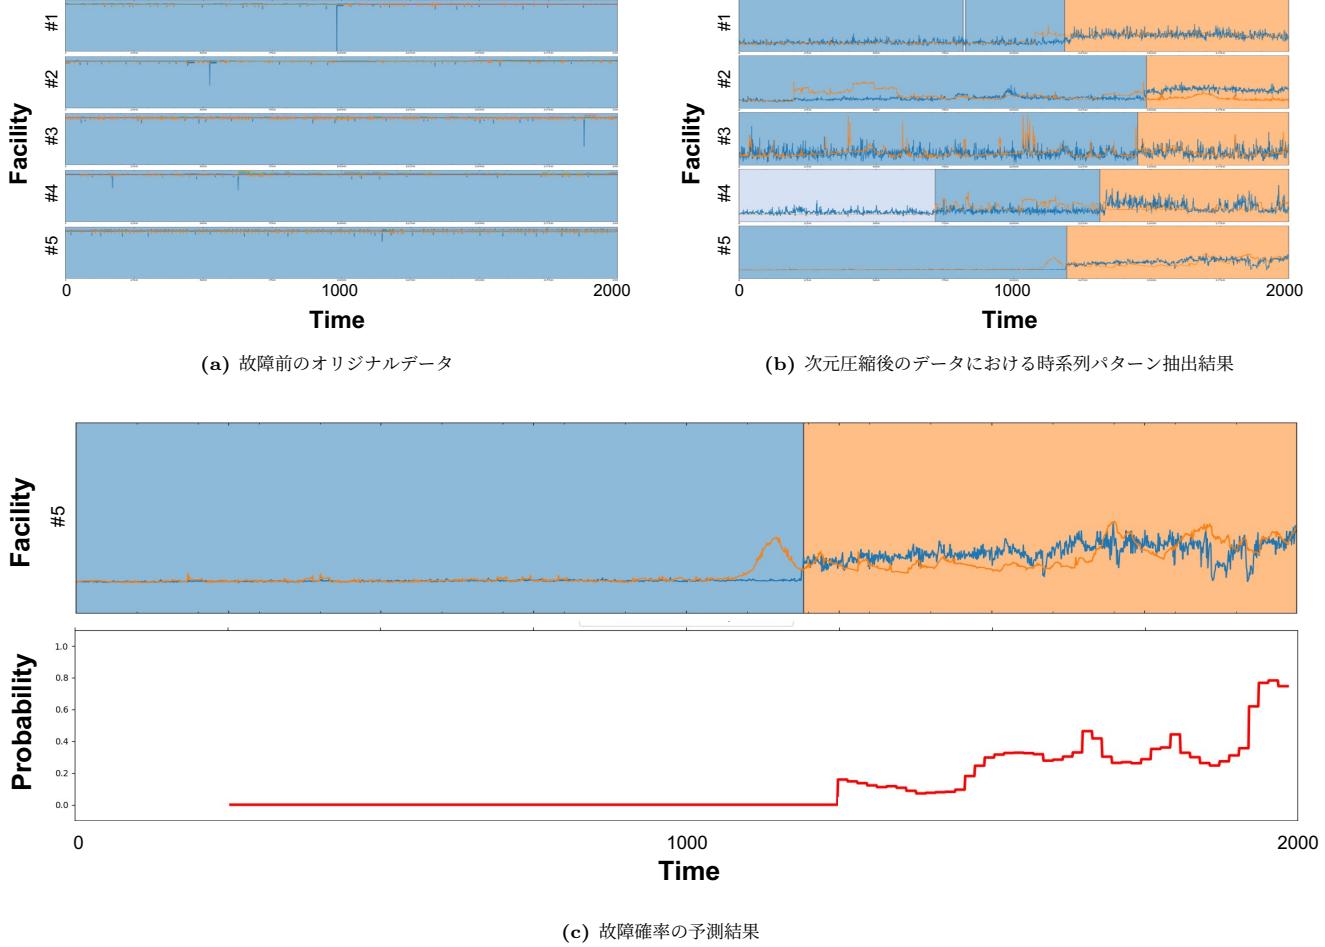


図 2: TMP のデータにおける提案手法の出力結果

ま入力値とした場合、各変数の故障に対する重要度が考慮されず、さらにノイズの影響を受けるため、効果的な特徴抽出が困難である。

図 2(b) は次元圧縮によって得られたデータを用いたパターン検出結果である。図 2(a) の 22 次元のデータを、マハラノビス距離を用いて 2 次元に圧縮している。図中の縦線は時系列パターンが変化した時刻を示し、同一レジームに属するセグメントは同一色で塗られている。故障の直前に、各事例で共通の橙色のレジームが生成されていることが確認できる。提案手法は、複数の TMP から得られた時系列データを同時に解析することにより、設備間で共通な時系列パターンを検出することが可能である。

図 2(c) の上半分は予測対象のデータ、下半分は提案手法による故障確率の予測結果である。2021 年 3 月以前に得られた 4 件の故障事例 (#1 ~ #4) を学習に用い、2021 年 5 月以降に得られた故障事例 (#5) をテストした。1200 ポイント周辺から故障確率が上昇し始め、故障直前の 2000 ポイント周辺で急上昇していることが確認できる。提案手法は検出された時系列パターンごとに予測モデルを切り替える。そのため、故障の予兆と考えられる橙色のレジームの発生以降に故障確率が上昇していると考えられる。提案手法は、データに含まれる潜在的なパターンを検出することで、故障に至る過程を多角的に分析し、

それらの要約情報を用いることで高精度な予測を実現している。

1.2 本研究の貢献

本論文では、センサデータを用いた TMP の故障予測手法を提案する。本手法は次の特徴を持つ。

- TMP から取得されたセンサデータ内に含まれる時系列パターン（レジーム）の変化点と潜在状態を、時間遷移と設備間の多角的な観点から把握する。
- 多次元の時系列データから故障に関する情報を集約し、集約情報に基づく効果的な故障予測を行う。

2 関連研究

センサデータの解析に関する研究が、データベースやデータマイニングなど、様々な分野で進められている [7–10]。自己回帰モデルや線形動的システムは代表的な技術であり、これらに基づくセンサデータの解析と予測手法が数多く存在する。CubeCast [11] は、時間と季節性の両方の観点から、大規模なテンソルストリームを類似したグループに分解することで、トレンドと季節性に関する潜在的な非線形ダイナミクスを捉える能力をもつ。本手法はセンサデータの実測値の予測において高い性能を示すが、設備の故障のような、ラベル付けされたイベ

ントデータの予測には対応していない。

センサデータを用いた設備の故障予測に関しては、Deep Neural Networkに基づく手法が考案されている [12]。Jalayer [13] らは FFT および CWT と、データの統計的特徴を組み合わせて LSTM に入力することによって、回転機械の故障予測を行う手法を提案している。Pandarakone [14] らは電流データに対して FFT による周波数ドメインの特徴抽出と CNN による学習を行い、誘導電動機のペアリング故障を予測している。

また、電流値や振動などの時系列データによる、TMP の故障に関する研究が行われている [15]。Ainapure ら [16] は、深層学習に基づく稼働状態の識別方法を提案した。ドメイン適応技術を用いることにより、機械の状態を診断する。なお、モデルへの入力データとして振動データが使用される。Alessandro ら [17] は、ポンプの複数箇所の平均温度と、振動データからマハラノビス距離を算出し、ポンプの正常・異常状態を判定している。しかし、これらの手法は、玉軸受型、もしくはハイブリッド型の TMP を対象にしており、磁気浮上型の TMP に対応していない。Bangcheng [18] らは磁気浮上型の TMP に対して、電流の損失や温度上昇を推定するモデルを提案しているが、故障予測には対応していない。結論として、磁気浮上型 TMP を対象とした故障予測手法はこれまで存在せず、提案手法が初の試みである。

3 問題定義

本研究で扱う工場設備センサデータは、ソニーセミコンダクタマニュファクチャリング株式会社で 2020 年 1 月から 2021 年 6 月の間に稼働した 4 つの TMP におけるセンサデータで構成される。本データは (*facility, sensor, time*) の 3 つ組で表現され、それぞれ、 w 個の設備、 d 種のセンサ、 n 個の観測点から構成される。このセンサデータは、3 階のテンソル $\mathcal{X} \in \mathbb{R}^{w \times d \times n}$ として表現することができ、 \mathcal{X} の要素 $x_{ij}(t)$ は時刻 t における i 番目の設備の j 番目のセンサでの計測値を示す。本論文では、このセンサデータを多次元時系列テンソルと呼ぶ。本研究の最終目的は、与えられた時系列テンソル \mathcal{X} から l_s ステップ先の故障を予測することであり、取り組む問題を以下のように定義する。

[問題] 時系列テンソル $\mathcal{X}(t_s : t_e)$ が与えられたとき、 l_s ステップ先の故障 $\mathcal{Y}(t_e + l_s)$ を次式に基づいて予測する。

$$\mathcal{Y}(t_e + l_s) = F(\mathcal{X}(t_s : t_e)) \quad (1)$$

ここで、 $t_e + l_s$ は予測に使用するテンソルのウインドウを表し、 F を提案モデルとする。

本論文では、 $\mathcal{Y}(t_e + l_s)$ を高精度に予測するために、多次元時系列テンソル \mathcal{X} に対してマハラノビス・タグチ法を利用した次元圧縮を行う。次に、次元圧縮後のテンソル \mathcal{X}' を m 個のセグメント集合 $\mathcal{S} = \{s_1, \dots, s_m\}$ に分割してその特徴をとらえる。 s_i は i 番目のセグメントの開始点 t_s 、終了点 t_e 、設備番号で構成され(つまり、 $s_i = \{t_s, t_e, facilityID\}$)、各セグメントは重複がないものとする。そして、発見したセグメント集合を

類似セグメントのグループに分類する。本論文において、これらのグループをレジームと呼ぶ。

[定義 1] (レジーム) r を最適なセグメントグループの個数とする。各セグメント s は、いずれかのセグメントグループに割り当てられる。

さらに、各セグメントが所属するレジームを表現するために、新たにセグメントメンバーシップを定義する。

[定義 2] (セグメントメンバーシップ) 時系列テンソル \mathcal{X}' が与えられたとき、 $\mathcal{F} = \{f_1, \dots, f_m\}$ を、 m 個の整数列とし、 f_i を i 番目のセグメントが所属するレジームの番号とする。

これにより、多次元時系列テンソル \mathcal{X}' を m 個のセグメントと r 個のレジームで $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ として表現することができる。次に提案手法は、得られたレジーム情報を基に、多次元時系列テンソルを分割し、故障に関する重要な特徴を抽出する。

それぞれのレジームは統計モデル $\Theta = \{\theta_1, \dots, \theta_r, \Delta_{r \times r}\}$ として表現される。本研究では、多次元時系列テンソルの振る舞いを表現するため、隠れマルコフモデル (HMM:Hidden Markov Model) を用いる。HMM は隠れ状態を持つマルコフ過程を仮定した確率モデルの一種であり、音声処理を含む様々な分野において、広く利用されている時系列処理手法である [19]。HMM は初期確率 $\pi = \{\pi_i\}_{i=1}^k$ 、遷移確率 $\mathbf{A} = \{a_{ij}\}_{i,j=1}^k$ 、出力確率 $\mathbf{B} = \{b_i(\mathbf{x})\}_{i=1}^k$ の 3 つ組で表現される。すなわち、 $\Theta = \{\pi, \mathbf{A}, \mathbf{B}\}$ である。ここで、 k は HMM の潜在状態数を示す。本論文では出力確率 \mathbf{B} が多次元ガウス分布から生成されるものとする。これにより多次元ベクトルのシーケンスは確率モデルで表現される(つまり $\mathbf{B} \sim \{N(\mu_i, \sigma_{2i})\}_{i=1}^k$)。HMM のモデルパラメータ $\Theta = \{\pi, \mathbf{A}, \mathbf{B}\}$ と、ある設備のシーケンス \mathbf{X} が与えられた時、 \mathbf{X} の尤度 $P(\mathbf{X}|\Theta)$ は次のように計算される:

$$P(\mathbf{X}|\Theta) = \max_{1 \leq i \leq k} \{p_i(n)\}$$

$$p_i(t) = \begin{cases} \pi_i \cdot b_i(\mathbf{x}_1) & (t = 1) \\ \max_{1 \leq j \leq k} \{p_j(t-1) \cdot a_{ji} \cdot b_i(\mathbf{x}_t)\} & (2 \leq t \leq n) \end{cases}$$

ここで、 $p_i(t)$ は時刻 t における潜在状態 i の最大確率を示し、 n は \mathbf{X} のシーケンス長である。この尤度は動的計画法の一種であるビタビアルゴリズムを用いて計算される。さらに、レジーム遷移行列 $\Delta_{r \times r}$ を用いる。

[定義 3] (レジーム遷移行列) $\Delta_{r \times r}$ を r 個のレジーム群の遷移行列と呼ぶ。ここで、要素 $\delta_{ij} \in \Delta$ は i 番目のレジームから j 番目のレジームへの遷移確率を示す。

上記のモデルを用いて、時系列テンソル \mathcal{X}' を要約し、特徴量化することで、高精度かつ長期的な予測を実現する。

具体的には、時系列テンソル \mathcal{X}' をレジーム情報 $\{m, r, \mathcal{S}, \Delta, \mathcal{F}\}$ に基づき分割し、レジームごとにモデルを構築する。さらに、レジームごとに多層の短時間フーリエ変換 (STFT) を行うことで、故障の要因となる高次元かつ非線形な動的特性を抽出する。

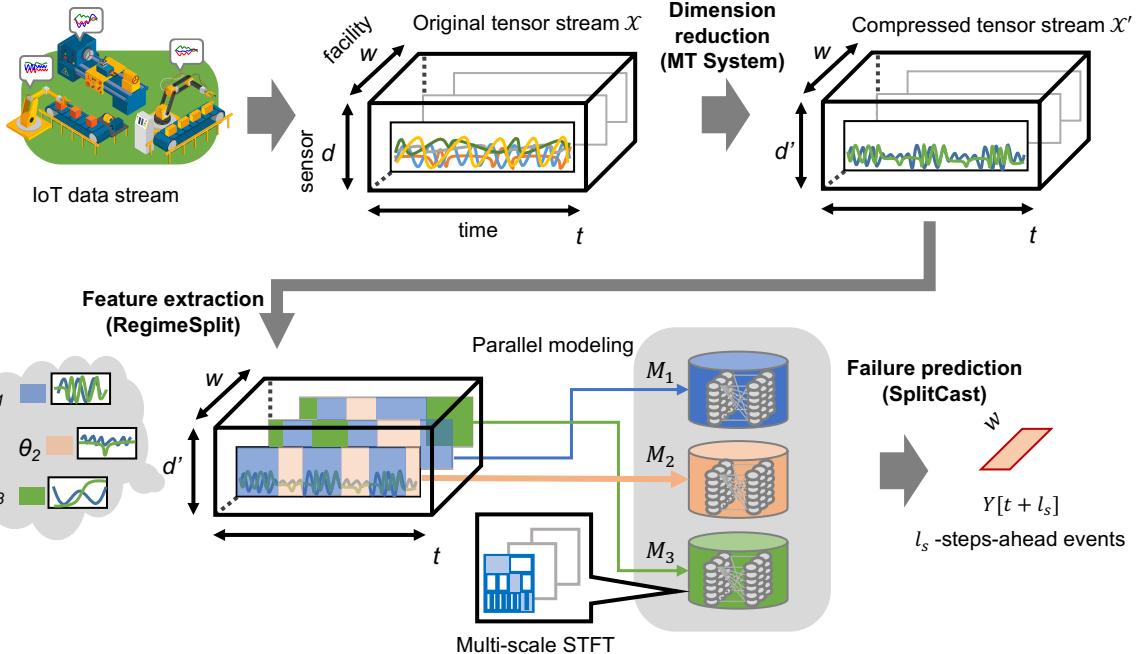


図 3: 提案モデルの概要

4 提案手法

4.1 概 要

提案手法は、以下の 3 つのモジュールで構成される。

- MT SYSTEM：故障予測に寄与する特徴量を抽出するために、マハラノビス・タグチ法を用いて次元圧縮を行う。多次元時系列テンソル $\mathcal{X} \in \mathbb{R}^{w \times d \times n}$ を $\mathcal{X}' \in \mathbb{R}^{w \times d' \times n}$ ($d' < d$) に変換する。
- REGIMESPLIT：テンソル \mathcal{X}' に含まれる時系列パターンの種類と変化点を検出する。各時系列パターンのダイナミクスをモデルパラメータ Θ として表現し、モデルパラメータ集合 $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ を得る。
- SPLITCAST：時系列パターンの要約情報 $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ を用いて、多次元時系列テンソル \mathcal{X}' をレジーム $\theta_1, \dots, \theta_r$ に分割する。さらに、レジーム $\theta_1, \dots, \theta_r$ に基づき、複数の予測モデル M_1, \dots, M_r を構築する。モデルごとに多層 STFT によって故障の予兆となる特徴を抽出し、部分テンソル $\mathcal{X}'(t_s : t_e)$ から l_s 先の故障ラベル $\mathcal{Y}(t_e + l_s)$ を予測する。

図 3 に提案モデルの概要を示す。テンソル \mathcal{X} が与えられたとき、提案手法は MT SYSTEM により、 \mathcal{X} を \mathcal{X}' に変換する。さらに、 \mathcal{X}' の時系列パターンの時間遷移と設備固有のパターンを捉え、それらに基づいて \mathcal{X}' をレジーム $\theta_1, \dots, \theta_r$ に要約する。最終的に、レジームごとに予測モデル M_1, \dots, M_r を構築し、 l_s ステップ先での故障ラベルを出力する。

4.2 MT System による情報集約

提案手法はまず、多次元時系列テンソル \mathcal{X} に対して、マハラ

ノビス・タグチ法を利用した情報集約を行う。マハラノビス・タグチ法はマハラノビス距離を用いた異常度算出法である。正常なデータ集合を基準とした単位空間を定義することによって、各データの異常度を算出する。本研究では、交換直後から約 4 日以内に観測されたセンサデータを正常なデータ集合としている。直感的には、多次元のデータ集合が与えられたとき、各次元の相関関係を考慮した基底を定義する。定義した空間において、データ集合の中心からの距離をマハラノビス距離、すなわち異常度として扱う。

TMP からは複数のセンサデータが利用できる。しかし、すべての時系列データをそのまま解析に用いる場合、類似した時系列パターンをもつ変数同士が冗長になる可能性があると考えられる。したがって、マハラノビス距離を用いることによって正常データからの変化を把握するとともに、類似した時系列パターンをもつ変数を集約している。

任意の設備で、時刻 t における p ($2 \leq p \leq d$) 種のセンサ値から成るベクトルは $\mathbf{x}_t = \{x_{ti}\}_{i=1}^p$ と表現できる。このとき、時刻 t の分析対象データのマハラノビス距離 (MD_t) は次の式で計算できる。

$$MD_t = (\mathbf{x}_t - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_t - \boldsymbol{\mu}) \quad (2)$$

$\boldsymbol{\Sigma}$ は単位空間の分散共分散行列であり、 $\boldsymbol{\mu}$ は単位空間の平均ベクトルである。なお、 \mathbf{x}_t は事前に z-score normalization を行っている。以上の操作によって、 p 次元から 1 次元への次元圧縮を実現する。

4.3 RegimeSplit による特徴抽出

我々が扱う多次元時系列テンソルは、時間ドメインの特徴と設備ドメインの特徴をもつ。具体的には、TMP から得られる時系列センサデータは、故障状態への時間遷移パターンと、設備

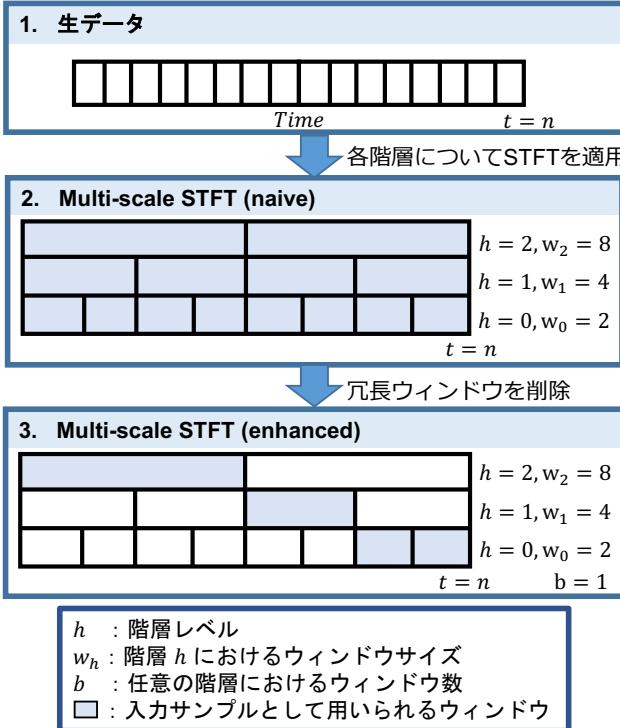


図 4: Multi-scale STFT の概要

固有のパターンを持つ。そこで本研究では、CubeMarker [20] を用いて、多角的なパターン発見とグループ化を同時に行う。

CubeMarker では、最小記述長の概念に基づき、適切なモデルを生成するための基準となる符号化スキームを導入している。具体的には、データが与えられたときのモデルのよさは次の式で表現される。

$$Cost_T(\mathcal{X}; \mathcal{M}) = Cost_M(\mathcal{M}) + \alpha \cdot Cost_C(\mathcal{X}|\mathcal{M}) \quad (3)$$

ここで、 $Cost_M(\mathcal{M})$ はモデル \mathcal{M} を表現するためのモデルコストを示し、 $Cost_C(\mathcal{X}|\mathcal{M})$ は \mathcal{M} が与えられたときのテンソル \mathcal{X} の符号化コストを示す。 α は符号化コストに対する重みであり、 α の値が大きいほどより実データに正確なモデルを生成する（セグメントの数 m 、レジームの数 r が大きくなる）。CubeMarker は式 3 を最小化するように時系列テンソル X に含まれる時系列パターンとその変化点の数 r, m を決定する。

- V-Split: テンソル \mathcal{X} から時間遷移するパターンとその変化点を検出し 2 つのレジームに分割する。それら 2 つのレジームに対し、モデルパラメータ $\{\theta_1, \theta_2, \Delta\}$ を推定する。
- H-Split: テンソル \mathcal{X} に表れるある 1 つのレジームから設備ごとの特徴を抽出し、2 つのレジームに分割後、それらのレジームのモデルパラメータを推定する。

上記のアルゴリズムにより、 $r = 1, 2, \dots$ とレジーム数が変化していく。もしレジーム θ_0 を 2 つのレジーム $\{\theta_1, \theta_2\}$ に分割した際、コスト関数（式 3）の値が大きくなれば θ_0 は最適とみなし、これ以上分割しない。生成された全てのレジームについて同様にコスト計算を繰り返し、コストが下がらなくなるまで上記の分割アルゴリズムを繰り返す。最終的に、コス

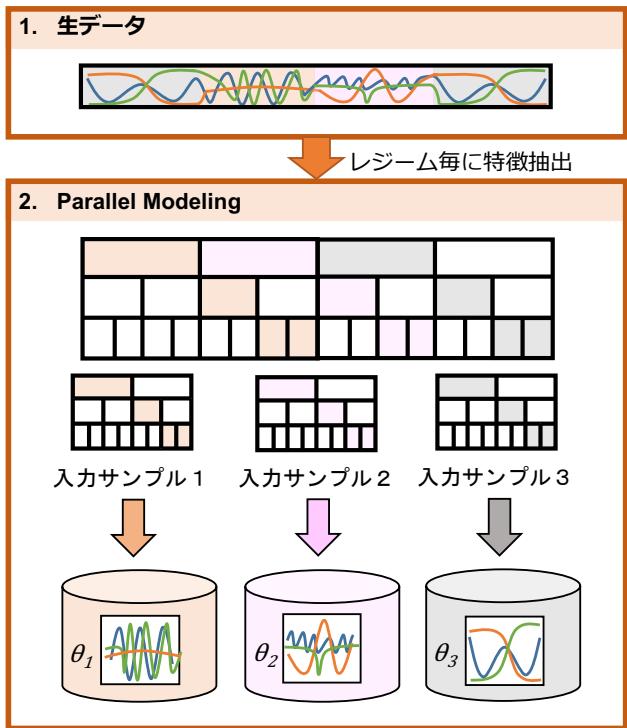


図 5: Parallel Modeling の概要

トが収束したときのセグメント、レジーム、モデルパラメータ $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ を出力し REGIMESPLIT を終了する。

4.4 SplitCast による故障予測

本研究の最終目的は、与えられた時系列テンソル \mathcal{X} から l_s ステップ先の故障を予測することである。本節では、これまでに得られたレジームを利用し、将来の故障予測を行うモジュールである、SPLITCAST について述べる。

故障予測タスクにおいて、近年では深層学習に基づく手法が数多く提案されている。深層学習においては、中間層を多層にしたり、中間層のユニット数を増やすことで柔軟な学習を実現できる。一方で、TMP のような高速回転を伴う設備においては、周波数ドメインの特徴も考慮する必要がある。

そこで提案手法は、REGIMESPLIT の出力であるレジーム情報を学習モデルの分割に用いるとともに、短時間フーリエ変換（STFT）を用いて周波数ドメインの特徴抽出を行うことで、効率的かつ効果的なイベント予測を実現する。具体的には、SPLITCAST は以下の 2 つのアルゴリズムによって構成される。

- Multi-scale STFT: STFT を用いて多階層ウィンドウを作成し、入力データをより効果的な入力サンプルに変換する。
- Parallel Modeling: REGIMESPLIT の特徴抽出結果を基に、並列モデリングを行う。

まず、Multi-scale STFT について説明する。周波数ドメインの解析手法として、STFT がよく知られている。単階層 STFT の場合、学習に有効な STFT のウィンドウ幅をチューニングする必要がある。そこで、提案手法では異なるウィンドウ幅を用いた、

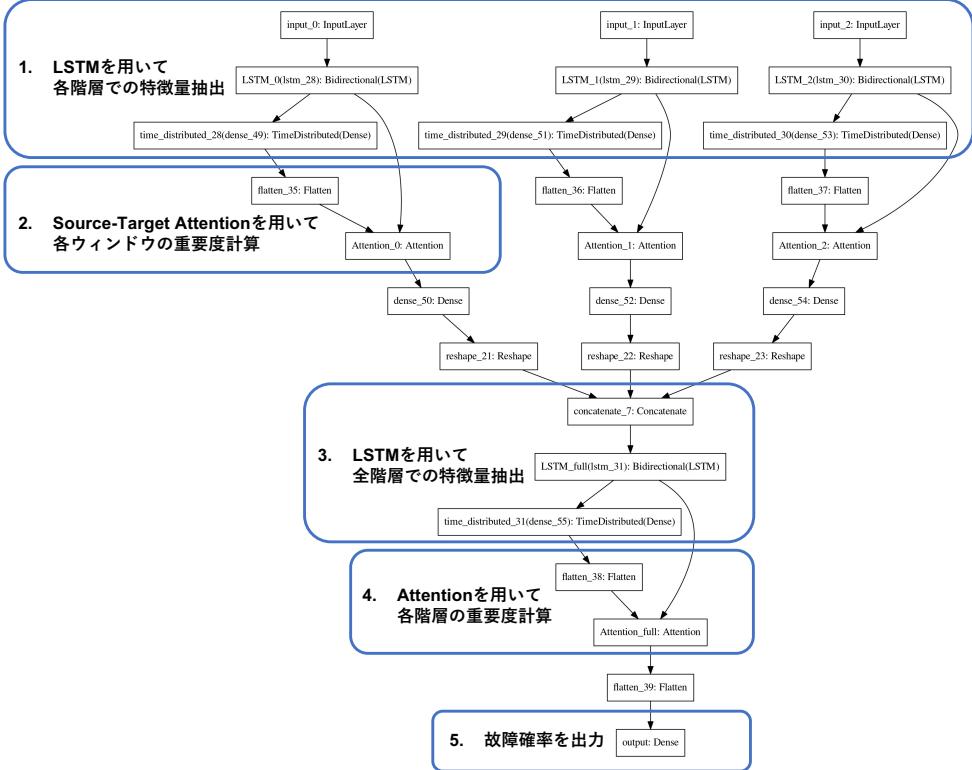


図 6: 故障予測モデルの構成

多階層 STFT を適用する。ここでは、入力された時系列データの長さを $t = n$ とする。多階層 STFT での最小ウィンドウサイズを w_0 、階層数を h_{max} とすると、階層 $h_i (0 \leq h_i \leq h_{max} - 1)$ でのウィンドウサイズ w_i は $w_0^{h_i+1}$ 、ウィンドウ数は $\frac{n}{w_i}$ と表せる。したがって、多層 STFT では h_{max} 種類のウィンドウサイズを用いたフーリエ係数の計算が可能である。図 4 上部に長さ n の時系列データと、 $h_{max} = 3, w_0 = 2$ としたときの多階層 STFT のウィンドウの様子を示す。一方で、同一のデータ点を複数のウィンドウサイズで周波数解析を行うため冗長性が存在する。そこで、提案手法では、任意の階層におけるウィンドウ数 b を導入することで、各階層が同一のデータ点を重複しないようにしている。なお、例外的に最下層のウィンドウ数は $2b$ である。このとき、入力サンプル長は $2^{h_{max}} b w_0$ である。図 4 下部に $b = 1$ としたときのウィンドウの様子を示す。

次に、Parallel Modeling について説明する REGIMESPLIT によってレジーム情報 $\{m, r, S, \Delta, F\}$ が得られた。ここでは、MT SYSTEM によって得られたテンソル \mathcal{X}' を r 個のレジームに分割し、レジーム毎に予測モデル $M_{\theta_1}, \dots, M_{\theta_r}$ を構築する。具体的には、レジーム θ_i の部分シーケンスに対して Multi-scale STFT が適用され、各階層で算出されたフーリエ係数がモデル $M_i (1 \leq i \leq r)$ に入力される。Parallel Modeling の概要を図 5 に示す。

最後に、予測モデルの構成について説明する。Multi-scale STFT と Parallel Modeling によって得られた入力サンプルを用いて、設備の故障を予測する。

本研究では、時間経過に伴うの故障発生の様子をモデリングするために LSTM(Long short-term memory) [21] を適用し

た。さらに、各階層の重要度を考慮するために、Attention [22] を導入した。図 6 に故障予測モデルの構成を示す。本研究では、時刻 t における最新の部分シーケンスからの l_s 先故障予測を 2 値分類タスクとして扱い、出力を時刻 $t + l_s$ における故障発生確率とする。また、予測モデルが最小化すべき目的関数 \mathcal{L} は Binary cross entropy (BCE) となり、次の式で表される。

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \{y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)\} \quad (4)$$

ここで、 N は学習時のバッチサイズ、 \hat{y}_i は各入力サンプル i に対する SPLITCAST の出力値、 y_i は正解ラベルである。

5 実験と議論

本論文では、提案手法の有効性を検証するため、実データを用いて実験を行った。図 2(b)、図 2(c)において提案手法の具体例をすでに示した。本章では、故障予測に対する提案手法の精度の検証を行う。実験は 128GB のメモリ、NVIDIA Quadro RTX 6000 48GB の GPU を搭載した Linux マシン上で実施した。

5.1 データセット

使用したデータセットは、ソニーセミコンダクタマニュファクチャリング株式会社で 2020 年 1 月から 2021 年 6 月の間、数ヶ月間実際に稼働していた 4 つの TMP に取り付けられた複数のセンサによって取得されたものであり、回転軸の振動、モータ電流、設備温度などの 22 項目で構成される。なお、振動については、 x, y, z 軸の 3 軸方向のデータが存在し、事前に

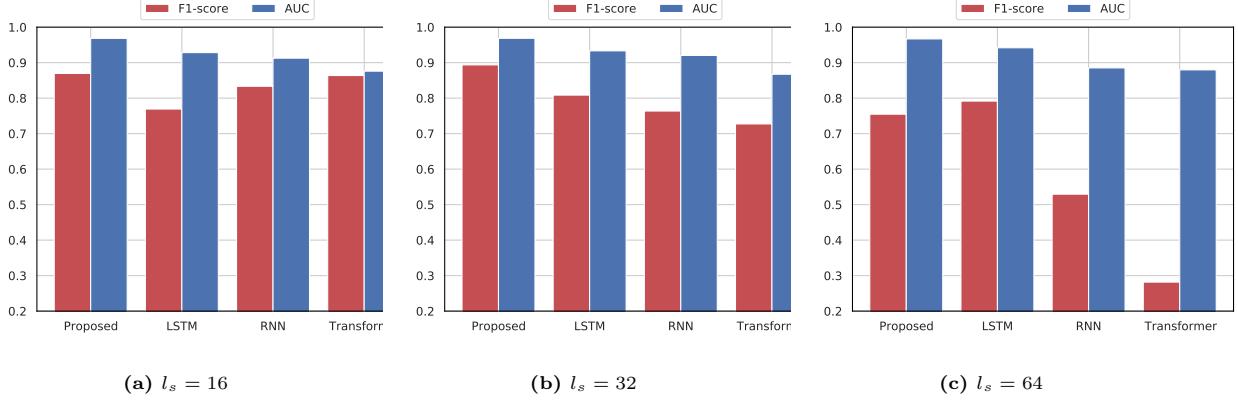


図 7: l_s ステップ先の予測精度の比較

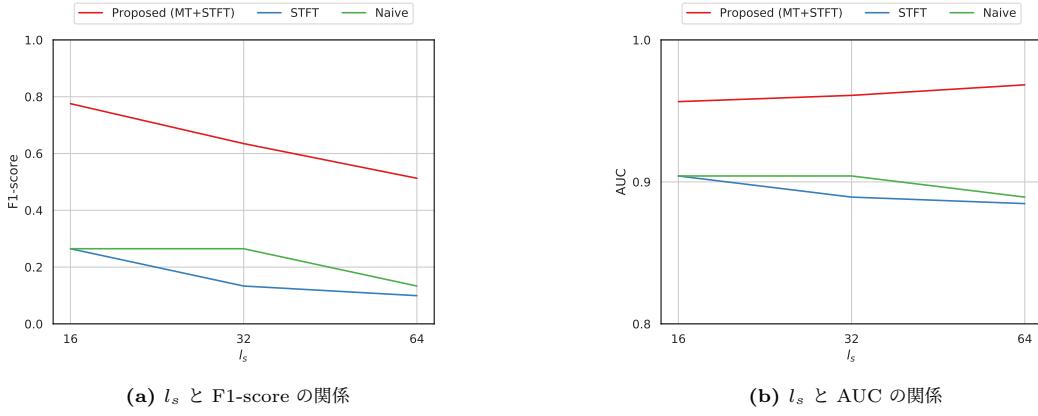


図 8: 特徴抽出の有無による予測精度の比較

STFT によって周波数解析されている。そのうち、動翼の回転数に関連した周波数帯 (459~465Hz) の成分を抽出した。本実験では、5 件の各故障事例において、故障発生前の 2000 点のデータを抽出した。まとめると、データセットは $w = 5$ 個の TMP, $d = 22$ 個の項目, $n = 2000$ 個の観測点から構成され、テンソル $\mathcal{X} \in \mathbb{R}^{5 \times 22 \times 2000}$ として表現できる。データセットはノイズ除去と正規化のために、ハンペルフィルタと z-score normalization が適用されている。

5.2 実験設定

22 個の項目のうち、振動に関連する 14 成分を MT SYSTEM によって、1 次元に圧縮した。2000 点のデータのうち、最初の 200 点のデータを用いて単位空間を定義した。また、同様にモータ電流など振動以外の 7 項目のデータを 1 次元に圧縮し、振動データの圧縮成分と連結した。したがって、次元圧縮後のテンソルは $\mathcal{X}' \in \mathbb{R}^{5 \times 2 \times 2000}$ である。

比較手法には、再帰型ニューラルネットワークモデルである RNN(Recurrent neural network), LSTM, Transformer [22] を用いた。

提案手法に関して、最小ウィンドウサイズ $w_0 = 4$ 、各階層におけるウィンドウ数 $b = 8$ 、階層数 $h_{max} = 3$ 、符号化コストの重み $\alpha = 1.0$ をデフォルトとして実験を行なっている。予測ステップ数を 16, 32, 64 と変化させた。また、提案手法を含むすべての再帰型モデルについては、中間層のユニット数を 10、

出力層のユニット数は 5 とし、最適化アルゴリズムには Adam を使用した。学習率を 0.002、epoch 数を 50 に設定し学習させた。また、提案手法を含むすべての手法において、5epoch 連続で loss の改善が見られなかった時点で学習を終了した。

5.3 評価指標

評価指標には F1-score, AUC(Area Under the Curve) を使用し、5 分割交差検証を行った。F1-score は対照的な特徴を有する Precision と Recall の調和平均であり、以下の式で計算される。

$$F1\text{-score} = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

なお、Precision は、予測されたイベントの合計数とそのうち正解であったイベントの合計数の割合を示す。Recall は、全てのイベントの正解値の数と予測されたイベントの中で正解した合計数の割合を示す。両者とも、精度が高い場合には 1 に近づく。また、AUC は横軸に偽陽性率、縦軸に再現率をとった ROC 曲線の下側の面積である。AUC は 0 から 1 の値をとり、0.5 がランダム、1 が完全な分類可能な状態である。

5.4 実験結果

図 7 は予測先のステップ数 l_s を変化させたときの予測精度の比較である。本実験は異なる l_s ごとに学習と予測を行っている。比較手法は、 l_s によって F1-score の値が大きく変動している。これは、多次元の時系列データに含まれる様々な時系列

パターンを同一のモデルで学習しており、時間・周波数ドメインの情報を適切に捉えられていないためと考えられる。一方で、提案手法はいずれの条件下でも安定した性能を示している。この結果から、故障は単なる各計測値の増減に依存するだけでなく、周期的な時系列パターン、周波数ドメインの情報を踏まえた解析によって予測することができると考えられる。

また、提案手法において MT SYSTEM と REGIMESPLIT による特徴抽出の効果について検証した。具体的には、MT SYSTEM による次元圧縮と、REGIMESPLIT によるレジーム分割を行わず、テンソル \mathcal{X} を SPLITCAST に直接入力したものと比較した。さらに、同様の設定において、SPLITCAST による STFT を実施しないものと比較した。図 8 は特徴抽出の効果検証の結果である。比較手法のうち、SPLITCAST に直接入力したものを青線、同様の設定で STFT を実施しなかったものを緑線で示す。MT SYSTEM と REGIMESPLIT によって特徴抽出を行ったものは、いずれの l_s においても高い予測精度を達成した。

6 む す び

本論文ではターボ分子ポンプの故障を予測するための大規模時系列解析アルゴリズムとして提案手法を説明した。提案手法は、マハラノビス距離を用いた圧縮により多次元のセンサデータを集約する。また、与えられた時系列テンソルに含まれる特徴的なパターンやその変化点を多角的に抽出し、レジームとして要約することで、長期的なイベント予測を実現する。工場設備で得られた実データを用いて実験を行い、提案手法が複雑な時系列パターンを適切にモデル化し、ターボ分子ポンプの故障予測能力を持つことを確認した。

謝 辞 本研究の一部は JSPS 科研費 JP20H00585, JP21H03446, 国立研究開発法人情報通信研究機構委託研究 21481014, JSTAIP 加速課題 JPMJCR21U4, 総務省 SCOPE 192107004, ERCA 環境研究総合推進費 JPMEERF20201R02 の助成を受けたものです。

文 献

- [1] 桜井充, “ターボ分子ポンプのメンテナンス”, 表面と真空, vol. 61, no. 8, pp. 522–527, 2018.
- [2] X. Ren, Y. Le, B. Han, and K. Wang, “Loss optimization and thermal analysis of a heteropolar magnetic bearing for a vacuum turbo-molecular pump,” *Int'l J. of Applied Electromagnetics and Mechanics*, vol. 54, no. 4, pp. 673–690, 2017.
- [3] S. W. Butler, J. V. Ringwood, and N. MacGearailt, “Prediction of vacuum pump degradation in semiconductor processing,” *IFAC Proc. Volumes*, vol. 42, no. 8, pp. 1635–1640, 2009.
- [4] Y. Matsubara, and Y. Sakurai, “Dynamic modeling and forecasting of time-evolving data streams,” in *Proc. of the 25th ACM SIGKDD Int'l Conf. on Knowledge Discovery & Data Mining*, 2019, pp. 458–468.
- [5] S. Zheng, and C. Wang, “Rotor balancing for magnetically levitated tmrps integrated with vibration self-sensing of magnetic bearings,” *IEEE/ASME Trans. on Mechatronics*, vol. 26, no. 6, pp. 3031–3039, 2021.
- [6] M. B. AbdulBary, A. G. Embaby, and F. R. Gomaa, “Fault diagnosis in rotating system based on vibration analysis,” *ERJ. Eng. Research J.*, vol. 44, no. 3, pp. 285–294, 2021.
- [7] S. Ayvaz, and K. Alpay, “Predictive maintenance system for production lines in manufacturing: A machine learning approach using iot data in real-time,” *Expert Systems with Applications*, vol. 173, p. 114598, 2021.
- [8] M. Khayati, A. Lerner, Z. Tymchenko, and P. Cudré-Mauroux, “Mind the gap: an experimental evaluation of imputation of missing values techniques in time series,” in *Proc. of the VLDB Endowment*, vol. 13, no. 5, 2020, pp. 768–782.
- [9] I.-C. Severin, “Time series feature extraction for head gesture recognition: Considerations toward hci applications,” in *2020 24th Int'l Conf. on System Theory, Control and Computing (ICSTCC)*, 2020, pp. 232–237.
- [10] Z. Zhu, Z. Liu, G. Jin, Z. Zhang, L. Chen, J. Zhou, and J. Zhou, “Mixseq: Connecting macroscopic time series forecasting with microscopic time series data,” *Advances in Neural Information Processing Systems*, vol. 34, 2021.
- [11] K. Kawabata, Y. Matsubara, T. Honda, and Y. Sakurai, “Non-linear mining of social activities in tensor streams,” in *Proc. of the 26th ACM SIGKDD Int'l Conf. on Knowledge Discovery & Data Mining*, 2020, pp. 2093–2102.
- [12] A. Mallak, and M. Fathi, “Sensor and component fault detection and diagnosis for hydraulic machinery integrating lstm autoencoder detector and diagnostic classifiers,” *Sensors*, vol. 21, no. 2, p. 433, 2021.
- [13] M. Jalayer, C. Orsenigo, and C. Vercellis, “Fault detection and diagnosis for rotating machinery: A model based on convolutional lstm, fast fourier and continuous wavelet transforms,” *Computers in Industry*, vol. 125, p. 103378, 2021.
- [14] S. E. Pandarakone, M. Masuko, Y. Mizuno, and H. Nakamura, “Deep neural network based bearing fault diagnosis of induction motor using fast fourier transform analysis,” in *2018 IEEE Energy Conversion Congress and Exposition (ECCE)*, 2018, pp. 3214–3221.
- [15] A. B. B. Moreira, and F. Thouverez, “Dynamic modelling and vibration control of a turbomolecular pump with magnetic bearings in the presence of blade flexibility,” in *Rotating Machinery, Vibro-Acoustics & Laser Vibrometry, Volume 7*. Springer, 2019, pp. 101–110.
- [16] A. Ainapure, X. Li, J. Singh, Q. Yang, and J. Lee, “Deep learning-based cross-machine health identification method for vacuum pumps with domain adaptation,” *Procedia Manufacturing*, vol. 48, pp. 1088–1093, 2020.
- [17] A. P. Daga, L. Garibaldi, and L. Bonmassar, “Turbomolecular high-vacuum pump bearings diagnostics using temperature and vibration measurements,” in *2021 IEEE Int'l Workshop on Metrology for Industry 4.0 & IoT (MetroInd4.0&IoT)*. IEEE, 2021, pp. 264–269.
- [18] H. Bangcheng, H. Zan, Z. Xu, L. Xu, W. Tong, and Z. Shiqiang, “Loss estimation, thermal analysis, and measurement of a large-scale turbomolecular pump with active magnetic bearings,” *IET Electric Power Applications*, vol. 14, no. 7, pp. 1283–1290, 2020.
- [19] 本田崇人, 松原靖子, 川畠光希, 櫻井保志・他, “大規模時系列テンソルによる多角的イベント予測”, 情報処理学会論文誌データベース (TOD), vol. 13, no. 1, pp. 8–19, 2020.
- [20] T. Honda, Y. Matsubara, R. Neyama, M. Abe, and Y. Sakurai, “Multi-aspect mining of complex sensor sequences,” in *2019 IEEE Int'l Conf. on Data Mining (ICDM)*. IEEE, 2019, pp. 299–308.
- [21] S. Hochreiter, and J. Schmidhuber, “Long short-term memory,” *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [22] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in neural information processing systems*, 2017, pp. 5998–6008.