

AE センサデータの時系列解析によるパワーモジュール寿命予測

佐藤 順[†] 松原 靖子[†] 菅沼 克昭[†] 陳 伝トウ[†] 張 政[†]
 末武 愛士[†] 若杉 直樹^{††} 櫻井 保志[†]

† 大阪大学産業科学研究所 〒567-0047 大阪府茨木市美穂ヶ丘 8-1

†† ヤマト科学株式会社 〒104-6136 東京都中央区晴海1-8-11 晴海トリトンスクエアY棟36階

E-mail: †{hayato88,yasuko,suganuma,chenchuantong,zhangzheng,asuetake,yasushi}@sanken.osaka-u.ac.jp,
 ††naoki.wakasugi@yamato-net.co.jp

あらまし パワーモジュールは主に電力変換に使用される、電力機器において欠かせないデバイスの1つである。本論文では、パワーモジュールのための寿命予測手法を提案する。提案手法はパワーモジュールのパワーサイクル試験において得られる時系列データから、時系列パターンを統合的に解析、要約し、寿命予測を行う。具体的には、パワーサイクル試験における、ジャンクション温度、熱抵抗値、AEセンサデータ等で構成される時系列データが与えられたとき、提案手法は、(a) デバイス間で共通、あるいは相違な時系列パターンを自動抽出し、デバイス状態を推定する。さらに、(b) デバイス状態の変化に応じて予測モデル切り替えることで、効果的な寿命予測を行う。実データを用いた実験では、提案手法が時系列データに含まれる特徴的な時系列パターンを多角的に捉え、高精度な寿命予測が可能であることを示した。

キーワード 時系列解析、センサデータ、寿命予測

1 まえがき

近年、パワーサイクル試験（PCT）によるパワーモジュール信頼性試験中の摩耗故障メカニズムや寿命を解析するために様々な故障予兆パラメータを用いたリアルタイムモニタリング手法の研究が盛んに行われている。一般的に、オン抵抗、コレクタ・エミッタ間電圧、順方向電圧、ジャンクション温度、熱抵抗などのデバイスの熱特性や電気特性の変化を捉えた値が故障予兆パラメータとして使用される[10], [23]が、これらのパラメータはデバイス動作中のパッケージ部品の磨耗故障との関連性が高く、変化するため、最終的な故障に対して敏感であるものの、故障の進行を検出することは困難である[15]。そこで、故障の進行を検出するために、アコースティック・エミッション（AE）センサデータを用いた研究が進められている[13]。AEセンサデータは、マイクロエレクトロニクスにおいてバルク材料[14] やリチウムイオン電池[3]、積層セラミックコンデンサー[17]、燃料電池[16]など、様々な材料損傷の実時間評価に利用されている。AEセンサは試験体に取り付けられ、信頼性試験中に材料が損傷したときに材料から放出される弾性波を検出する。図1にパワーエレクトロニクス機器の磨耗故障による弾性波の発生と伝播過程の一例を示す。損傷によって検出される弾性波はAE信号と呼ばれ、損傷の量、大きさ、成長率などさまざまな損傷情報を含んでいる。損傷や最終故障の情報は、損傷や最終故障の情報は、AE信号の時間領域や周波数領域の特性（カウント、振幅、中心周波数など）を解析することで定義される。そこで、本研究では一般的な故障予兆パラメータに加えて、AEセンサデータに現れるAE信号の重要な特徴を故

障予兆パラメータとして用いた。

また、パワーモジュールの信頼性を高めるために、PCTは複数のデバイスに対して行われる。そのため、今回取り扱う時系列データは複数のドメイン（デバイス、センサ、時間など）を持つ複雑なデータであり、多角的なパターンを持つことが多い。つまり、複数の時系列パターンの時間遷移のみならず、複数デバイス間における共通/相違なパターンを持つことが考えられる。デバイスの故障の要因を効果的に捉えるためには、このような多角的かつ動的なパターンを柔軟に表現すると同時に、それらの間に隠された因果関係を明らかにする必要がある。

加えて、時系列データを用いた寿命予測タスクにおいて、入力として用いられる時系列データには、正常、故障予兆、故障後などの時系列パターンが含まれることが想定されるが、得られた時系列パターンのうち故障予兆を含むデータを重点的に学習することで、より効果的かつ効率的な学習が可能になると考えられる。

本論文では、大規模時系列データを用いたパワーモジュール寿命予測手法を提案する。提案手法は、時系列データに含まれる典型的なパターン（本研究では、“レジーム”と呼ぶ）の数と変化点を多角的に捉え、デバイスの状況を正確に把握することで、将来発生する故障を効果的に予測する。より具体的には、

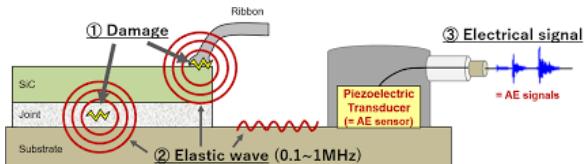


図1: PCT時のパワーモジュールにおけるAE信号（弾性波）の発生、伝播、収集プロセス[2]

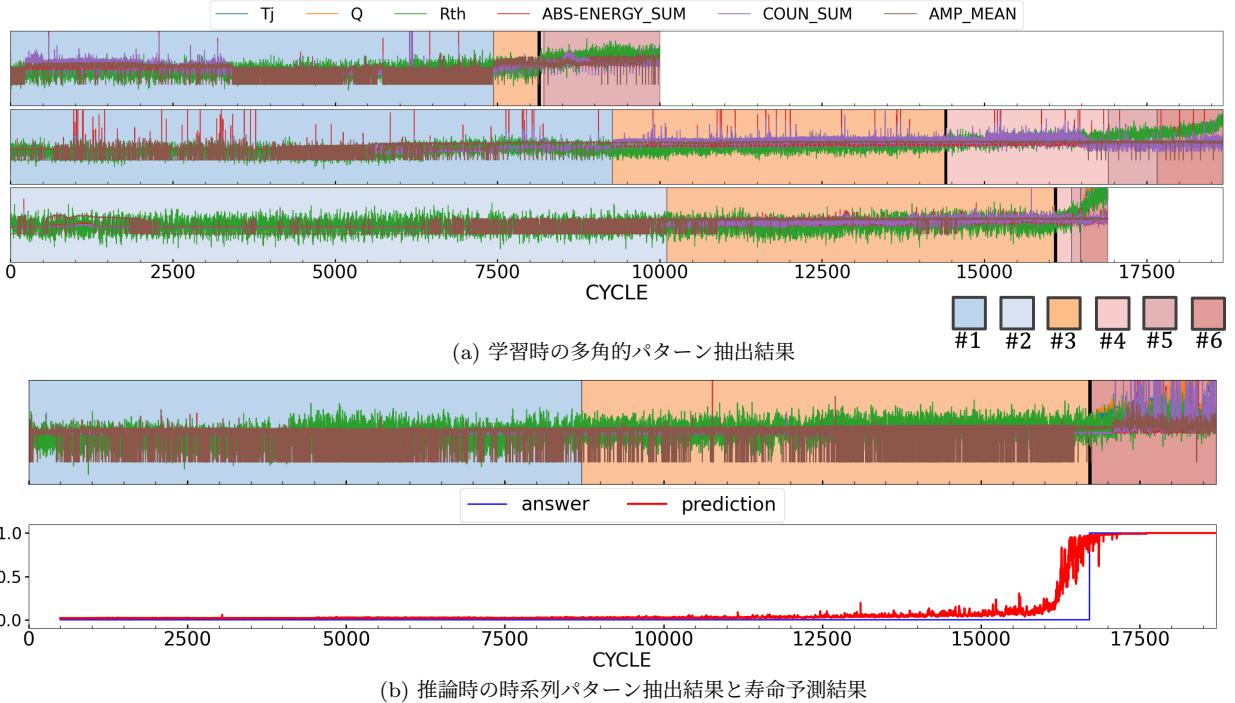


図 2: パワーモジュールのパワーサイクル試験時に得られる時系列データを与えたときのパターン抽出と寿命予測結果

(a) 時系列データの中から多角的な時系列パターンとその変化点を自動抽出し、デバイス状態を推定する。さらに、(b) デバイス状態の変化に応じて予測モデルを切り替え、デバイスの寿命予測をする。

1.1 具体例

図 2 は、SiC ショットキーバリアダイオード (SBD) をDBC 基板に焼結銀を用いて接合された 4 つのデバイスの PCT において得られたパワーモジュールのジャンクション温度 (T_j)、電力 (Q)、熱抵抗 (R_{th}) と AE センサデータから得られる特徴量 (1 サイクル内で発生した AE 信号におけるエネルギーの絶対値の合計 (ABS-ENERGY_SUM), 1 サイクル内で発生した AE 信号のカウント数の合計値 (COUN_SUM), 1 サイクルで発生した AE 信号の振幅の平均値 (AMP_MEAN)) からなる時系列テンソルを提案手法に与えたときに得られる時系列パターン抽出結果と寿命予測結果を示す。4 つのデバイスは全て、リボンボンド接合部位の破断により故障している。図中の横軸はサイクル数を表し、縦線は時系列パターンが変化したサイクル、黒太線は故障が発生したサイクルを示し、同一レジームに属するセグメントは同一色で塗られている。また、PCT では一定時間の加熱と冷却を 1 サイクルとし、指定された温度にジャンクション温度が達するまで、加熱と冷却が繰り返し行われる。

図 2(a) にて、提案手法は与えられた時系列テンソルから正常レジーム (#1, #2), 予兆レジーム (#3), 故障後レジーム (#4, #5, #6) を自動的に捉えることに成功した。さらに、正常レジーム、故障後レジームについては、デバイス間に個体差があり、予兆レジームについては、全てのデバイスにおいて共通していることを発見した。これは、提案手法が、複数のデバイスから得られた時系列データを同時に解析することにより、

多角的なパターン、すなわち、各デバイス内のパターンの時間遷移だけでなく、デバイス間で共通、あるいは相違なパターンの検出が可能であるためである。

また、図 2(b) に推論時の時系列パターン抽出結果（上図）と $l_s = 400$ ステップ（約 2 時間）後の寿命予測結果（下図）を示している。寿命予測結果の図において、青線が正解ラベル、赤線が提案手法による予測結果を示している。提案手法は、新たに与えられた時系列データに対して学習時に生成された正常レジーム (#1), 予兆レジーム (#3), 故障後レジーム (#6) を適切に割り当て、予兆レジームについて重点的に学習したモデルで故障発生前後の予測を行うことで、高精度な寿命予測にも成功した。

1.2 本研究の貢献

本研究では、PCT 時に得られる多次元時系列データを用いたパワーモジュール寿命予測手法を提案する。本手法は次の特徴を持つ。

- PCT 時に得られるデータ内に含まれる時系列パターン (レジーム) の変化点と潜在的な振る舞いを、時間遷移とデバイス間の多角的な観点から把握する。
- 入力サンプルの時系列パターンに応じて予測モデルを個別に構築することで、効率的な学習を行う。
- 時系列パターンの変化に応じて予測モデルを切り替えることで、効果的な寿命予測を行う。

2 関連研究

時系列データ解析に関する研究は、データベースやデータマイニング等、様々な分野で進められている [1], [22], [24]。自己回帰モデルや線形動的システムは代表的な技術であり、これら

表 1: 主な記号と定義

記号	定義
w	デバイスの数
d	時系列の次元数
n	時系列の長さ
\mathcal{X}	時系列テンソル $\mathcal{X} \in \mathbb{R}^{w \times d \times n}$
\mathcal{Y}	ラベル集合 $\mathcal{Y} = \{\mathbf{y}_1, \dots, \mathbf{y}_w\}$
m	セグメントの数
\mathcal{S}	\mathcal{X} に含まれるセグメント集合: $\mathcal{S} = \{s_1, \dots, s_m\}$
k_i	i 番目のレジームの潜在状態数
r	レジームの数
Θ	r 個のレジームパラメータ集合 $\Theta = \{\theta_1, \dots, \theta_r, \Delta_{r \times r}\}$
θ_i	i 番目のレジームパラメータ
$\Delta_{r \times r}$	レジーム遷移行列: $\Delta = \{\delta_{ij}\}_{i,j=1}^r$
\mathcal{F}	セグメントメンバーシップ $\mathcal{F} = \{f_1, \dots, f_m\}$
$Cost_M(\Theta)$	Θ のモデル表現コスト
$Cost_C(\mathcal{X} \Theta)$	Θ による \mathcal{X} の符号化コスト
\mathcal{M}	r 個の予測モデル集合 $\mathcal{M} = \{\mathcal{M}_1, \dots, \mathcal{M}_r\}$
\mathcal{M}_i	i 番目のレジームに対応する予測モデル

に基づく時系列データの解析と予測手法が数多く存在する [18]. OrbitMap [20] は大量に生成され続ける多次元センサデータに含まれる動的パターンを、潜在的な非線形微分方程式に基づきリアルタイムに推定することで、適応的に将来を予測する手法である。本手法は半無限長のセンサストリームを入力とし、センサデータの実測値の予測において高い性能を示すが、分類タスクの予測には対応していない。

また、時系列ビッグデータを対象としたパターン検出とクラスタリングも重要な課題である [9], [12], [21]. Honda ら [11] は大規模時系列テンソルの解析手法として CubeMarker を提案した。CubeMarker は多角的な分析により、時系列データに含まれる典型的なパターンの数や変化点を自動抽出する手法であるが、新たに与えられた時系列テンソルを過去に生成されたモデルで表現する能力は持っていない。

パワーサイクル試験におけるパワーモジュールの故障の進行を検出するための研究も進められている [10], [13], [23], [27]. Choe ら [2] は、SiC パワーモジュールの消耗故障の監視にアコースティックエミッション (AE) を適用し、AE モニタリングがリボンのリフトオフ破壊につながる加速度的な伝播段階を破断前に検出することを確認し、高感度の早期警報方法として使用できることを示した。しかし、AE センサデータを用いた寿命予測技術の開発には至っていない。

3 問題定義

本章では、本論文で必要な概念と取り組む問題の定義を行う。表 1 に主な記号と定義を示す。時系列テンソル \mathcal{X} が与えられたとき、本研究ではまず、 \mathcal{X} を m 個のセグメント集合 $\mathcal{S} = \{s_1, \dots, s_m\}$ に分割してその特徴をとらえる。 s_i は i 番目のセグメントの開始点 t_s 、終了点 t_e 、デバイス番号で構成され(つまり、 $s_i = \{t_s, t_e, deviceID\}$)、各セグメントは重複がないものとする。そして、発見したセグメント集合を類似セグメントのグループに分類する。本論文ではこれらのグループをレジームと呼ぶ。

[定義 1] (レジーム) r を最適なセグメントグループの個数とする。それぞれのセグメント s はセグメントグループの 1 つに割り当てられる。

さらに、各セグメントが所属するレジームを表現するため、セグメントメンバーシップを定義する。

[定義 2] (セグメントメンバーシップ) 時系列テンソル \mathcal{X} が与えられたとき、

$\mathcal{F} = \{f_1, \dots, f_m\}$ を、 m 個の整数列とし、 f_i を i 番目のセグメントが所属するレジームの番号とする。

これにより、時系列テンソル \mathcal{X} を m 個のセグメントと r 個のレジームで $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ として表現することができる。ここで、 Θ は r 個のレジームのモデルパラメータ集合を表している。つまり、 r 個のレジームは統計モデル $\Theta = \{\theta_1, \dots, \theta_r, \Delta_{r \times r}\}$ として表現される。本研究では、時系列テンソルの振る舞いを表現するため、隠れマルコフモデル (HMM: Hidden Markov Model) を用いる。HMM は隠れ状態を持つマルコフ過程を仮定した確率モデルの一種であり、音声認識を含む様々な分野において、時系列処理手法として広く利用されている [6], [19], [28]. HMM は初期確率 $\pi = \{\pi_i\}_{i=1}^k$ 、遷移確率 $\mathbf{A} = \{a_{ij}\}_{i,j=1}^k$ 、出力確率 $\mathbf{B} = \{b_i(\mathbf{x})\}_{i=1}^k$ の三つ組で表現される(すなわち、 $\theta = \{\pi, \mathbf{A}, \mathbf{B}\}$)。ここで、 k は HMM の潜在状態数を示す。本論文では出力確率 \mathbf{B} が多次元ガウス分布から生成されるものとする。これにより多次元ベクトルのシーケンスを確率モデルで表現する(つまり $\mathbf{B} \sim \{\mathcal{N}(\mu_i, \sigma_i^2)\}_{i=1}^k$)。HMM のモデルパラメータ $\theta = \{\pi, \mathbf{A}, \mathbf{B}\}$ と、あるデバイスのシーケンス \mathbf{X} が与えられたとき、 \mathbf{X} の尤度 $P(\mathbf{X}|\theta)$ は次のように計算される。

$$P(\mathbf{X}|\theta) = \max_{1 \leq i \leq k} \{p_i(n)\}$$

$$p_i(t) = \begin{cases} \pi_i \cdot b_i(\mathbf{x}_1) & (t = 1) \\ \max_{1 \leq j \leq k} \{p_j(t-1) \cdot a_{ji}\} \cdot b_i(\mathbf{x}_t) & (2 \leq t \leq n) \end{cases}$$

ここで、 $p_i(t)$ は時刻 t における潜在状態 i の最大確率を示し、 n は \mathbf{X} のシーケンス長である。この尤度は動的計画法の一種であるビタビアルゴリズム [8] を用いて計算される。さらに、レジーム遷移行列 $\Delta_{r \times r}$ という概念を導入する。

[定義 3] (レジーム遷移行列) $\Delta_{r \times r}$ を r 個のレジーム群の遷移行列と呼ぶ。ここで、要素 $\delta_{ij} \in \Delta$ は i 番目のレジームから j 番目のレジームへの遷移確率を示す。

本研究の最終的な目的は、時系列テンソル \mathcal{X} から l_s ステップ先の寿命を予測することであり、取り組む問題を以下のように定義する。

[問題 1] 時系列テンソル $\mathcal{X}(t_s : t_e)$ が与えられたとき、 l_s ステップ先の寿命を $\mathcal{Y}(t_e + l_s)$ を次式に基づいて予測する。

$$\mathcal{Y}(t_e + l_s) \approx F(\mathcal{X}(t_s : t_e)). \quad (1)$$

ここで、 $t_s : t_e$ は予測に使用するテンソルのウインドウを表し、 F を提案モデルとする。

提案手法は、 $\mathcal{Y}(t_e + l_s)$ を高精度に予測するために、確率モ

デルと深層学習に基づくモデルを構築する。具体的には、次の2つの能力を有する。

- (P1) 潜在的な動的パターンの多角的な検出
- (P2) l_s ステップ先の長期的な寿命予測

4 アルゴリズム

提案手法は、以下の2つのアルゴリズムで構成される。

• (P1) 潜在的な時系列パターンの検出：テンソル \mathcal{X} に含まれる時系列パターンの種類と変化点を検出する。各時系列パターンのダイナミクスをレジームパラメータ集合 Θ として表現し、 \mathcal{X} の要約情報 $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ を得る。学習時において生成されたレジームパラメータ集合は、RegimeDB に保存する。推論時において生成されたレジームパラメータ集合は、RegimeDB 内のレジームパラメータ集合で置換する。

• (P2) l_s ステップ先の寿命予測：テンソル \mathcal{X} のうち、あるデバイスの部分シーケンス $\mathbf{X}(t_s : t_e)$ について、(P1) の結果を基に、ModelDB 内の予測モデル集合 \mathcal{M} から最適なモデルを選択し、 l_s ステップ先の故障確率 $\mathbf{Y}(t_e + l_s)$ を予測する。

図3に提案手法の概要を示す。特に、図3(a)は提案手法の学習アルゴリズム、図3(b)は提案手法の推論アルゴリズムを表している。テンソル \mathcal{X} が与えられたとき、提案手法は学習時において、まず、 \mathcal{X} の時系列パターンの時間遷移とデバイス間のパターンを捉え、レジームモデル集合 Θ をRegimeDB に保存する。その後、テンソル \mathcal{X} のうち、予測の入力として使用される、あるデバイスの部分シーケンス $\mathbf{X}(t_s : t_e)$ のレジーム情報に基づき、対応する予測モデルを選択し、個別に学習することで、予測モデル集合 \mathcal{M} を生成し、ModelDB に保存する。また、推論時において、提案手法は学習時にRegimeDB に保存されたレジームモデル集合 Θ と ModelDB に保存された予測モデル集合 \mathcal{M} を用いて、 l_s ステップ先でのデバイスの故障確率 $\mathbf{Y}(t_e + l_s)$ を予測する。

4.1 (P1) 潜在的な時系列パターンの検出

ここでは、時系列テンソル \mathcal{X} が与えられたとき、 \mathcal{X} の要約情報を得るためにアルゴリズムについて述べる。

時系列テンソルから潜在的な時系列パターンを抽出するためには、本研究では、CubeMarker [11] を用いる。時系列テンソルが与えられたとき、CubeMarker は効率的かつ効果的に重要なパターンを多角的に発見する。しかし、CubeMarker はスタッタクを用いた手法であり、貪欲法に基づくアルゴリズムであるため、新規時系列テンソルを過去に生成したレジームパラメータ集合で表現することができない。

そこで、本研究では、新規時系列テンソルを過去に生成されたレジームパラメータ集合で表現するためのアルゴリズムとして、REGIMEINTEGRATION を導入する。新規時系列テンソル、CubeMarker により生成された新規時系列テンソルの要約情報、過去に生成されたレジームパラメータ集合が与えられたとき、REGIMEINTEGRATION は新規時系列テンソルを過去に生成されたレジームパラメータ集合で表現した場合の要約情報を生成する。

4.1.1 CubeMarker

3章で定義した概念を用いて、CubeMarker は時系列テンソル \mathcal{X} の要約情報 $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ を生成する。ここで問題となるのは、どのようにして最適なレジーム数 r とセグメント数 m を決定するかである。そこで、CubeMarker は最小記述長 (MDL: Minimum Description Length) の概念に基づき、適切なモデルを生成するための基準となる符号化スキームを導入する。直感的には、データが与えられたときのモデルのよさは次の式で表現できる。

$$Cost_T(\mathcal{X}; \mathcal{C}) = \alpha \cdot Cost_M(\mathcal{C}) + Cost_C(\mathcal{X}|\mathcal{C}) \quad (2)$$

ここで、 $Cost_M(\mathcal{C})$ は要約情報 $\mathcal{C} = \{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ を表現するためのモデルコストを示し、 $Cost_C(\mathcal{X}|\mathcal{C})$ は \mathcal{C} が与えられたときのテンソル \mathcal{X} の符号化コストを示す。 α はモデルコストに対する重み¹であり、 α の値が小さいほどより実データに正確なモデルを生成する（セグメントの数 m 、レジームの数 r が大きくなる）。

モデルコスト。 具体的には、提案手法の全パラメータ集合の表現コストは次の要素で構成される：時系列テンソル \mathcal{X} のサイズ： $\log^*(w) + \log^*(d) + \log^*(n)$ ビット²、セグメント集合 \mathcal{S} ： $\log^*(m) + \sum_{i=1}^{m-1} \log^*|s_i|$ ビット、レジーム割り当て \mathcal{F} ： $m \log(r)$ ビット、レジームパラメータ集合 Θ ： $\sum_{i=1}^r Cost_M(\theta_i) + Cost_M(\Delta)$ ビット。ここで、浮動小数点のコストを C_F とすると、 k 個の状態を持つ単一のレジームパラメータ θ は $Cost_M(\theta) = \log^*(k) + C_F \cdot (k + k^2 + 2kd)$ 、レジーム遷移行列 Δ は $Cost_M(\Delta) = C_F \cdot r^2$ のコストを要する。

符号化コスト。 モデル θ が与えられた際の \mathcal{X} の符号化コストは、ハフマン符号を用いた情報圧縮により、負の対数尤度を用いて次のように表現することができる： $Cost_C(\mathcal{X}|\theta) = \log \frac{1}{P(\mathcal{X}|\theta)} = -\log P(\mathcal{X}|\theta)$ 。ここで、 $P(\mathcal{X}|\theta)$ は \mathcal{X} の尤度を示す。テンソル \mathcal{X} と r 個のレジームのモデルパラメータ集合 Θ が与えられたとき、データ圧縮ためのコストの総数は次のとおりである： $Cost_C(\mathcal{X}|\Theta) = \sum_{i=1}^m Cost_C(\mathcal{X}[s_i]|\Theta) = \sum_{i=1}^m -\log(\delta_{vu} \cdot (\delta_{uu})^{|s_i|-1} \cdot P(\mathcal{X}[s_i]|\theta_u))$ 。ここで、 i と $(i-1)$ 番目のセグメントはそれぞれ u と v 番目のレジームに所属するものとし、 $\mathcal{X}[s_i]$ は \mathcal{X} に含まれるセグメント s_i で構成される部分シーケンスを表す。 $P(\mathcal{X}[s_i]|\theta_u)$ は θ_u が与えられたときの $\mathcal{X}[s_i]$ の尤度とする。

結論として、CubeMarker は式(2)を最小化するように、 \mathcal{X} に含まれる時系列パターンとその変化点の数 r, m を決定する。

次に、時系列テンソルの多角的解析のためのアルゴリズムである V-Split と H-Split をについて説明する。V-Split は時間方向の観点からレジームを推定し、H-Split はデバイスごとの特性をレジームとして表現する。これら二つのアルゴリズムを任意方向に行うことで、効率的かつ効果的に重要なパターンを多角的に発見し、レジームとして要約する。具体的には、式(2)に基づき、以下の二つのアルゴリズムを繰り返す。

1: デフォルトでは $\alpha = 1.0$.

2: ここで、 \log^* は整数のユニバーサル符号長を表す： $\log^*(x) \approx \log_2(x) + \log_2 \log_2(x) + \dots$ [25].

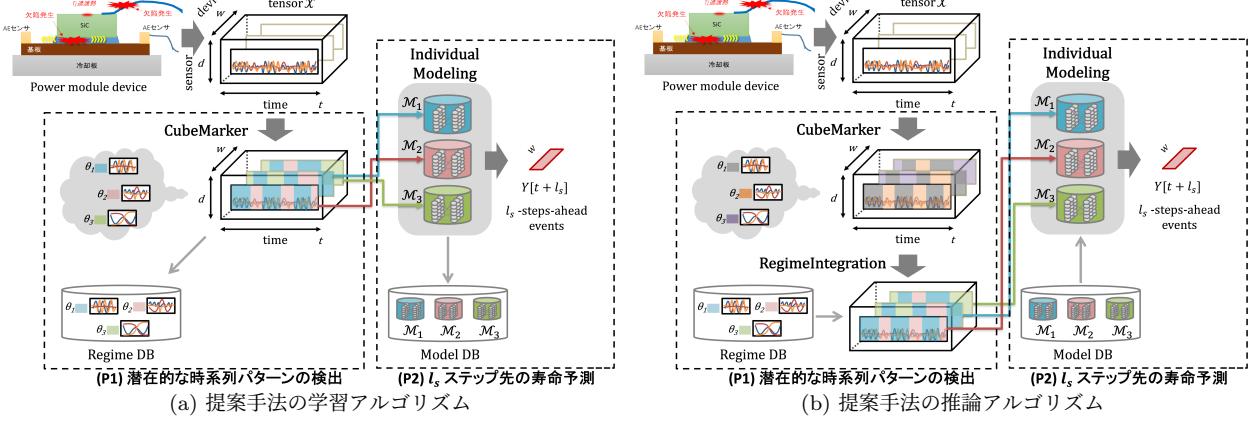


図 3: 提案手法のアルゴリズム概要

- V-Split: テンソル \mathcal{X} から時間遷移するパターンとその変化点を検出し 2 つのレジームに分割する。それら 2 つのレジームに対し、モデルパラメータ $\{\theta_1, \theta_2, \Delta\}$ を推定する。
- H-Split: テンソル \mathcal{X} に表れるある 1 つのレジームからデバイスごとの特徴を抽出し、2 つのレジームに分割後、それらのレジームのモデルパラメータを推定する。

上記のアルゴリズムにより、 $r = 1, 2, \dots$ とレジーム数が変化していく。もしレジーム θ_0 を 2 つのレジーム $\{\theta_1, \theta_2\}$ に分割した際、式(2)のコスト関数の値が大きくなれば θ_0 は最適とみなし、これ以上分割しない。生成された全てのレジームについて同様にコスト計算を繰り返し、コストが下がらなくなるまで上記の分割アルゴリズムを繰り返す。最終的に、コストが収束したときの要約情報 $\{m^*, r^*, \mathcal{S}^*, \mathcal{F}^*\}$ を出力し、CubeMarker を終了する。また、学習時に生成されたレジームパラメータ集合 Θ は、RegimeDB に保存される。

4.2 RegimeIntegration

続いて、推論時において CubeMarker により生成された要約情報を、RegimeDB 内のレジームパラメータ集合で表現するためのアルゴリズムである REGIMEINTEGRATION について述べる。新規時系列テンソル \mathcal{X}^* 、 \mathcal{X}^* の要約情報 $\{m^*, r^*, \mathcal{S}^*, \mathcal{F}^*\}$ 、RegimeDB 内の r 個のレジームのモデルパラメータ集合 Θ が与えられたとき、REGIMEINTEGRATION は、新規時系列テンソル \mathcal{X}^* を RegimeDB 内のレジームパラメータ集合 Θ を用いて表現した場合の要約情報を生成する。

具体的なアルゴリズムの流れをアルゴリズム 1 に示す。まず、各レジーム θ_i^* に割り当てられたセグメント集合 \mathcal{S}_i^* に対し、RegimeDB 内のレジームパラメータ集合 Θ に含まれる r 個のレジームパラメータのうち、符号化コストが最小となるレジームパラメータ θ_j を求める。最後に、セグメント集合 \mathcal{S}_i^* をレジーム θ_j に割り当てることで、統合後の要約情報 $\{m^*, r, \mathcal{S}^*, \Theta, \mathcal{F}'\}$ を取得する。

5 (P2) l_s ステップ先の寿命予測

ここでは、(P1) で生成された要約情報 $\{m, r, \mathcal{S}, \Theta, \mathcal{F}\}$ とあ

Algorithm 1 REGIMEINTEGRATION ($\mathcal{X}^*, \Theta, m^*, r^*, \mathcal{S}^*, \mathcal{F}^*$)

```

1: Input: Tensor  $\mathcal{X}^*$ , model parameters in RegimeDB  $\Theta$ ,
   summary information  $\{m^*, r^*, \mathcal{S}^*, \mathcal{F}^*\}$ 
2: Output:  $\mathcal{F}'$ 
3:  $\mathcal{F}' = \{f'_1, \dots, f'_{m^*}\}$ ;
4: for  $i = 1$  to  $r^*$  do
5:    $minCost = \infty$ ;  $similarRegimeID = 0$ ;
6:   for  $j = 1$  to  $r$  do
7:     if  $minCost > Cost_C(\mathcal{X}^*[\mathcal{S}_i^*] | \theta_j)$  then
8:        $minCost = Cost_C(\mathcal{X}^*[\mathcal{S}_i^*] | \theta_j)$ ;
9:        $similarRegimeID = j$ ;
10:    end if
11:   end for
12:   for  $k = 1$  to  $m^*$  do
13:     if  $f_k^* == i$  then
14:        $f'_k = similarRegimeID$ ;
15:     end if
16:   end for
17: end for
18: return  $\mathcal{F}'$ ;

```

るデバイスの部分シーケンス $\mathbf{X}(t_s : t_e)$ を基に、 l_s ステップ先のデバイスの故障確率 $\mathbf{Y}(t_e + l_s)$ を効率的に予測するためのアルゴリズムについて述べる。部分シーケンスが与えられたときの l_s ステップ先のデバイスの故障確率を予測するために、本研究では、予測モデルとして Gated Recurrent Unit (GRU) [4] を用いる。さらに、(P1) で生成された要約情報を活用し、より効率的かつ効果的な寿命予測を行うためのアルゴリズムとして、INDIVIDUALMODELING を導入する。

5.1 GRU

提案手法の予測モデルとして用いる GRU について、具体的な説明を行う。GRU は、RNN [26] の中間層のユニットをメモリユニットと呼ばれる特殊な構造に置き換えたものであり、メモリユニットは更新ゲートとリセットゲートの 2 つのゲートによって構成されている。更新ゲートは過去の情報をどれだけ将来の予測へ加味するか決定し、リセットゲートは過去の情報をどれだけ忘却するか決定する役割を持つ。時刻 t における更新ゲートの値を z_t 、リセットゲートの値を r_t 、新しい隠れ状態

を \tilde{h}_t とすると、GRU の順伝播は以下の式で表現される。

$$\begin{aligned} z_t &= \sigma(\mathbf{x}_t \mathbf{W}_x^{(z)} + \mathbf{h}_{t-1} \mathbf{W}_h^{(z)} + \mathbf{b}^{(z)}) \\ r_t &= \sigma(\mathbf{x}_t \mathbf{W}_x^{(r)} + \mathbf{h}_{t-1} \mathbf{W}_h^{(r)} + \mathbf{b}^{(r)}) \\ \tilde{h}_t &= \tanh(\mathbf{x}_t \mathbf{W}_x + (r_t \odot \mathbf{h}_{t-1}) \mathbf{W}_h + \mathbf{b}) \\ h_t &= (1 - z_t) \mathbf{h}_{t-1} + z_t \tilde{h}_t \end{aligned}$$

ここで、 \odot はアダマール積を示し、 $\sigma(\cdot)$ は sigmoid 関数を示す。GRU はメモリユニットによって与えられた入力系列の長期依存性を学習することができるため、レジーム内部の状態遷移の過程でデバイス故障に対して特に重要な特徴を記憶しながら、最新のデバイス状況を要約した特徴ベクトルを抽出すると考えられる。最後に、 \mathbf{h}_t を用いて l_s ステップ先の寿命予測を行う。

本研究では、時刻 t における最新の部分シーケンスからの l_s ステップ先寿命予測を 2 クラス分類タスクとして扱い、出力を時刻 $t + l_s$ における故障発生確率とする。したがって、提案手法の最終的な出力は、 $\hat{y}_{t+l_s} = \sigma(\mathbf{h}_t \mathbf{W}_h^{(y)} + \mathbf{b}^{(y)})$ となる。また、提案モデルが最小化すべき目的関数は Binary cross entropy (BCE) となり、モデル学習時のバッチサイズを N 、各入力サンプル i に対する提案手法の出力値を \hat{y}_i 、正解ラベルを y_i とすると、 $\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \{y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)\}$ で表される。

5.2 Individual Modeling

INDIVIDUAL MODELING は、入力部分シーケンスのレジーム情報に基づき、各レジームのパターンに特化した予測モデルを作成することで、効果的かつ効率的な学習、推論を実現するためのアルゴリズムである。より具体的には、 r 個の予測モデル集合 $\mathcal{M} = \{\mathcal{M}_1, \dots, \mathcal{M}_r\}$ を用いて予測を行う。まず、入力部分シーケンス $\mathbf{X}(t_s : t_e)$ がレジーム θ_i の時系列パターンを持つ場合、 l_s ステップ先のデバイス状態をモデル \mathcal{M}_i で予測し、学習させる。そして、推論時には、部分シーケンス $\mathbf{X}(t_s : t_e)$ がレジーム θ_i の時系列パターンを持つ場合、モデル \mathcal{M}_i を用いて予測を行う。

6 評価実験

本論文では、提案手法の有効性を検証するため、実データを用いた実験を行った。図 2 において提案手法の具体例をすでに示した。本章では、AE センサデータの時系列解析と PCT におけるパワーモジュール寿命の長期的予測に対する提案手法の精度の検証を行う。実験は 196GB のメモリ、Intel Xeon Gold 5218 2.3GHz の CPU と NVIDIA Tesla V100 32GB の GPU 搭載の Linux (CentOS 8.2) マシン上で実施した。

本研究で使用した、PCT における故障データの取得に用いられたパワーモジュールと PCT 設定を表 2 に示す。ここで、 T_j はジャンクション温度を示す。

本研究では、基盤、チップ、接合材料が共通している 2 つ以上のデバイスの PCT により得られた時系列データを 1 つのデータセットとみなし、3 つのデータセットについてデバイスの寿命予測を行った。また、本実験で用いたデータセットは、

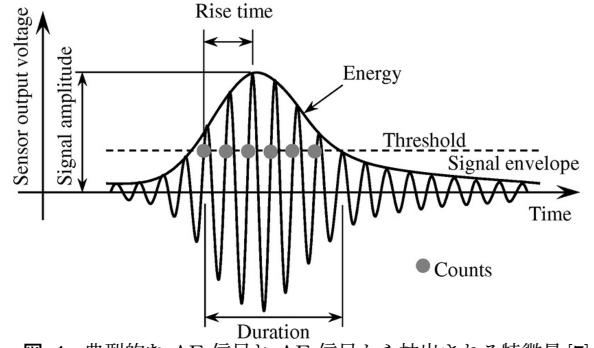


図 4: 典型的な AE 信号と AE 信号から抽出される特微量 [7]

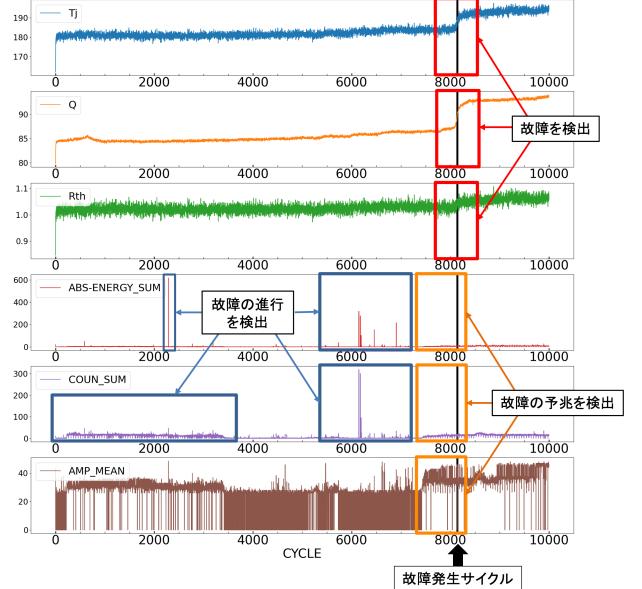


図 5: デバイス 1 の PCT において得られた多次元時系列データ

全て平均値と分散値で正規化 (z-normalization) して使用している。

6.1 AE センサデータの時系列解析

AE センサデータは複数の AE 信号により構成される。図 4 より、1 つの AE 信号から様々な特徴量 (AE パラメータ) を抽出可能であることがわかる。本研究では、AE パラメータのうち、AE 信号の包絡線検波波形の面積から計算されるエネルギー、しきい値を超えた AE 波の振動回数を表すカウント数、AE 信号の振幅値を用いた。より具体的には、1 サイクルで発生した AE 信号の、エネルギーの絶対値の合計値 (ABS-ENERGY_SUM)、カウント数の合計値 (COUN_SUM)、振幅の平均値 (AMP_MEAN) を AE センサデータから得られる故障予兆パラメータとして用いた。また、AE パラメータに加えて、一般的に故障予兆パラメータとして用いられる、デバイスの熱特性や電気特性を表すデータのうち、ジャンクション温度 (T_j)、電力 (Q)、熱抵抗 (R_{th}) を用いた。

図 5 にデバイス 1 の PCT において得られたデータのうち、本研究で入力データとして用いた多次元時系列データの詳細を示す。横軸はサイクル数を示しており、8200 サイクル付近の黒太線はパワーモジュールの故障発生サイクル、青枠はデバイスの故障の進行を捉えているデータ、オレンジ枠はデバイスの故障

表 2: PCT における故障データ取得に使用されたパワーモジュールと PCT 設定

デバイス ID	基盤	チップ	接合材料	初期 T_j (°C)	加熱時間(秒)	冷却時間(秒)	故障発生サイクル	故障原因
1	Direct Bonded Copper	SiC ショットキーバリアダイオード	焼結銀	175	3.740	11.000	8140	リボンボンド接合部位の破断
2	Direct Bonded Copper	SiC ショットキーバリアダイオード	焼結銀	175	2.000	18.000	14400	リボンボンド接合部位の破断
3	Direct Bonded Copper	SiC ショットキーバリアダイオード	焼結銀	175	2.000	18.000	16100	リボンボンド接合部位の破断
4	Direct Bonded Copper	SiC ショットキーバリアダイオード	焼結銀	175	2.000	18.000	16700	リボンボンド接合部位の破断
5	Direct Bonded Copper	SiC マイクロヒーターチップ	焼結銀	180	2.000	5.000	7620	基板接合部の劣化進展
6	Direct Bonded Copper	SiC マイクロヒーターチップ	焼結銀	180	2.000	5.000	7720	基板接合部の劣化進展
7	Direct Bonded Copper	SiC マイクロヒーターチップ	鉛フリーはんだ	180	2.000	5.000	1360	基板接合部の劣化進展
8	Direct Bonded Copper	SiC マイクロヒーターチップ	鉛フリーはんだ	180	2.000	5.000	1335	基板接合部の劣化進展

表 3: 予測結果の F1 スコアによる比較

	デバイス 1 ~ 4	デバイス 5, 6	デバイス 7, 8
GRU	0.90	0.87	0.93
RNN	0.91	0.80	0.97
Proposed	0.95	0.92	0.97

の進行を捉えているデータ、赤枠はデバイスの故障のタイミングを捉えているデータを表している。図 5 から、デバイスの熱特性や電気特性の変化を表すデータ (T_j , Q , R_{th}) は、デバイスの故障のタイミングを正確に捉えているのに対して、AE センサデータの特徴量である AE パラメータ (ABS-ENERGY_SUM, COUN_SUM, AMP_MEAN) は、故障の進行や予兆など、故障発生前のデバイス状態の変化を捉えていることがわかる。

本研究では、PCT 時のパワーモジュールの状態変化を正確に捉えるための入力時系列テンソルデータとして、複数のデバイスから得られる、 T_j , Q , R_{th} , ABS-ENERGY_SUM, COUN_SUM, AMP_MEAN の 6 次元の時系列データを用いた。

6.2 提案手法の予測精度

次に、与えられた時系列テンソルに対する提案手法の寿命予測精度について検証する。比較手法には、再帰型ニューラルネットワークモデルである RNN (Recurrent neural network) [26], GRU (Gated recurrent unit) [4] を使用した。提案手法を含むすべての再帰型モデルについて、ユニット数を 5 としており、学習率は 0.001、バッチサイズは 32 に設定し、最適化アルゴリズムには NAdam [5] を使用した。評価指標には F1 スコアを使用し、しきい値を 0.9 に設定して精度を比較した。F1 スコアは故障と予測したサンプルの合計数のうち正解であったサンプルの合計数の割合を示す適合率 (Precision) と、正しく予測したサンプルの合計数のうち故障と予測したサンプルの合計数の割合を示す再現率 (Recall) の調和平均を表しており、次の式で求められる。

$$F_1 = \frac{2 \times recall \times precision}{recall + precision}$$

F1 スコアは精度が高い場合には 1 に近づく。また、提案手法を含むすべての手法において、loss の改善が見られなかったエポックにて学習を終了した。

表 3 に、デバイス 1 ~ 4 の PCT データセットにおいてモデルコストの重み 0.5、予測ステップ数 300、ウインドウサイズ 500 としたときと、デバイス 5, 6 の PCT データセットにおいてモデルコストの重み 5.0、予測ステップ数 300、ウインドウサイズ 1000 としたとき、デバイス 7, 8 の PCT データセットにおいてモデルコストの重み 0.5、予測ステップ数 100、ウイ

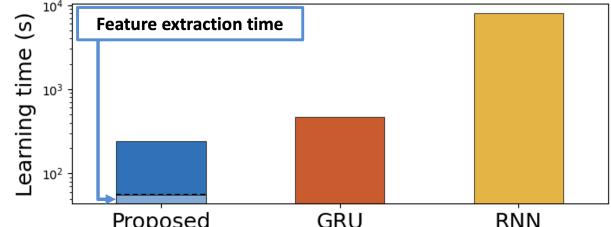


図 6: 学習に要した時間の比較

ンドウサイズ 100 としたときの予測精度を F1 スコアを用いて比較した結果を示す。太字は各データセットにおいて最も精度の高い値を表している。3 つのデータセット全てにおいて、提案手法は比較手法よりも高い精度での予測に成功している。これは、正確な特徴抽出結果に基づき入力サンプルを複数のモデルに振り分けて学習することで、単一モデルによる学習よりも効果的な学習を行えたためであると考えられる。

6.3 提案手法の学習速度

図 6 はデバイス 1, 2, 3 の PCT データセットをモデルコストの重み 0.5、ウインドウサイズ 500、予測ステップ数 300、エポック数 200 に設定した際の学習に要した時間の比較結果を示している。提案手法は予測モデルの学習前に時系列パターンの抽出を行っているにもかかわらず、入力サンプルの時系列パターンに基づいた予測モデル分割を行い並列に学習することで、GRU の約 2 倍、RNN の約 33 倍高速な学習を実現した。

7 む す び

本論文では、パワーサイクル試験におけるパワーモジュールの寿命予測手法を提案した。提案手法は、与えられた時系列テンソルから、デバイス間で共通、あるいは相違な時系列パターンを自動抽出することでデバイス状態を推定し、デバイス状態の変化に応じて予測モデル切り替えることで、効果的な寿命予測を実現する。実データを用いた実験では、AE センサデータから得られる AE パラメータが故障の進行や予兆を捉えていることを確認し、提案手法がデバイス間で共通した故障の予兆と見られる時系列パターンを捉えることができ、長期的な寿命予測能力を持つことを確認した。また、既存手法よりも高速な学習で高精度な予測を行えることを示した。

謝 辞 本研究の一部は JSPS 科研費 JP20H00585, JP21H03446, 国立研究開発法人情報通信研究機構委託研究 21481014, JSTAIP 加速課題 JPMJCR21U4, 総務省 SCOPE 192107004, ERCA 環境研究総合推進費 JPMEERF20201R02,

文 献

- [1] G. E. Box, G. M. Jenkins, and G. C. Reinsel. *Time Series Analysis: Forecasting and Control*. Prentice Hall, Englewood Cliffs, NJ, 3rd edition, 1994.
- [2] C. Choe, C. Chen, S. Nagao, and K. Suganuma. Real-time acoustic emission monitoring of wear-out failure in sic power electronic devices during power cycling tests. *IEEE Transactions on Power Electronics*, 36(4):4420–4428, 2021.
- [3] C.-Y. Choe, W.-S. Jung, and J.-W. Byeon. Damage evaluation in lithium cobalt oxide/carbon electrodes of secondary battery by acoustic emission monitoring. *Materials Transactions*, 56(2):269–273, 2015.
- [4] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio. Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*, 2014.
- [5] T. Dozat. Incorporating nesterov momentum into adam. 2016.
- [6] R. Durbin, S. R. Eddy, A. Krogh, and G. Mitchison. *Biological sequence analysis: probabilistic models of proteins and nucleic acids*. Cambridge university press, 1998.
- [7] M. K. ElBatanouny, J. Mangual, P. H. Ziehl, and F. Matta. Early corrosion detection in prestressed concrete girders using acoustic emission. *Journal of Materials in Civil Engineering*, 26(3):504–511, 2014.
- [8] J. G. DAVID FORNEY. The viterbi algorithm. In *Proceedings of the IEEE*, pages 268–278, 1973.
- [9] D. Hallac, S. Vare, S. Boyd, and J. Leskovec. Toeplitz inverse covariance-based clustering of multivariate time series data. In *KDD*, pages 215–223, 2017.
- [10] A. Hanif, Y. Yu, D. DeVoto, and F. Khan. A comprehensive review toward the state-of-the-art in failure and lifetime predictions of power electronic devices. *IEEE Transactions on Power Electronics*, 34(5):4729–4746, 2019.
- [11] T. Honda, Y. Matsubara, R. Neyama, M. Abe, and Y. Sakurai. Multi-aspect mining of complex sensor sequences. In *2019 IEEE International Conference on Data Mining (ICDM)*, pages 299–308. IEEE, 2019.
- [12] K. Kawabata, Y. Matsubara, and Y. Sakurai. Automatic sequential pattern mining in data streams. In *CIKM*, pages 1733–1742, 2019.
- [13] T. J. Kärkkäinen, J. P. Talvitie, M. Kuisma, J. Hannonen, J.-P. Ström, E. Mengotti, and P. Silventoinen. Acoustic emission in power semiconductor modules—first observations. *IEEE Transactions on Power Electronics*, 29(11):6081–6086, 2014.
- [14] D. Kohn, P. Ducheyne, and J. Awerbuch. Acoustic emission during fatigue of ti-6al-4v: Incipient fatigue crack detection limits and generalized data analysis methodology. *Journal of Materials Science*, 27(12):3133–3142, 1992.
- [15] A. Lahyani, P. Venet, G. Grellet, and P.-J. Viverge. Failure prediction of electrolytic capacitors during operation of a switchmode power supply. *IEEE Transactions on Power Electronics*, 13(6):1199–1207, 1998.
- [16] B. Legros, P.-X. Thivel, Y. Bultel, M. Boinet, and R. Nogueira. Acoustic emission: Towards a real-time diagnosis technique for proton exchange membrane fuel cell operation. *Journal of Power Sources*, 195(24):8124–8133, 2010.
- [17] S. Levikari, T. J. Kärkkäinen, C. Andersson, J. Tamminen, and P. Silventoinen. Acoustic phenomena in damaged ceramic capacitors. *IEEE Transactions on Industrial Electronics*, 65(1):570–577, 2018.
- [18] L. Li, J. McCann, N. Pollard, and C. Faloutsos. Dynammo: Mining and summarization of coevolving sequences with missing values. In *KDD*, 2009.
- [19] H. Liu, L. He, H. Bai, B. Dai, K. Bai, and Z. Xu. Structured inference for recurrent hidden semi-markov model. In *IJCAI*, pages 2447–2453, 2018.
- [20] Y. Matsubara and Y. Sakurai. Dynamic modeling and forecasting of time-evolving data streams. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 458–468, 2019.
- [21] Y. Matsubara, Y. Sakurai, and C. Faloutsos. Autoplait: Automatic mining of co-evolving time sequences. In *SIGMOD*, pages 193–204, 2014.
- [22] Y. Matsubara, Y. Sakurai, and C. Faloutsos. The web as a jungle: Non-linear dynamical systems for co-evolving online activities. In *WWW*, pages 721–731, 2015.
- [23] N. Patil, J. Celaya, D. Das, K. Goebel, and M. Pecht. Precursor parameter identification for insulated gate bipolar transistor (igbt) prognostics. *IEEE Transactions on Reliability*, 58(2):271–276, 2009.
- [24] T. Rakthanmanon, B. J. L. Campana, A. Mueen, G. E. A. P. A. Batista, M. B. Westover, Q. Zhu, J. Zakaria, and E. J. Keogh. Searching and mining trillions of time series subsequences under dynamic time warping. In *KDD*, pages 262–270, 2012.
- [25] J. Rissanen. A Universal Prior for Integers and Estimation by Minimum Description Length. *Ann. of Statist.*, 11(2):416–431, 1983.
- [26] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [27] Z. Zhang, A. Suetake, C. Chen, H. Ishino, H. Sampei, T. Endo, K. Sugiura, K. Tsuruta, and K. Suganuma. Development of solder deterioration diagnosis system of a power module via the acoustic emission monitoring (aem) technique. In *2021 33rd International Symposium on Power Semiconductor Devices and ICs (ISPSD)*, pages 179–182, 2021.
- [28] R. Zhao and Q. Ji. An adversarial hierarchical hidden markov model for human pose modeling and generation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, 2018.