

ツールへの習熟度による操作傾向の違いに基づく 作業支援のためのノウハウ抽出手法の提案

今井 岳[†] 牧原 史弥^{††} 寺崎 周平[†] 桑田 修平[†] 瀬川 英吾^{††}
大野 敬史^{††} 武 理一郎^{††}

[†] アマダ AI イノベーション研究所 〒100-0006 東京都千代田区有楽町 1-1-2 日比谷三井タワー 12 階
^{††} 富士通株式会社 〒211-8588 神奈川県川崎市中原区上小田中 4-1-1
E-mail: [†]{takashi.imai,shuuhei.terasaki,shuhei.kuwata}@amada.co.jp,
^{††}{makihara.fumiya,segawa.eigo,ohno,riro}@fujitsu.com

あらまし 本稿では、機器やソフトウェアなどのツールを活用する作業において、複数の作業員の操作履歴に基づき、作業の状況に応じた適切な操作を、有用なノウハウとして作業員に推薦する手法を提案する。操作履歴の中には、習熟度の低い作業員が実施したでたらめな操作や、誰でもすぐに気が付くような、推薦に値しない操作も多く含まれている。提案手法では、習熟度による作業員の行動モデルを仮定することにより、作業員の習熟度を推定しつつ、習熟度が低い作業員にとって有用であるが気が付きにくい操作を抽出する手法を構築した。提案手法により、習熟度の低い作業員にとって有用なノウハウが抽出可能であることを、人工データを用いた実験により示す。

キーワード 推薦システム, Matrix Factorization, EM アルゴリズム

1 はじめに

近年 ICT の進歩により、日常の様々な作業の遂行に ICT によるサポートが欠かせないものとなってきた。作業に活用される機器やソフトウェアなどのツールは、有用な機能が多数実装されて便利になる一方で複雑さを増し、ツールに対する習熟度が低い場合に、多くの有用な機能が十分に活用されないという問題がある。例えば、実際にユーザに利用されるソフトウェアの機能が限定的であることが文献 [1] で指摘されている。本研究の目的は、このように有用であるにもかかわらず利用されていない機能を利用者が適切に利用できるような支援を行う事により、作業員の行動変容や成長を促し、作業の効率や生産性を向上させる事である。

習熟度が低い作業員は、該当の機能（操作）の存在を知らないかまたは知っていてもどういう状況で活用すると効果的かを十分に把握できていないと考えられる。そこで、コンテキスト（状況）に応じて、適した操作の候補を作業員に提案する支援が、習熟度の低い作業員に適切な機能の活用を促すために有効であると考えられる。ここでコンテキストとは、作業員のタスクの属性や関連する環境の属性のことである。例えば、図面に基づき加工する作業であれば、図面から判断できる加工の特性や加工対象のサイズ、現在の作業工程、発注者などがコンテキストであり、これらのコンテキストに基づき、機械の設定変更などの操作を推薦する。このような支援方法は、作業のコンテキストを把握することができれば、測定機器やソフトウェア、クラウドサービスなど様々なツールに対して適用可能である。

このような推薦システムを実現するため、複数の作業員の過

去の操作履歴を活用し、各コンテキストにおける操作の傾向に基づいて推薦すべき適切な操作を抽出する方法を提案する。ここで、ツールの操作履歴には、様々な習熟度の作業員の多様な操作が記録されており、そのため、操作に慣れない作業員によるでたらめな操作や、誰でもすぐに気が付く推薦に値しない操作も多く含まれていることに留意する必要がある。支援がなくても気が付くような操作を提案しても作業員の行動変容や成長につながらず、作業員にとって煩わしいだけである。行動変容や成長を目的とした支援のためには、状況に応じて適切でかつ、習熟度が低い作業員が気が付きにくい操作を推薦する事が必要である。本稿では、作業員が操作の有用性を明確に認識できている状態を、操作（またはアイテム）が顕在化していると記述する。提案手法では、習熟度による作業員の操作モデルを仮定することにより、操作履歴から作業員の習熟度を推定し、習熟度を考慮した操作傾向に基づき、状況に応じて有用かつ顕在化しにくい操作を推薦すべきノウハウとして抽出する。また、人工データを用いて、提案手法により状況に応じた推薦すべき操作を抽出できることを確認した。

本稿の構成は、以下のとおりである。2 節で関連研究について述べ、3 節で本研究で取り組む問題を明らかにする。4 節では提案手法について詳述し、5 節で人工データによる実験方法と実験結果について述べる。6 節で実験結果の考察と今後について述べ、最後に、7 節で本稿についてまとめる。

2 関連研究

操作履歴に基づく推薦システムの問題は、暗黙的なデータに基づく推薦問題に分類される。暗黙的なデータとは、ユーザが

推薦対象の良否を明示的に評価したデータではなく、購買やクリックなどの行動履歴を肯定的評価とみなす事により収集したデータであり、ユーザに負担なく収集できるというメリットがある。

暗黙的なデータを活用した作業支援の推薦システムとして、大杉ら [2, 3] や McCarey ら [4] の研究がある。大杉ら [2, 3] はオフィスソフトウェアを対象とした機能発見の課題に対し、協調フィルタリング [5] を適用し、他のユーザの操作履歴が、機能の発見に有用であることを示した。また、McCarey ら [4] は、ソフトウェア開発時に利用する関数を推薦する Rascal というシステムを提案した。Rascal では、開発中の Java のクラスと、クラス内で利用する関数に対し、協調フィルタリングを適用している。開発中のクラスを開発者にとってのコンテキストとみなせば、この研究はコンテキストとアイテム間に協調フィルタリングを適用する事により、コンテキストに応じた作業支援を行う試みであったと言える。これらの研究はメモリベースの協調フィルタリング [5] に基づいており、データに内在する複雑な構造を考慮することは難しかった。

一方で、暗黙的なデータの性質を考慮したモデルベースの協調フィルタリング手法も研究されている [6, 7]。暗黙的なデータを用いた推薦システムでは、否定的な評価が得られない、また肯定的評価にもノイズが大きいという問題が指摘されている [6]。否定的な評価が得られないとは、選択されなかったアイテムは、必ずしも否定的な評価のため選択されなかったとは限らないという問題である。Hu らの研究 [6] は、個々の履歴に対して信頼度の概念を導入し、信頼度を考慮した損失関数を最小化する方法を提案している。選択されていないアイテムを否定的な評価とみなすがその信頼度を低く見積もり、高頻度で選択されるアイテムほど肯定評価の信頼度を高く見積もることにより、上記の問題を考慮したモデルを生成可能としている。さらに、Liang ら [7] は、選択されなかった場合に否定的評価がされたかどうかを考慮する確率モデルを導入する手法を提案している。

3 問題設定

暗黙的なデータに基づく推薦システムのための従来の手法では、購買行動やコンテンツ選択を対象としており、過去に選択された行動を、嗜好や興味と直接的に関係するとみなしていた。一方で、何らかの作業のための操作は、多くの場合、状況に応じて合理的な操作が存在し、習熟度が高い作業者は習熟度が低い作業者と比較して、合理的な操作を行う傾向が高いと考えられる。従来の手法ではこのような習熟度の違いによる行動の違いが考慮されておらず、操作履歴からコンテキストに応じた有用な操作を抽出する事は困難である。

上記のような作業に対する操作履歴の特性について、以下のように仮定した。

- 操作履歴には、様々な習熟度の作業者の操作が混ざっているが各作業者の習熟度は未知である
- 操作履歴には、状況に応じた適切な操作だけではなく、

誤って行う操作や、意味のない操作、試行錯誤のために行う操作などが含まれる

- 習熟度の高い作業者ほど、遭遇した状況（コンテキスト）でどの操作が適切かを正しく判断でき、無駄な操作が少なくなる

- 状況（コンテキスト）によって適切な操作が容易に判断できる場合と、判断が難しい場合がある

本研究では、上記の性質を考慮した人工データを生成し、人工データに真値として隠してラベル付けされている有用かつ顕在化しにくい操作を精度よく発見する手法を構築する。人工データの詳細な生成方法については、5 節で述べる。

生成する人工データのうち、観測可能である部分を操作履歴 D とし、情報抽出に利用できるとした。作業者 $u \in U$ と、コンテキスト $c \in C$ 、 c において u が実際に行った操作 $i \in I$ がシステムにより観測可能であるとする。ただし、各コンテキスト内で複数の操作が観測される可能性があり、観測されたコンテキストごとに、実施可能なすべての操作に対して実施されたかどうかを $y \in \{0, 1\}$ として記録されるとする。すなわち、観測された u 、 c に対して、実施可能なすべての操作の数の (u, c, i, y) の組み合わせが記録される。操作履歴 D の t 番目の記録を $(u^{(t)}, c^{(t)}, i^{(t)}, y^{(t)})$ とする。

4 提案手法

提案手法は、Liang ら [7] が提案する exposure matrix factorization(ExpoMF) のモデルを取り入れ、習熟度による作業者の操作モデルを考慮する拡張を行う。本節では、4.1 節で ExpoMF について述べ、4.2 節で提案手法のモデルについて述べる。4.3 節ではパラメータの推定方法について述べる。

4.1 ExpoMF

ExpoMF [7] は、アイテム i がユーザ u に対して選択肢として顕在化している場合にのみ選択されうという仮定に基づいている。 u の i に関する選択を表す確率変数 $y_{ui} \in \{0, 1\}$ と、 i が u に対して選択肢として顕在化しているかどうかを表す確率変数 $a_{ui} \in \{0, 1\}$ を用いて以下のようにモデル化される。

$$\begin{aligned}\theta_u &\sim \mathcal{N}(0, \lambda_\theta^{-1} \mathbf{I}_K) \\ \beta_i &\sim \mathcal{N}(0, \lambda_\beta^{-1} \mathbf{I}_K) \\ a_{ui} &\sim \text{Bernoulli}(\mu_{ui}) \\ y_{ui} | a_{ui} = 1 &\sim \mathcal{N}(\theta_u^\top \beta_i, \lambda_y^{-1}) \\ y_{ui} | a_{ui} = 0 &\sim \delta_0\end{aligned}\tag{1}$$

θ_u と β_i はそれぞれユーザの嗜好とアイテムの属性を表す K 次元の特徴ベクトルであり、 μ_{ui} は i が u に対して選択肢として顕在化している確率を表す。また、 λ_θ 、 λ_β 、 λ_y はハイパーパラメータであり、それぞれ θ 、 β 、 y の分散の逆数を表す。 \mathbf{I}_K は K 次元の単位行列、 δ_0 は $p(y_{ui} = 0 | a_{ui} = 0) = 1$ である確率分布であるとする。

ExpoMF ではさらに μ_{ui} に関して幾つかのモデル化を行っており、 θ_u 、 β_i および μ_{ui} を Expectation-Maximization(EM アルゴリズム) [8, 9] により推定している。

4.2 提案手法のモデル

従来の推薦モデルでは、ユーザとアイテムの嗜好に関するマッチングを考慮するが、本研究では、作業の状況（コンテキスト）に対する操作の有用さのマッチングを考慮する。また、提案モデルでは、習熟度が高い作業ほど適切な操作を行う性質を利用し、習熟度が高い作業の判断を重要視して操作の有用さを推定する。

準備として次の変数およびパラメータを導入する。

有用度 r_{ci} : コンテキスト c における行動（操作） i の有用さ

顕在化変数 $a^{(t)} \in \{0, 1\}$: 各観測において、作業 $u^{(t)}$ がコンテキスト $c^{(t)}$ において、行動 $i^{(t)}$ の有用度を正しく判断できているかどうかを表す確率変数、単に a と表すこともある

顕在化難易度 η_{ci} : コンテキスト c において、行動（操作） i の有用度を判断する難易度

習熟度 θ_u : 作業 u のツールに対する習熟度

提案手法では、ExpoMF を拡張し、以下の仮定をモデルに取り入れた。

- ユーザとアイテムではなく、コンテキストとアイテムのマッチングを行い、ユーザによる行動の違いは習熟度のみ起因する
- 作業の習熟度が顕在化難易度を上回る場合にアイテムが顕在化するとし、顕在化変数の分布は、習熟度と顕在化難易度に基づく Bradley-Terry モデル [10] に従う
- 習熟度の低い作業者のでたらめな操作を想定するため、顕在化していない場合でもアイテムが選択される可能性がある
ある操作記録において、作業 u がコンテキスト c において各操作 i を実施するかどうかの行動判断のモデルは以下のよう表すことができる。

$$\begin{aligned}\gamma_c &\sim \mathcal{N}(0, \lambda_\gamma^{-1} \mathbf{I}_K) \\ \beta_i &\sim \mathcal{N}(0, \lambda_\beta^{-1} \mathbf{I}_K) \\ a^{(t)} &\sim \text{Bernoulli}\left(\frac{\theta_u}{\theta_u + \eta_{ci}}\right) \\ y^{(t)} | a^{(t)} = 1 &\sim \mathcal{N}(\gamma_c^\top \beta_i, \lambda_y^{-1}) \\ y^{(t)} | a^{(t)} = 0 &\sim \text{Bernoulli}(\alpha_{ci})\end{aligned}\quad (2)$$

ここで、式中の右辺の添え字である u, c, i には、各観測で記録された、 $u^{(t)}, c^{(t)}, i^{(t)}$ の値が入る。 γ_c, β_i はそれぞれコンテキスト c と行動（操作） i の潜在特徴量を表す K 次元のパラメータである。 α_{ci} は $a^{(t)} = 0$ の時、すなわち、 c において i の有用度を正しく把握できない場合に、 i を実施する確率を表す。また、 $\lambda_\gamma, \lambda_\beta, \lambda_y$ は ExpoMF の定義に従うハイパーパラメータであり、それぞれ γ, β, y の分散の逆数を表す。

有用度 r_{ci} は、 $a^{(t)} = 1$ の時の、 $y^{(t)}$ の生成分布の平均値とし、 c と i によって以下のように表せる。

$$r_{ci} = \gamma_c^\top \beta_i \quad (3)$$

コンテキストごとに、有用度と顕在化難易度がともに高い行動（操作）が推薦すべき対象である。

提案モデルと ExpoMF のグラフィカルモデルの比較を図 1 に示す。ここで、 N_u, N_c, N_i はそれぞれ、ユーザ、コンテキ

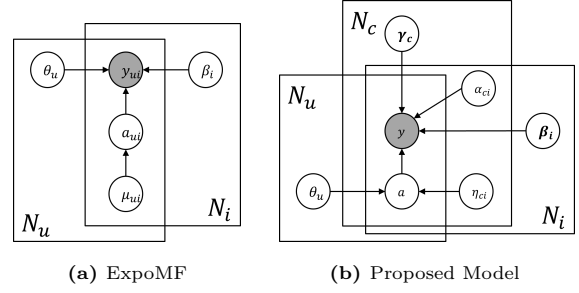


図 1: ExpoMF と提案モデルの比較

スト、アイテム（操作）の数を表し、色付きのノードは観測可能であることを表す。

4.3 パラメータの推定

操作履歴 D について、顕在化変数 $a^{(t)}$ を未観測変数とし、EM アルゴリズム [8, 9] により、 $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ を推定する。簡単のため、 α_{ci} は c, i に関わらず一定とし、ハイパーパラメータ α として与えることとする。

u, c, i および a, y が既知の場合の、推定パラメータの対数尤度関数は式 (4) で表される。

$$\begin{aligned}\log p(a, y | u, c, i, \gamma_c, \beta_i, \theta_u, \eta_{ci}) \\ = \log p(a | u, c, i, \theta_u, \eta_{ci}) + \log p(y | a, c, i, \gamma_c, \beta_i)\end{aligned}\quad (4)$$

ここで $p(a | u, c, i, \theta_u, \eta_{ci})$, $p(y | a, c, i, \gamma_c, \beta_i)$ は、式 (2) より以下となる。

$$\begin{aligned}p(a | u, c, i, \theta_u, \eta_{ci}) &= \begin{cases} \frac{\eta_{ci}}{\theta_u + \eta_{ci}} & (a = 0) \\ \frac{\theta_u}{\theta_u + \eta_{ci}} & (a = 1) \end{cases} \\ p(y | a, c, i, \gamma_c, \beta_i) &= \begin{cases} \sqrt{\frac{\lambda_y}{2\pi}} \exp(-\frac{1}{2} \lambda_y (1 - \gamma_c^\top \beta_i)^2) & (a = 1, y = 1) \\ \sqrt{\frac{\lambda_y}{2\pi}} \exp(-\frac{1}{2} \lambda_y (\gamma_c^\top \beta_i)^2) & (a = 1, y = 0) \\ \alpha & (a = 0, y = 1) \\ 1 - \alpha & (a = 0, y = 0) \end{cases}\end{aligned}\quad (5)$$

EM アルゴリズム [8, 9] では、 $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ の値を初期化し、E-STEP と M-STEP を繰り返すことにより $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ を更新する。

E-STEP

E-STEP では、式 (6) を用いて、前ステップで求めた $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ を用いて、観測された各 (u, c, i, y) に対する顕在化変数 $a = 1$ の確率 q_{uciy} を求める。

$$\begin{aligned}q_{uciy} &= p(a = 1 | y, u, c, i, \gamma_c, \beta_i, \theta_u, \eta_{ci}) \\ &= \frac{p(a = 1 | u, c, i, \theta_u, \eta_{ci}) p(y | a = 1, y, c, i, \gamma_c, \beta_i)}{\sum_{a \in \{0, 1\}} p(a | u, c, i, \theta_u, \eta_{ci}) p(y | a, y, c, i, \gamma_c, \beta_i)}\end{aligned}\quad (6)$$

M-STEP

E-STEP で求めた q_{uciy} を用いて、式 (4) で示される尤度関数の期待値が最大となる $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ を計算する。

Algorithm 1 Proposed Method

Input: D
Output: $\gamma_c, \beta_i, \theta_u, \eta_{ci}$

```

1:  $n_{uci} \leftarrow$  (count records of each combination  $(u, c, i)$  in  $D$ )
2:  $n_{uciy} \leftarrow$  (count records of each combination  $(u, c, i, y)$  in  $D$ )
3:  $\gamma_c, \beta_i, \theta_u, \eta_{ci} \leftarrow$  (initialization)
4: while not converge do
5:    $q_{uciy} \leftarrow$  (calculated from  $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ ), (6)
6:    $\gamma_c \leftarrow$  (calculate from  $q_{uciy}, n_{uciy}, \beta_i$ ), (7)
7:    $\beta_i \leftarrow$  (calculate from  $q_{uciy}, n_{uciy}, \gamma_c$ ), (8)
8:    $\hat{\theta}_u, \hat{\eta}_{ci} \leftarrow \theta_u, \eta_{ci}$ 
9:   while not converge do
10:     $\tilde{\theta}_u, \tilde{\eta}_{ci} \leftarrow$  (calculate from  $n_{uci}, n_{uciy}, q_{uciy}, \hat{\theta}_u, \hat{\eta}_{ci}$ ), (9)
11:     $\hat{\theta}_u, \hat{\eta}_{ci} \leftarrow$  (calculate from  $\tilde{\theta}_u, \tilde{\eta}_{ci}$ ), (10)
12:   end while
13:    $\theta_u, \eta_{ci} \leftarrow \hat{\theta}_u, \hat{\eta}_{ci}$ 
14: end while

```

γ_c, β_i と θ_u, η_{ci} はそれぞれ別に求めることができる。 γ_c, β_i については ExpoMF と同様に、式 (7), 式 (8) で更新できる。ここで、 n_{uciy} は観測データ D 内で同じ u, c, i, y の組み合わせを観測した回数であり、 \mathbf{I}_K は K 次元の単位行列である。

$$\gamma_c \leftarrow (\lambda_y \sum_{u,i,y} n_{uciy} q_{uciy} \beta_i \beta_i^\top + \lambda_\gamma \mathbf{I}_K)^{-1} (\sum_{u,i,y} \lambda_y n_{uciy} q_{uciy} y \beta_i) \quad (7)$$

$$\beta_i \leftarrow (\lambda_y \sum_{u,c,y} n_{uciy} q_{uciy} \gamma_c \gamma_c^\top + \lambda_\beta \mathbf{I}_K)^{-1} (\sum_{u,c,y} \lambda_y n_{uciy} q_{uciy} y \gamma_c) \quad (8)$$

θ_u, η_{ci} については Bradley-Terry モデルの解法 [10] に基づき、式 (9), 式 (10) の繰り返し計算により求める。 $\hat{\theta}_u, \hat{\eta}_{ci}$ を初期化後、式 (9), 式 (10) により、収束するまで更新を繰り返す。

$$\begin{cases} \tilde{\theta}_u \leftarrow \frac{\sum_{c,i,y} n_{uciy} q_{uciy}}{\sum_{c,i} \frac{n_{uci}}{\hat{\theta}_u + \hat{\eta}_{ci}}} \\ \tilde{\eta}_{ci} \leftarrow \frac{\sum_{u,y} n_{uciy} (1 - q_{uciy})}{\sum_u \frac{n_{uci}}{\hat{\theta}_u + \hat{\eta}_{ci}}} \end{cases} \quad (9)$$

$$\begin{cases} \hat{\theta}_u \leftarrow N_u \frac{\tilde{\theta}_u}{\sum_u \tilde{\theta}_u} \\ \hat{\eta}_{ci} \leftarrow N_u \frac{\tilde{\eta}_{ci}}{\sum_u \tilde{\theta}_u} \end{cases} \quad (10)$$

ここで、 n_{uci} は、観測データ D 内で、同じ u, c, i をの組み合わせを観測した回数であり、 N_u はデータに含まれる作業者数である。アルゴリズムの概要を Algorithm1 に示す。

上記により、 $\gamma_c, \beta_i, \theta_u, \eta_{ci}$ が推定できる。また、式 (3) により、 γ_c, β_i から有用度 r_{ci} を求めることができる。ここで、有用度 r_{ci} と顕在化難易度 η_{ci} が共に高いアイテム i が、コンテキスト c において推薦すべき有用な操作である。

表 1: 生成する操作履歴 D

| 通し番号 | 作業者番号 | コンテキスト番号 | 操作番号 | 作業者選択 |
|------|-------|----------|------|-------|
| t | u | c | i | y |
| 0 | 9 | 3 | 0 | 0 |
| 1 | 9 | 3 | 1 | 1 |
| 2 | 1 | 2 | 0 | 1 |
| ... | ... | ... | ... | ... |

5 評価実験

本節では、人工データを用いた数値実験により提案手法の有効性を検証する。具体的には、人工データに提案手法を適用して得られるモデルパラメータの推定精度の評価、およびデータに含まれるノウハウの抽出精度の評価を行う。

本実験では、3 節の問題設定を再現するため、所望の動作をする複数の作業者エージェントと動作時の生成パラメータを設計し、作業者エージェントのシミュレーションを通して、抽出すべきノウハウや無駄な操作を含む操作履歴を生成する。そのために、まず複数の仮想的な作業者エージェントとコンテキスト-操作の組を用意する。そして、ノウハウや無駄な操作がデータに一定量含まれるように、作業者エージェントの習熟度およびコンテキスト-操作の顕在化難易度と有用度の設定値を生成する確率分布の生成パラメータの設計を行う。ここで、ノウハウとは顕在化難易度と有用度が相対的に高いコンテキスト-操作の組であり、無駄な操作とはあるコンテキストにおいて有用度が低い操作である。また、作業者エージェントがコンテキストによっては誤った操作を行うように、習熟度を上回る顕在化難易度を有するコンテキスト-操作に対してランダムな選択を行うように作業者エージェントの動作を設計する。

5.1 節に人工データ生成の詳細な手続きを述べる。5.2 節では本稿における数値実験のセットアップについて述べる。そして、5.3 節にて実験で取得したモデルパラメータの推定結果を評価し、5.4 節で設定したノウハウの抽出精度を評価する。

5.1 人工データ生成

はじめに、生成する操作履歴 D について説明する。操作履歴は表 1 に示すテーブルデータで表し、カラムの項目は、通し番号 t , 作業者番号 u , コンテキスト番号 c , 操作番号 i , 作業者選択 y とする。各レコードには、コンテキストと操作の組に対して、作業者がその操作を選択したかどうかを記録する。操作履歴 D は観測可能な情報であり、提案手法への入力データとして使用する。

本実験では、習熟度の異なる作業者の操作を含む操作履歴を再現するために、仮想的な作業者である作業者エージェントを複数生成する。図 2 は作業者エージェントの操作選択フローを示した図である。各作業者エージェントは、固有の習熟度を内部パラメータとして有し、指定されたコンテキストごとに、各々の操作について自己の習熟度とコンテキスト-操作の組の顕在化難易度に基づいて、各操作が顕在化しているかを判定す

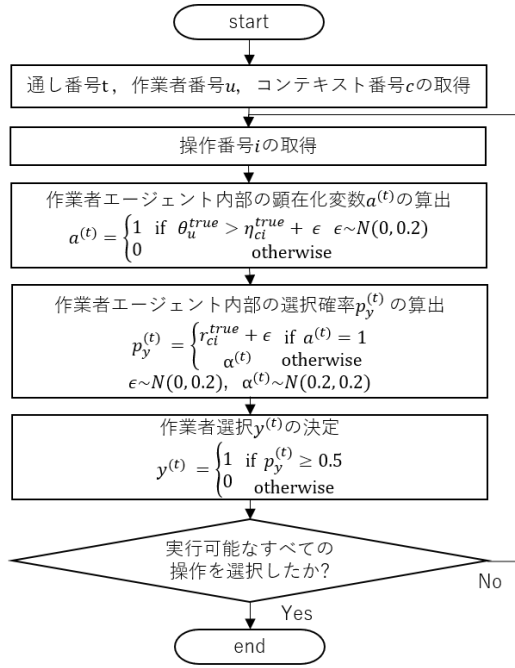


図 2: 作業員エージェントの操作選択フロー

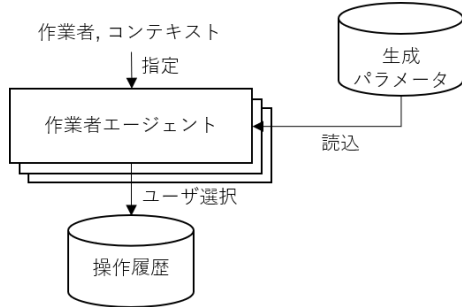


図 3: 操作履歴 D 生成のブロック図

る。そして、顕在化している場合は有用度に基づき操作を選択するかどうかを判定し、顕在化していない場合はランダムな値により操作を選択するかどうかを判定する。これにより、習熟度の低い作業員の誤操作や意味のない操作を再現する。

つぎに、作業員エージェントを用いた操作履歴の生成シミュレーションについて述べる。データ生成のブロック図を図 3 に示す。まず、作業員番号 u とコンテキスト番号 c をランダムに決定する。その後、指定された u に紐づいた作業員エージェントに対してコンテキスト c を入力し、すべての操作 $\{i\}$ に対するユーザ選択 $\{y\}$ を取得し、記録する。これらの過程を事前に指定したトライアル数分繰り返す。

最後に、数値実験で用いる生成パラメータの設計方針について述べる。生成パラメータ設計の目的は、発見すべきノウハウや無駄な操作、作業員エージェントの動作から発生しうる誤操作を一定量含むデータを生成するように調整することである。本実験では以下のように生成パラメータを設計する。

習熟度の設計

様々な習熟度の作業員がいることを想定し、作業員エージェントの習熟度の設定値 θ_u^{true} を下式により生成する。

表 2: c-i カテゴリ

| | $X^{(c)} = A^{(c)}$ | $X^{(c)} = B^{(c)}$ | $X^{(c)} = C^{(c)}$ | $X^{(c)} = D^{(c)}$ | $X^{(c)} = E^{(c)}$ |
|---------------------|---------------------|---------------------|---------------------|---------------------|---------------------|
| $X^{(i)} = A^{(i)}$ | A | B | C | D | E |
| $X^{(i)} = B^{(i)}$ | E | A | B | C | D |
| $X^{(i)} = C^{(i)}$ | D | E | A | B | C |
| $X^{(i)} = D^{(i)}$ | C | D | E | A | B |
| $X^{(i)} = E^{(i)}$ | B | C | D | E | A |

$$\log(\theta_u^{true}) \sim U(-2.0, 2.0) \quad (11)$$

ここで、 $U(\cdot, \cdot)$ は一様分布を表す。ただし、習熟度が $\exp(1.0)$ 以上の作業員エージェントを特に習熟度が高い作業員エージェントとし、その割合を全体の 20% 程度になるように調整した。

顕在化難易度、有用度の設計

つぎに、顕在化難易度および有用度の設定値の生成方法について記す。はじめに、コンテキストと操作について便宜上それぞれ 5 つのカテゴリ $X^{(c)} \in \{A^{(c)}, B^{(c)}, C^{(c)}, D^{(c)}, E^{(c)}\}$, $X^{(i)} \in \{A^{(i)}, B^{(i)}, C^{(i)}, D^{(i)}, E^{(i)}\}$ を設定し、事前にランダムに振り分ける。ここで、右肩の添え字 (c) , (i) はそれぞれコンテキスト、操作のカテゴリであることを表す。つぎに、コンテキストと操作の組に対して表 2 に示す対応表をもとにコンテキスト-操作カテゴリ X_{ci} を決定する (以降、c-i カテゴリと記述)。本実験では c-i カテゴリとして 5 つのカテゴリ $\{A, B, C, D, E\}$ を設け、c-i カテゴリが A に属するコンテキスト-操作の組を発見すべきノウハウとする。また、A 以外の c-i カテゴリを用いて顕在化難易度と有用度の組み合わせにより生じる様々なコンテキスト-操作の組を表現する。この中には、多くの作業員が行う当たり前の操作や習熟度が低い作業員の行う誤った操作が含まれるものとする。

これらを踏まえて、顕在化難易度の設定値 η_{ci}^{true} を式 (12) により、有用度の設定値 r_{ci}^{true} を式 (13) により生成する。c-i カテゴリが A に属する組については、習熟度の高い作業員のみが適切に選択できる高い顕在化難易度かつ高い有用度を設定した。また、A 以外の組については、有用度による推定結果の差異を見るため、有用度の生成パラメータの値を段階的に設定した。

$$\begin{aligned} \log(\eta_{ci}^{true}) &\sim U(1.0, 2.0) \quad (X_{ci} = A) \\ \log(\eta_{ci}^{true}) &\sim U(-2.0, 1.0) \quad (X_{ci} \in \{B, C\}) \\ \log(\eta_{ci}^{true}) &\sim U(-2.0, 2.0) \quad (X_{ci} \in \{D, E\}) \end{aligned} \quad (12)$$

$$\begin{aligned} r_{ci}^{true} &\sim U(0.5, 1.0) \quad (X_{ci} = A) \\ r_{ci}^{true} &\sim U(0.75, 1.0) \quad (X_{ci} = B) \\ r_{ci}^{true} &\sim U(0.5, 0.75) \quad (X_{ci} = C) \\ r_{ci}^{true} &\sim U(0.25, 0.5) \quad (X_{ci} = D) \\ r_{ci}^{true} &\sim U(0.0, 0.25) \quad (X_{ci} = E) \end{aligned} \quad (13)$$

5.2 実験セットアップ

以下に本稿における実験のセットアップを記す。本実験では、作業員数、コンテキスト数、操作数はそれぞれ、100, 50, 50 とした。これらは、様々な作業員やコンテキスト-操作の組を発




図 4: 習熟度の推定結果




図 5: 顕在化難易度の推定結果

生させるために十分かつ特徴ベクトル γ_c , β_i の分解に十分な数であった。操作履歴の記録を取得するトライアルの数は 100,000 とした。モデルの学習にはハイパーパラメータ $K = 3$, $\lambda_\gamma = 0.5$, $\lambda_\beta = 0.5$, $\lambda_y = 0.5$ を使用した。ただし、ハイパーパラメータ α に関しては、ノウハウ抽出精度の評価における値による差異を見るために、 $\alpha \in \{0.01, 0.05, 0.1, 0.2\}$ とした。 α は、モデルにとって顕在化していない操作がどの程度選択されるかの想定、すなわち操作履歴におけるノイズレベルの想定を設定するハイパーパラメータである。 α の値によりノウハウ抽出の特性を調整できることが期待される。また、モデルパラメータ推定精度の評価では、代表的な値として $\alpha = 0.05$ を採用した。モデルパラメータの初期値に関して、 θ_u , γ_c , β_i は一様分布から生成し、 η_{ci} は一定値とした。EM アルゴリズムの収束条件として、確率 q_{uci} の更新前後での差分の二乗平均が閾値 0.001 以下であることを用いた。

5.3 パラメータ推定精度の評価

提案手法による人工データを用いた各種パラメータの推定結果について述べる。以後、取得した推定値はすべて相対値であることに留意する。

はじめに、習熟度の推定結果について述べる。図 4 は、すべての作業エージェントの習熟度の設定値を横軸に、推定値を縦軸にプロットした図である。図より習熟度を精度よく推定で




図 6: 有用度の推定結果

きていることが確認できる。このときの相関は 0.98 であり、量的にも推定精度の良さがわかる。

つぎに、顕在化難易度の推定結果について述べる。図 5 は、すべてのコンテキスト-操作の組について、顕在化難易度の設定値を横軸に、推定値を縦軸にプロットした図である。図より、c-i カテゴリが A, B, C に属する有用度が比較的高いコンテキスト-操作の組は、対角線上にプロットされ、うまく推定されていることがわかる。また、c-i カテゴリが D のプロットも、A などに比べてばらつきはあるものの、多くの点が対角線上にプロットされていることがわかる。一方で、c-i カテゴリが E のプロットについては、比較的高い値に誤って推定されている場合がみられた。この理由については 6 節で述べる。なお、相関は 0.63 であった。

最後に、有用度の推定結果について述べる。有用度の推定値は γ_c , β_i の推定値より算出した。図 6 は、すべてのコンテキスト-操作の組について、有用度の設定値を横軸に、推定値を縦軸にプロットした図である。図より、c-i カテゴリ A の値が全体的に低く推定されているものの、設定値の高いコンテキスト-操作ほど推定値も高く推定されており、全体的にうまく推定されていることがわかる。相関も高く、0.86 であった。

まとめると、パラメータ推定について以下の結果が得られた。

- 習熟度の推定精度は非常に高い
 - 有用度が高い c-i カテゴリ A に属するコンテキスト-操作の組の顕在化難易度はうまく推定されているが、有用度が低い c-i カテゴリ E の一部の顕在化難易度が誤って高く推定されている
 - 有用度は、c-i カテゴリ A の値がやや低いものの、全体的に精度良く推定されている
- 以上の結果を踏まえて、ノウハウである c-i カテゴリ A に属するコンテキスト-操作の組を抽出する。

5.4 ノウハウ抽出精度の評価

作業エージェントの習熟度の推定値およびコンテキスト-操作の組の顕在化難易度と有用度の推定値に基づいてノウハウを抽出し、その精度を評価する。ここで、ノウハウとは顕在化難易度が高く、有用度の高いコンテキスト-操作の組であり、c-i

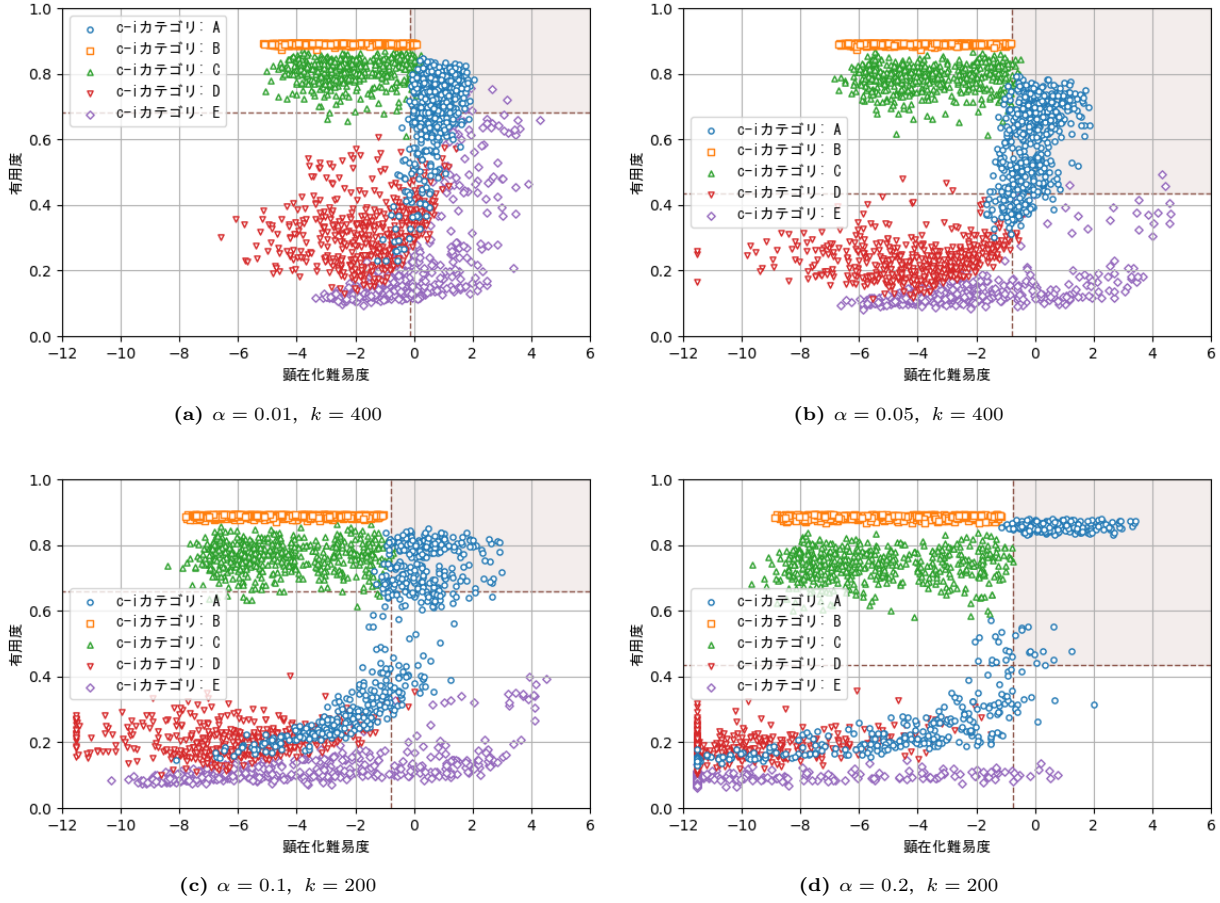


図 7: 顕在化難易度 (推定値) - 有用度 (推定値)

カテゴリが A に属するものである．ノウハウの抽出方法として，教師データがある場合は分類問題として定式化したり，クラスタリングによる教師なし学習を行うことが考えられるが，本実験では 5.3 節で得られたパラメータの推定結果に基づいて以下のようにノウハウを抽出した．

ノウハウ抽出方法

STEP.1 習熟度 (推定値) の高い上位 20% を分離する値を顕在化難易度の閾値とする

STEP.2 閾値以上の顕在化難易度 (推定値) を有するコンテキスト-操作の組の集合 P から有用度 (推定値) の高い上位 k 個の組をノウハウと予測する

この処理の意図は，c-i カテゴリ A および E のみ値が高く推定されていた顕在化難易度にフィルタをかけてノウハウの候補を決めた後に，その中でも有用度が高い c-i カテゴリ A のみをノウハウとして抽出することである．

ノウハウの抽出精度の評価指標として，以下を定義する．

$$\text{Precision@}k = \sum_{\{c,i\} \in P} \frac{\mathbb{1}(\text{rank}_P(r_{ci}) \leq k) \mathbb{1}(X_{ci} = A)}{k} \quad (14)$$

$$\text{Recall@}k = \sum_{\{c,i\} \in P} \frac{\mathbb{1}(\text{rank}_P(r_{ci}) \leq k) \mathbb{1}(X_{ci} = A)}{N_{|A|}} \quad (15)$$

ただし， $\mathbb{1}()$ は指示関数であり， $\text{rank}_P()$ は集合 P における昇順のランキング関数である．また， $N_{|A|}$ は c-i カテゴリ A に

表 3: ノウハウ抽出精度 (Precision@ k /Recall@ k)

| | $k = 100$ | $k = 200$ | $k = 300$ | $k = 400$ | $k = 500$ | $k = 600$ |
|-----------------|-----------|-----------|-----------|-----------|-----------|-----------|
| $\alpha = 0.01$ | 0.58/0.11 | 0.75/0.29 | 0.81/0.47 | 0.84/0.66 | 0.83/0.81 | 0.77/0.90 |
| $\alpha = 0.05$ | 0.87/0.17 | 0.94/0.36 | 0.96/0.56 | 0.96/0.75 | 0.85/0.82 | - |
| $\alpha = 0.1$ | 0.97/0.19 | 0.99/0.38 | 0.91/0.53 | - | - | - |
| $\alpha = 0.2$ | 1.00/0.19 | 1.00/0.39 | - | - | - | - |

属するコンテキスト-操作の数である．Precision@ k は c-i カテゴリ A と予測したもののうち実際に c-i カテゴリ A であった割合であり，Recall@ k は実際に c-i カテゴリ A であるもののうち，c-i カテゴリ A と予測された割合である．

これより，ノウハウの抽出結果を表 3 および図 7 に示す．表 3 はハイパーパラメータ α と抽出するコンテキスト-操作の数 k を変化させたときの Precision@ k および Recall@ k の値である．ただし，集合 P に属する要素の数が k に満たない場合は「-」と表記した．また，図 7 は α を 0.01, 0.05, 0.1, 0.2 としたときの結果であり，横軸は顕在化難易度の推定値，縦軸は有用度の推定値である．縦の破線は顕在化難易度の閾値を表し，横の破線は集合 P において上位 k 個を分離する線である．よって，網掛けの領域に含まれる点が c-i カテゴリ A と予測されたコンテキスト-操作の組となる．なお，各図の k は表 3 の Precision@ k が高いときの値を用いた．表 3 より， α が大きいほど，Precision@ k が大きくなるが，Recall@ k が低い値で頭打

ちになることがわかる。これは、図7より、集合 P に含まれるノウハウの数が少なくなっているためであるといえる。 k を大きくすると、Precision@ k , Recall@ k ともに大きくなるが、 k を大きくとりすぎると Precision@ k は逆に下がってしまう傾向が見られた。これは、 k を大きくすると c-i カテゴリ E が予測値に混入するためであることが、図7よりわかる。

6 考察

一般の推薦問題では、有用度のみを問題としており、例えば本手法で有用度のみを考慮した場合には、図6からもわかるように、c-i カテゴリ A のアイテム（操作）は有用度が低く推定され、推薦されるアイテムの多くは c-i カテゴリが B, C のアイテム、すなわち、推薦されなくても作業者が選ぶアイテムとなる。本当に推薦したい c-i カテゴリ A のアイテムは、顕在化難易度が高く、実際の操作履歴の中で選択されないケースが多い。そのため、有用性を判断する材料が不十分であり、有用度が低めに見積もられていると考えられる。提案手法では、顕在化難易度を同時に推定することにより、表3に示すように、高い精度で c-i カテゴリ A, すなわち、有用度と顕在化難易度が高いアイテムが抽出可能であることが示された。作業者の行動変容や成長を促すという目的においては、作業者にとって未知で有用なアイテムを推薦することが重要であり、本研究の問題設定においては提案手法により行動変容につながる重要なノウハウを抽出できたと考える。実際に推薦に活用する場合には、各作業者の推定された習熟度に合わせて、例えば習熟度より顕在化難易度が高いアイテムのみを推薦対象にすることにより、行動変容につながる支援が可能であると考えられる。

c-i カテゴリ A のアイテムの有用度が低く推定されるケースのほかに、c-i カテゴリ E のアイテムの有用度が高く見積もられるケースがある。例えば、図7(a)では、右上の領域に有用度が低いはずの c-i カテゴリ E のアイテムが多く分布している。どちらのケースも、選択される頻度が低いアイテムが、有用度が低いためであるか、顕在化難易度が高いためであるかを判断することが難しい事が原因となっている。図7からわかるように、 α の値によって高難易度に判断されやすいか、低有用度に判断されやすいかを制御することができる。抽出した結果を時間をかけてスクリーニングする用途の場合は α を低い値することにより、もれなくノウハウを抽出することが可能である。また、抽出したノウハウを機械的に推薦する場合には α を高めに設定し、確度の高い情報のみを推薦するなどの運用が考えられる。

本研究では3節で示した仮説に基づき生成した人工データにより手法の検証を行っているが、実際の操作履歴が同様の特性を持つかどうかを検証することは今後の課題である。しかしながら、選択頻度が少ないにも関わらず該当の操作が抽出したい操作かどうかは、操作履歴から陽には判断できないため、実際に収集した操作履歴において本手法を定量的に評価することは容易ではない。ユーザ評価などを通して本手法の価値を検証する必要があると考える。また、実データに適用するにあたり、

提案モデルでは単純化していいたいくつかの点に関しては再度検討が必要であろう。

習熟度の多次元化 提案モデルでは、習熟度をスカラー値としているが、特定のコンテキストにのみ習熟しているなど、多様な習熟のパターンが存在しうる

顕在化されていない操作の選択モデルの詳細化 提案手法では、顕在化されていない操作が取られる確率は一定であると単純化したが、実際には、習熟度が低い作業者が間違えやすい操作などが存在し、一定ではない

推薦アイテムの抽出方法 本稿では単純な閾値により、顕在化難易度と有用度が高いアイテムを抽出したが、データの特性によりこれらは調整する必要がある

7 まとめ

本稿では、操作履歴に基づく、作業状況に応じた支援を目的としたツールの操作推薦のシステムにおいて、習熟度による行動の違いを考慮した推薦モデルを提案した。また、有用度と顕在化難易度を推定することにより、推薦すべき有用なノウハウを抽出可能であることを人工データにより示した。

本研究の最終目的は、作業者の合理的な行動変容や早期の成長を促す支援を行い、全体の生産性を高めることである。そのため将来的には、作業者の成長モデルを考慮し、成長を最大化するような支援方法や、ツールの操作履歴にとどまらず、ウェアラブルデバイスなど、様々なセンサから獲得できる作業者の振る舞いの履歴を活用した支援方法の検討を行う予定である。

文 献

- [1] 森崎修司, 門田暁人, 松本健一, 井上克郎, 鳥居宏次. 機能実行履歴を用いたソフトウェア利用知識の共有. 情報処理学会論文誌 41.10 : 2770-2781, 2000.
- [2] Naoki Ohsugi, Akito Monden and Ken-ichi Matsumoto. A recommendation system for software function discovery. Ninth Asia-Pacific Software Engineering Conference, 2002.
- [3] 大杉直樹, 門田暁人, 森崎修司, 松本健一. 協調フィルタリングに基づくソフトウェア機能推薦システム. 情報処理学会論文誌 45.1 : 267-278, 2004.
- [4] Frank McCarey, Mel Ó. Cinnéide, and Nicholas Kushmerick. Rascal: A recommender agent for agile reuse. Artificial Intelligence Review 24.3-4, 253-276, 2005.
- [5] Xiaoyuan Su, and Taghi M. Khoshgoftaar. A survey of collaborative filtering techniques. Advances in artificial intelligence, 2009.
- [6] Yifan Hu, Yehuda Koren, and Chris Volinsky. Collaborative filtering for implicit feedback datasets. 2008 Eighth IEEE International Conference on Data Mining. Ieee, 2008.
- [7] Dawen Liang, Laurent Charlin, James McInerney and David M. Blei. Modeling user exposure in recommendation. Proceedings of the 25th international conference on World Wide Web, 2016.
- [8] Arthur P. Dempster, Nan M. Laird, and Donald B. Rubin. Maximum likelihood from incomplete data via the EM algorithm. Journal of the Royal Statistical Society: Series B (Methodological) 39.1 : 1-22, 1977.
- [9] 上田 修功. 汎用学習手法 -EM アルゴリズム-. 計測と制御, 44巻, 5号, p. 333-338, 2005.
- [10] David R. Hunter. MM algorithms for generalized Bradley-Terry models. The annals of statistics 32.1 : 384-406, 2004.