

統計的特徴量に基づくフェイクレビュー検出

黒木 亮人[†] QU LIJING[†] 成 凱[†]

[†]九州産業大学 〒813-8503 福岡県福岡市東区 2-3-1

E-mail: [†] chengk@is.kyusan-u.ac.jp

あらまし インターネットを介して商品を購入する際に、実際に商品を手にとってみることはできないため他の購入者の口コミであるレビューを参考にすることが多い。しかしレビューの中にはフェイクレビューが存在し、製品やサービスを販売する企業が物品や金銭を見返りにして実際には商品を購入していないレビューアを募り偽のレビューを書かせている。レビューというものは個人が主観に基づいて書くことが多いため、レビューテキストからそのレビューが本物であるかどうかということを見分けるのが非常に難しい。本研究では、「他の大多数のレビューとは異なる振る舞いを持つレビュー」をフェイクレビューと考え、異常検出を用いたフェイクレビュー検出を試みる。また、異常検出を行う際に使用する特徴量として基本的統計量を検討し、それぞれ有効性の比較を行う。

キーワード 偽情報、情報の信憑性、フェイクレビュー、特徴量抽出、異常検出

1. はじめに

近年、インターネットの発展により EC サイトなどのインターネットを介した商品の購入の需要が増加している。しかし、この場合商品を実際に手に取ってみることはできないため他の購入者の口コミであるレビューを商品購入の参考にすることが多い。Goo リサーチが行った調査[11]によると、日本国内 15 歳以上の男女（計 2,107 名）を対象に行った「購買行動においてクチコミが与える影響」について調査し、商品やサービスを購入・選定する際に全体の約 17%がクチコミに非常に気になる、約 64%がやや気になる」と回答した。すなわち 81.6%が商品の購入・選定の際にレビューを参考にすることがわかる。

しかしレビューの中には「フェイクレビュー」という偽のレビューが存在する。フェイクレビューは通常、製品やサービスを販売する企業が物品や金銭を見返りにしてソーシャルメディアなどで実際には商品を購入していないレビューアを募り偽のレビューを書かせている。また、Amazon などの EC サイトでは、実際に購入した人間に対して見返りを用意し最高評価のレビューを書くことを依頼する事例もある。フェイクレビューは主に自社の商品の評価を上げる、または他社の商品の評価を下げることでその企業が利益を増大させることを目的としている。フェイクレビューの存在によって、商品に対する正当な評価が失われる、WEB サイトの信頼性が失われるなどの影響があり、この影響が長期的に続くことにより健全なデジタル社会の実現に悪影響を及ぼす可能性がある。よって、フェイクレビューの対策を行う必要がある。

これまでの研究ではテキスト解析による特徴量を使用したフェイクレビュー検出に関する研究が多かった[1][4][7]。テキスト解析から効果的な特徴量を作成するためには大きな計算資源を要する[7]。そのため、

テキストよりもその他のレビューに付随する情報からフェイクレビュー検出のための特徴量を作成することが必要である。

本研究では「他の大多数のレビューとは異なる振る舞いを持つレビュー」をフェイクレビューとして考える。この考えから異常検出という手法でフェイクレビューを検出する。また、異常検出を行う際に使用する特徴量について基本的な統計に関するものから検討し、それぞれ比較を行う。

2. フェイクレビュー対策

フェイクレビューは偽情報の一種であるため、偽情報対策の一部としてフェイクレビュー対策を考えることができる。偽情報とは意図的に広められる虚偽もしくはは不正確な情報である。英語では Disinformation といい、欧州委員会が 2018 年に公表した EU Code of Practice on Disinformation という文書[10]において、検証により虚偽である又は誤解を誘発する情報と証明可能であり、経済的利益又は意図的に公衆を欺くことを目的として作成、提示及び頒布され、公衆の利益を害する恐れがあるものと定義されている。

偽情報による影響は情報の出どころによって度合いが異なる[12]。主にうわさ系、マスメディア系、行政系に分類される。うわさ系とは「巷の人から人へと伝わっていく、事実の裏付けのない情報」であり、デマや流言などがこれにあたる。マスメディア系とはマスメディアによる偽情報を含む報道、行政系とは政府や自治体など行政機関による誤情報を含む発表である。社会に対する影響としては行政系、マスメディア系、うわさ系の順で影響が大きい。行政系は世論誘導などの重大な市民に対する背信行為を含むので特に影響が強い。マスメディアは「第 4 の権力」とも言われており市民の多くが情報源として使用しているため影響が

大きい。

フェイクレビューは偽のレビューの一つであるが偽のレビュー全てがフェイクレビューというわけではない。偽のレビューにはその商品・サービスと全く関連性のない意見を書いたり、他の商品の宣伝をしたりなど人間が読めばすぐに偽のレビューだとわかる種類のものもある。しかし、フェイクレビューは他のユーザの意見を誘導し企業に利益をもたらすために書かれているため巧妙な文章となっていることが多く、人間が読んでもそれがフェイクレビューだとわからないようになっている。

また、意見を操作するスパマーを特定するに様々な特徴が使える。例えば、異なる商品において同様の内容のレビューがあることはスパマーであることが非常に高い特徴である。スパマーはレビュー作成に時間をかけたくないため同じ内容のテキストを使用してレビューを作成する。よって、レビューテキストの類似性はスパマーの検出に大きく貢献する。

レビューアは商品評価値の最高点と最低点である 1 点と 5 点でレビューを投稿することで製品の平均評価値を意図的に操作できる。このような行動はスポンサーとなる企業側の利益に貢献しやすいためスパマーに多い行動となる。

一部のレビューアは同じコンピュータを使用してある商品のレビューを複数投稿することがある。この行動は非常に疑わしくスパマーである可能性の高い特徴となる。特定のブランドに対し、同じレビューアが複数のレビューを投稿しているとき、そのレビューが一様に高評価、もしくは低評価である場合にそのレビューアはスパマーである可能性が高くなる。レビュー対象によってはレビューが投稿された場所も重要となる。ホテルのレビューが近いそのホテルから近い場所から投稿された場合そのレビューの信憑性は低くなる。

3. レビューデータ

さまざまな EC サイトや口コミサイトが Kaggle などのサイトを通じて、または企業サイトで直接レビューデータを格納したデータセットを提供している。それぞれレビューデータセットでデータ項目は異なる。製品の ID、レビューの有用性評価、製品の評価、レビュータイトル、レビューのテキスト、レビュー投稿時間、レビューアID、レビューア名といった香も奥は共通して存在するが、さまざまな商品についてのレビューをまとめたデータセットでは商品についての情報があるが、一つのジャンルのみのレビューをまとめたデータセットにはその情報は存在しない。

3.1. レビューデータの統計的特徴量

レビューデータセットから統計的特徴量を抽出し

フェイクレビュー検出に利用する。統計的特徴量とは各値の平均、偏差、分散、中央値、またレビューの投稿件数といった統計値を算出する。

平均とは、データの中心位置を示す値である。平均についてあるレビューアの商品評価点の平均がユーザ全体に比べて極端な場合、そのレビューアがスパマーである可能性は高いと考えられる。

分散とは、「データの平均値に対してのばらつき」である。分散の平方根をとることで偏差となる。

商品評価値の偏差、分散がレビューア全体の平均より高い場合そのレビューアは高い評価と低い評価のレビューのどちらも投稿している。その場合そのレビューアはフェイクレビューである可能性が高いと考えられる。しかし、偏差はその計算の性質上、レビュー投稿件数が 1 件のレビューアについては計算することができない欠点がある。

中央値とは、ある数の集合の丁度真ん中に位置する数のことで、数の集合が {1,2,3,4,5} であれば 3 を取る。しかし、あるレビューアの商品評価値の中央値が 5 や 1 の場合そのレビューアは極端な評価値のレビューのみを投稿しているということが平均値よりも明確にみえる。平均の場合、商品評価値が 1 と 5 の商品 2 件のみを投稿している場合平均は 3 となり、一見平均的なレビューアのようにみえてしまう。中央値の場合はこの平均の欠点を克服することができる。反面、中央値の場合ある程度の投稿件数があるレビューアの傾向は正確に見ることができるが、レビュー投稿件数が少ないレビューアについて傾向を見ることが難しい。これは投稿件数が 1 件の場合中央値はその 1 件の商品評価値そのままとなるためである。

レビュー投稿件数はレビューアの行動の重要な指標である。レビューの投稿件数は 2.4.2 で述べた通り、スパマーは通常のレビューアよりもレビュー投稿件数が多い。そのため、レビュー投稿件数が多いレビューアよりも多い場合、スパマーである可能性が高くなる。

これらの特徴量の傾向として、複数以上のレビュー投稿件数があるレビューアについては把握することができると考えられるが、投稿件数が 1 件のみのレビューアについて把握することが難しいという欠点がある。

3.2. 統計的特徴量の抽出

レビューデータセットから統計的特徴量の抽出を行った。今回はレビューの商品評価値に関して商品ごとまたはユーザごとの平均、偏差、中央値、またレビュー投稿件数、またレビューテキストの長さの平均、偏差を算出した。

3.2.1. 使用レビューデータセット

今回、Yelp Labelled Review Dataset with Sentiments

and Features というデータセットを対象に抽出実験を行った。口コミサイト Yelp が公開している 2011 年 3 月 11 日から 2014 年 8 月 31 日までのホテルとレストランのレビュー 355,210 件をまとめたデータセット。以下の項目が含まれている。

User_id - レビューアーの ID

Product_id - 商品の ID

Rating - 商品評価値

Date - レビュー投稿日時

Review - レビューテキスト

Spam(1) and Not Spam(0) - Yelp が独自のアルゴリズムでフィルタリングした結果であり，フェイクレビューなら 1，そうでないなら 0

Sentiment - レビューテキストについて Yelp の感情分析結果，肯定的なレビューなら Positive，否定的な

レビューなら Negative

Features - レビューテキスト内の特徴的な単語

Length - レビューテキストの長さ

3.2.2. 結果と考察

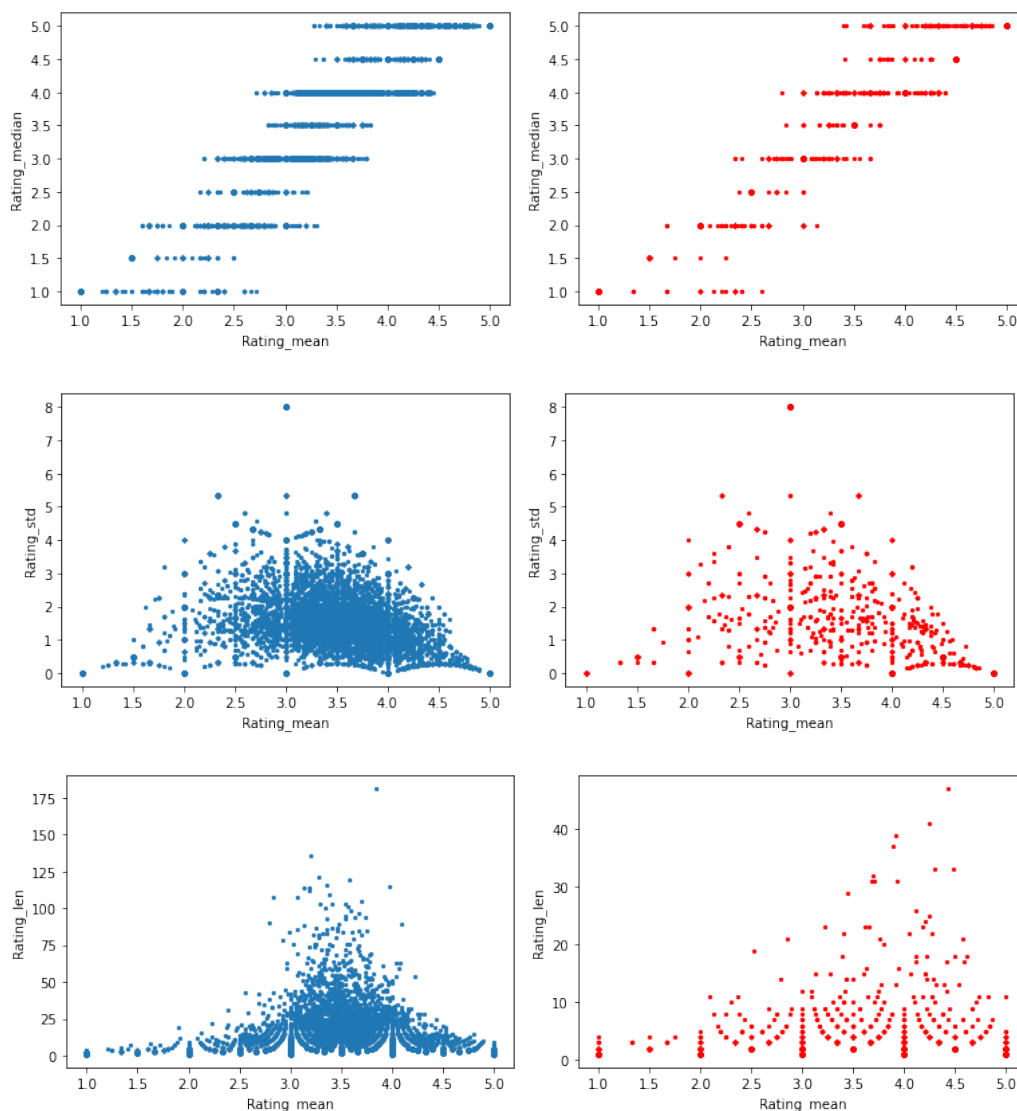
ユーザごと，商品ごとのレビュー投稿件数と商品評価値の平均，偏差，分散，偏差，中央値，ユーザごとのレビューテキストの長さの平均，偏差を算出し，横軸を商品評価値の平均をとりそれ以外を縦軸にとった散布図を示す。各散布図の縦軸・横軸は商品/ユーザごとの以下の統計量を使っている。

Rating_mean：評価値の平均

Rating_std：評価値の偏差地

Rating_len：レビュー投稿件数

Length_mean: レビューテキスト長さの平均値

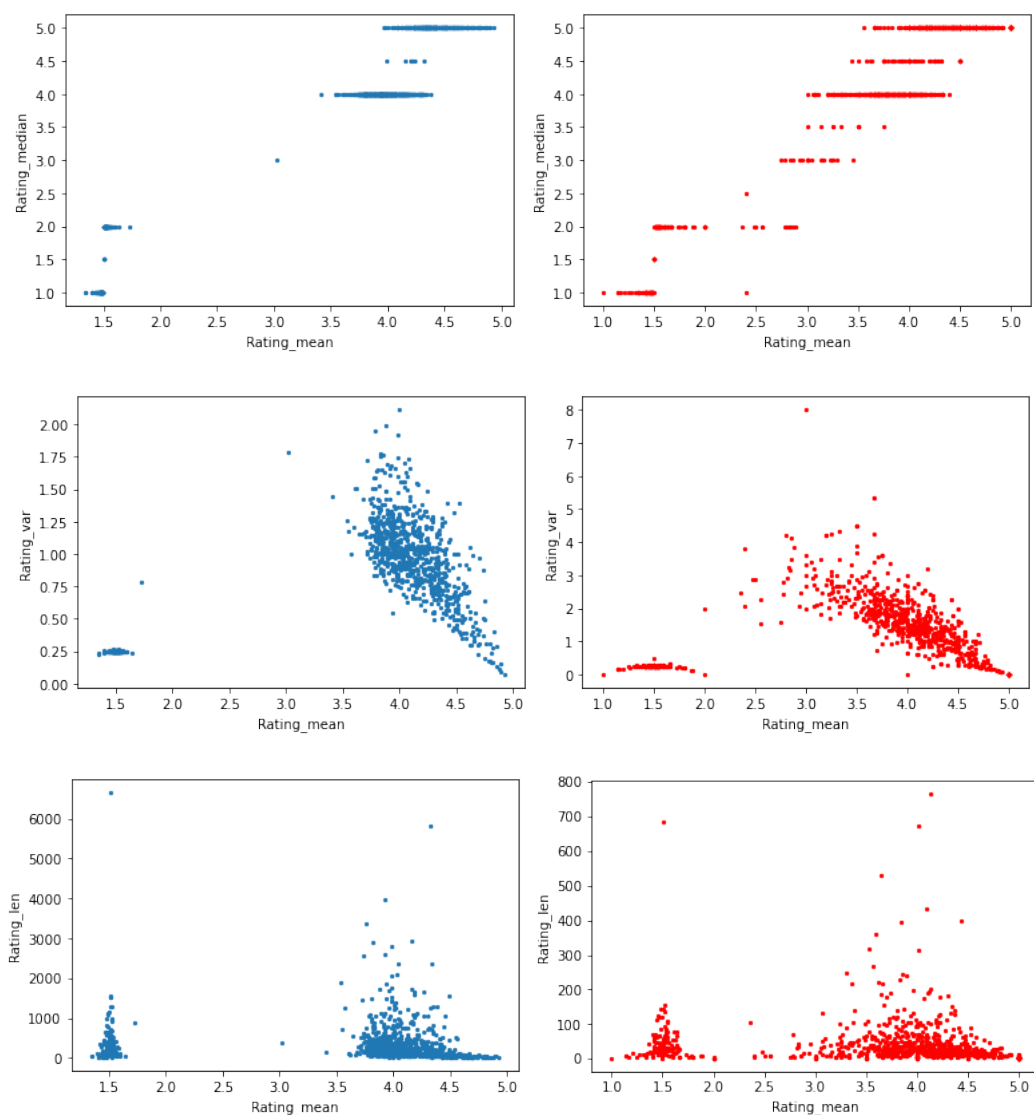


1 ユーザごとの統計量散布図（青：正常；赤：スパム）

図 1 よりフェイクレビューと非フェイクレビュー間で最も異なるのはユーザごとの投稿件数である。これは、スパマーの行動的特徴としてある程度多くのレビューを投稿する特徴と矛盾する。しかし、これはYelpによるフィルタリングではレビュー件数をあまり重要視していないということが考えられる。また、他の平均、分散、偏差にあまり大きな違いが見られず、フェイクレビュー、非フェイクレビューともにある程度高い評価をするユーザが多い。スパマーの行動的特徴として極端な評価の投稿が多いことと矛盾するかに見えるが、そもそも多くの通常のレビューアーの心理としてレビューを投稿されやすい商品というのは良い商品もしくは悪い商品に対してであり、無難な商品について

のレビューを投稿することが少ないのではないかと考えられる。

図 2 より商品ごとの偏差についてフェイクレビューの偏差、つまりばらつきが大きいことわかる。このことからスパマーは1と5や1と4などの高評価のレビューと低評価のレビューのどちらも行う人間が多いと考えられる。また、中央値を見ると高評価の分布にはあまり差がないが、3以下の分布に違いがある。また、図 3.6 の各散布図とも平均値が高いか低い商品が多い。これは前述した多くの通常のレビューアーの心理と合致し、通常のレビューアーは高評価をすることが多いことがわかる。フェイクレビューでは高評価も多いが、通常のレビューよりも低評価が多い。



2 商品ごとの統計量散布図（青：正常；赤：スパム）

さらに、商品、ユーザごとに、フェイクレビューと非フェイクレビューの割合で、商品とユーザの信頼度を評価している。ユーザごとにフェイクレビューの割合が10%以上、商品ごとのフェイクレビューの割合が15%以上であるとき、 $Fake=1$ と判定し、そうでなければ、 $Fake=0$ と判定する。図3と図4はそれぞれユーザごとと商品ごとの各種統計量の散布図を示している。

図3 ユーザごとの各散布図よりも分布が異なる原因としてレビュー対象が大きく異なるもの（施設と書籍）であることが考えられる。このことから訓練データセットと教師データセットを異なるレビュー対象のデータセットにするという場合にはまずデータセットの分析を詳細に行い使用する特徴量について考察する必要があるといえる。




図3 ユーザごとの統計量の散布図

図4より商品ごとの偏差についてフェイクレビューの偏差、つまりばらつきが大きいことわかる。このことからスパマーは1と5や1と4などの高評価のレビューと低評価のレビューのどちらも行う人間が多いと考えられる。また、中央値を見ると高評価の分布にはあまり差がないが、3以下の分布に違いがある。また、各散布図とも平均値が高いか低い商品が多い。これは前述した多くの通常のレビュアーの心理と合致し、通常のレビュアーは高評価をすることが多いことがわかる。フェイクレビューでは高評価も多いが、通常のレビューよりも低評価が多いことがわかる。




図4 商品ごとの統計量の散布図

横軸評価平均、縦軸レビューテキストの平均長さではレビューテキストについては偏差が大きな意味を持つ。これは、スパマーがレビューを複数生産する場合にコピーをする可能性があり、そのようなスパマーは偏差が小さくなる。この図からもスパマーの方がレビューテキストについて平均、偏差ともに小さいことがわかる。

4. フェイクレビュー対策のための異常検出

4.1. 異常検出手法

異常検出手法の手法は統計モデルに基づくものとデータ間の距離に基づくものがある。それぞれの代表的な手法について説明する。

ホテリングの理論ではデータの分布を正規分布として仮定する。正規分布の母平均を μ 、母標準偏差を σ とすると観測データ x は以下の確率密度分布に従って出現すると考える。

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

μ と σ は正規分布の母数であり、直接観測できない量ですが、観測値が $\{x_1, x_2, \dots, x_n\}$ と与えられた時、データの標本平均 m 、標本標準偏差 s で推定できることが知られている。今、異常値を含まなか含んでいたとしても μ 、 σ の推定には影響を無視できるほど少数しか含んでいない観測データ $\{x_1, x_2, \dots, x_n\}$ から m 、 s が得られているとする。新しい観測データ x' が得られた時 x' の異常度 $a(x')$ を以下のように定義する。

$$\begin{aligned} a(x') &= -\log p(x'|m, s^2) \\ &= -\log \frac{1}{\sqrt{2\pi s^2}} \exp\left(-\frac{(x'-m)^2}{2s^2}\right) \\ &= \frac{(x'-m)^2}{2s^2} + \text{定数} \end{aligned}$$

右辺を 2 倍して x' に関係しない項を削除したものを新たに $a(x')$ とおくことで、異常度 $a(x')$ は以下のように定義できる。

$$a(x') = \frac{(x'-m)^2}{s^2}$$

ホテリング理論の要はこうして定義した $a(x')$ はデータ数 n が十分に大きい時、自由度 1 のカイ二乗分布に従うことが数学的に証明できるということある。

・ Isolation Forest

Isolation Forest は Fei Tony Liu らが提案したモデルであり Random Forest と同じくアンサンブル学習の一つである。アンサンブル学習とは複数の機械学習モデルを組み合わせることでより強力なモデルを構築する手法である。入力したデータ点の集合を決定木で分割していき、特徴量をランダムに選び特徴量の最大値か

ら最初値の区間で分割点をランダムに選ぶ。分割を繰り返していき、葉にはデータ点が 1 つだけになるように分割していき、ルートノードから葉までの距離が異常スコアを表す。早い段階で外れ値は分割される確率が高いためルートノードから葉までの距離 (Average Path Length) が小さいほど異常スコアが高くなる。

・ k 近傍法(k-means)

ホテリング理論ではデータが正規分布から生成されていると仮定しているため、正常なデータが図 2 のような多数のクラスターからなる場合にはうまく異常値を取り除くことができない。そこで確立分布を明示的には仮定せずに、各店から最も近いデータへの距離を計算することで異常値を検知する手法がよく使われる。これを最近傍法という。最近傍法では、あるデータから最も近くにあるデータ（最近傍点）までの距離がある閾値を超えたらその点は異常値であると判定する。このとき閾値は分析者が何らかの方法であらかじめ決めておく必要がある。

距離の定義にはユークリッド距離が使われることが多いが、マハラノビス距離やマンハッタン距離など任意の距離を用いることもできる。最近傍法では最も近い点までの距離を用いて異常値を判別するが最も近い点の代わりに 2 番目に近い点、3 番目に近い点までの距離を用いることも可能。これらをまとめて k 近傍法という。

・ OCSVM 法

OCSVM (One-Class-SVM) は 1 クラス分類問題を扱うために、Schölkopf らにより提案された手法である。OCSVM はデータ空間において正しいデータを含む領域を推定し、推定された領域内のデータを正常値、領域外のデータを外れ値とみなす教師なし学習アルゴリズムである。

4.2. 異常検出の実験

各データセットに対して外れ値検出によりフェイクレビューの検出を行う。実験環境は特徴量抽出動作環境に準ずる。3.3 で抽出した特徴量に対して異常検出を行い有効な特徴量を検証する。

予測精度の検証を行う際は「正常と異常」が事前にわかっている検証データセットがあることが大前提である。

4.3. 実験結果

アルゴリズムは OCSVM, IsolationForest を使用して、それぞれのアルゴリズムで異常検出実験を行った。特徴量の組合せで異常検出を行い、異常検出に有効な特徴量を検証する。表 1 は評価値平均と評価値分散を用いた異常検出を示している。

表 1 評価値平均と評価値分散を用いた異常検出結果

	OCSVM	IsolationForest
正解率	0.601732	0.61039
異常適合率	0.161616	0.373737
正常適合率	0.931818	0.787879
異常再現率	0.64	0.569231
正常再現率	0.597087	0.626506
異常誤報率	0.36	0.430769
正常誤報率	0.402913	0.373494
異常 F 値	0.258065	0.45122
正常 F 値	0.727811	0.697987

各種組合せによる異常検出の F 値を図 5 に示す．横軸が異常 F 値，縦軸が正常 F 値となっている．それぞれの凡例の見方は実験番号,使用アルゴリズム,使用特徴量となっている．使用特徴量が一つしか明記されていないものは商品評価地の平均も特徴量として使用している．




図 5 商品を対象とする検出実験 F 値散布図

4.4. 考察

図 5 から多くの特徴量とアルゴリズムの組み合わせで正常 F 値が高い．しかし，多くの組み合わせで異常 F 値が低く，0.4 を超える実験結果は存在しない．このことから異常な値を正常な値と誤判定していることが考えられる．つまり，フェイクレビューの特性をうまく掴むことができていない．よって，より適切な特徴量を考察しなければならない．Yelp データセットでの教師データは行動的特徴だけでなくテキスト解析から抽出した特徴量も同時に用いており，これはデータセットにも感情分析や特徴語の項目を持っていることからわかる．このことから今回抽出した評価値からのレビューアーの行動的特徴と，テキスト解析から抽出することのできる特徴を考慮した異常検出モデルを作成することで異常 F 値を改善することができると考えられる．

また，F 値が近い値をとっているが，正常 F 値の高

い結果の中で最も異常 F 値が高いものはユーザごとの評価値の平均と中央値を特徴量とし，アルゴリズムに OCSVM を使用した結果である．

5. 終わりに

本研究では，フェイクレビュー検出において困難である真に正しい教師データの有無によらない，またレビュー内容の主観性による問題によらないフェイクレビュー検出の検証を目的とし，レビューの商品評価値から抽出した特徴量を用いて異常検出を行った．また，異常検出のためのレビューそのものの特性を掴むため 2 つのデータセットの評価値について解析を行った．

解析結果について，Yelp データセットについてのフェイクレビュー，非フェイクレビューについてユーザごとの統計量，商品ごとの統計量について特徴的な差が存在した．ユーザごとの統計量についてはユーザごとのレビュー投稿件数が特に多く差があった．商品ごとの統計量については商品ごとの評価値の偏差に分布の差があった．この偏差の分布の差はフェイクレビューの傾向に合致するものでフェイクレビュー検出に有用であると考えられる．また，レビューテキストの長さにもフェイクレビューと通常のレビュー間に分布の差があることがわかった．

異常検出について，12 種類の特徴量と 3 種類のアルゴリズムを使用して異常検出モデルを作成した．結果，正常 F 値については良い値を示したが異常 F 値については非常に低い値のみしか示されなかった．このことより正常値の検出はうまくいったが異常値の誤検出が多かったことがわかる．これは，実験で評価のため使用した yelp データセットの教師データは行動的特徴だけでなくテキスト解析から導出した特徴量を使用していることでより複雑なフェイクレビュー検出をおこなっていることが原因であると考えられる．

そのため，今回使用した特徴量に加えてテキスト分析から導出することができると考えられる特徴量を使用することでより優れた異常検出モデルを構築することができると予想される．さらに，今回はデータセットの商品評価値の統計量の特徴量として使用することで行動特徴を掴もうとしたが行動特徴を表すことのできる特徴量は今回使用した統計量だけではないことが Mohawesh らの調査論文[4]からもわかる．より柔軟にスパマーの行動特徴を掴むことができない特徴量について検討することが必要である．

謝辞 本研究は令和 3 年度 KSU 基盤研究費による支援を頂いており，ここで謹んで感謝の意を表す．また，発表会で座長やコメンテータの方から大変有益なコメントをいただき，今後の参考になった．

参 考 文 献

- [1] Nitin Jindai, Bing Liu, 2008, Opinion Spam and Analysis, WSDM'08: Proceedings of the 2008 International Conference on Web Search and Data Mining, 219-230
- [2] Liu, Wenqian, et al. A Method for the Detection of Fake Reviews Based on Temporal Features of Reviews and Comments. IEEE Engineering Management Review 47.4 (2019): 67-79.
- [3] Karishma Sharma, Feng Qian, He Jiang, Natali Ruchansky, Ming Zhang, and Yan Liu. 2019. Combating Fake News: A Survey on Identification and Mitigation Techniques. ACM Trans. Intell. Syst. Technol. 10, 3, Article 21 (May 2019), 42 pages DOI: <https://doi.org/10.1145/3305260>
- [4] R. Mohawesh et al, Fake Reviews Detection : A Survey. In IEEE Access. vol.9, pp.65771-65802, 2021. Doi:10.1109 /ACCESS.2021.3075573
- [5] Xinyi Zhou and Reza Zafarani. 2020. A Survey of Fake News: Fundamental Theories, Detection Methods, and Opportunities. ACM Comput. Surv. 53, 5, Article 109 (September 2021), 40 pages. DOI: <https://doi.org/10.1145/3395046>
- [6] Liu, Bing. Sentiment analysis: Mining opinions, sentiments, and emotions. Cambridge university press, 2020.
- [7] Savage, David, et al. Detection of opinion spam based on anomalous rating deviation. Expert Systems with Applications 42.22 (2015): 8650-8657.
- [8] Mukherjee, A., Venkataraman, V., Liu, B., and Glance, N. S. (2013, July). What yelp fake review filter might be doing?. In Icwsm pp. 409-418
- [9] Liu Fei Tony, Kai Ming Ting, and Zhi-Hua Zhou. Isolationforest 2008 eighth IEEE international conference on data mining. IEEE, 2008.
- [10] European Commission, Code of Practice on Disinformation, <https://digital-strategy.ec.europa.eu/en/policies/code-practice-disinformation>
- [11] NTT レゾナンス.”「購買行動におけるクチコミの影響」に関する調査”. NTT コム リサーチ .2012/04/27. <https://research.nttcoms.com/database/data/001436/>(参照 2021/01/08)
- [12] 福永秀彦 著, 2019, 放送研究と調査 2019 年 8 月号 SNS 時代の誤情報・虚偽情報とマスメディアの打ち消し報道, 東京都, NHK 放送文化研究所
- [13] 総務省 総合通信基盤局 電気通信事業部 消費者行政第二課, 2020, 新型コロナウイルス感染症に関する情報流通調査.
- [14] 株式会社三菱総合研究所 デジタル・イノベーション本部, 2019, 諸外国におけるフェイクニュース及び偽情報への対応, プラットフォームサービスに関する研究会 (第 8 回)
- [15] 平内和樹, 倉元昭季, 瀬尾明彦, ”One-Class Support Vector Machine を用いた異常検出手法による作業性の評価”, 2019, 人間工学 Vol.55, No.2
- [16] サクラチェッカー 信頼度・信憑性・仕組み等の FAQ, <https://sakura-checker.jp/article/shinraido/#shikumi>
- [17] 消費者庁, 2020/6/12, 消費者の信頼を確保するための消費者レビューの管理, デジタル・プラット
- フォーム企業が介在する消費者取引における環境整備等に関するプロジェクトチーム
- [18] 井手剛, 杉山将著, 2015, 異常検出と変化検知, 東京都: 講談社
- [19] Albert, 異常検出とは, Basic Knowledge on Data Analysis, https://www.albert2005.co.jp/knowledge/machine_learning/anomaly_detection_basics/anomaly_detection (参照 2021/12/14)
- [20] 曾我部東馬 著 曾我部完 監修, 2021, Python による異常検出, 東京都: オーム社
- [21] ヤン・ジャクリン. Isolation Forest と異常検出 (ネットアクセスログを用いて). GRIBlog. 2020-07-06. <https://griblog.hatenablog.com/entry/2020/07/05/171621>, (2021/6/14)