

主観モデリングのためのリストワイズガウス過程選好学習

蔵内 雄貴[†] 幸島 匡宏[†] 南部 優太[†] 山本 隆二[†]

[†]NTT 人間情報研究所 〒239-0847 神奈川県横須賀市光の丘 1-1

E-mail: [†]{yuuki.kurauchi.mv, yuta.nambu.fs, masahiro.kohjima.ev, ryuji.yamamoto.sv}@hco.ntt.co.jp

あらまし ある人がある事物をどう感じるかなどの個人の主観のモデリングは、パーソナライズされたサービスに必要である。主観モデルの構築には、データ収集とモデル構築を効率的に行うベイズ最適化の枠組みと、ペアワイズ比較データから関数を推定するガウス過程選好学習の併用が有望と考えられる。しかし後者は、ペアワイズ比較データを用いるために学習に必要な比較の回数が多く時間もかかり、被験者の負担が大きい問題があった。そこで本研究では、リストワイズ比較データから関数を推定するガウス過程選好学習を用いる手法を構築した。本手法により一度の比較で複数のデータへの評価が得られ、被験者による比較の回数と時間を減らし負担を軽減できる。表情認知モデルを被験者ごとに構築し最適な表情を得る実験を通じ、提案法が従来手法より少ない被験者の負担でより高精度な表情認知モデルを構築し、より最適な表情を得られることを確認した。

キーワード ベイズ最適化, ガウス過程選好学習, リストワイズガウス過程選好学習, 主観モデリング

1. はじめに

個人のデータを収集する仕組みが作りやすい分野において、パーソナライズが多く用いられている。例えば、閲覧/再生/クリック/購買/評価ログから個人のモデリングを行い、最適な商品/コンテンツ/サービス/広告を提示するパーソナライズが行われている[1]。一方、個人のデータを収集する仕組みが作りにくい分野においては、パーソナライズは一般的でない。例えば、顔表情/文章/声からの感情/好感度推定、飲食物からの香り/味/美味しさの感じ方など、何らかの事物に対してどう感じるかの主観データは収集が難しい。そのため、主観データのモデル化は、広く一般にどう感じられるかは研究されている[2,3,16]ものの、ある A さんがどう感じるかなどの個人単位においては実用レベルに達していない。このような個人の主観データのモデル化が実現されれば、個人の主観に対して最適なアイテムを提示するパーソナライズが実現できる。例えば、ある A さんにとって最も好感度の高い表情やアバタの提示、最も美味しく感じられるレシピの作成などが実現できる。以上から、主観データに関する個人のモデルを容易に構築する主観モデリングの手法が必要である。このような主観モデリングは、ブラックボックス関数を対象として最適化する問題としてとらえることができ、主観データを対象とするために以下 2 つの課題がある。

1. 評価回数の制限によるデータの少なさ

2. 値としての主観評価の不確実性

前者は、個人のデータを収集する際に、被験者の拘束時間や疲労の問題から得られるデータが少ない課題である。後者は、主観評価を行う際に、値としての評価が正確でない課題である。例えば、提示された顔表情画像に対し、どのくらい楽しそうに見えるかを 100 点満点で評価しようとしても、1 試行前の評価に影響さ

れるなどにより、正確な評価は難しい。

ブラックボックス関数を対象として最適化する手法[4,5]のうち、ベイズ最適化[5]は、データ収集とモデル構築を効率的に行うことで少ないデータからでも効率的にモデルを構築でき、課題 1 を解決できる。課題 2 については、被験者にとって連続値や離散値としての評価よりも比較による相対的な評価の方が容易なことから、比較データを用いてモデルを構築する方法[6,7,8]が用いられている。ベイズ最適化の関数推定のステップにおいて比較データを用いる方法には、2 つのパラメタを被験者に提示し比較を行った結果（以降、ペアワイズ比較データと呼ぶ）から関数を推定するペアワイズガウス過程選好学習[8]がある。以上から、主観モデルの構築にはベイズ最適化の枠組みとガウス過程選好学習の併用が有望と考えられる。しかし、ペアワイズガウス過程選好学習には、ペアワイズ比較データを用いるために学習に必要な比較の回数が多く時間もかかり、被験者の負担が大きい問題がある。

そこで我々は、複数のパラメタを被験者に提示し比較を行った結果（以降、リストワイズ比較データと呼ぶ）から学習するリストワイズガウス過程選好学習を用いたベイズ最適化手法を提案する。この手法では、被験者は提示された複数のパラメタについて比較、すなわち評価の高い順に順位付けした結果を回答する。リストワイズ比較データはペアワイズ比較データに展開され、ペアワイズガウス過程選好学習が行われる。そして学習結果を元に次に提示するパラメタを探索する、という処理を繰り返し、最適値を得る（図 1）。比較するリストの長さを N としたとき、一度のリストワイズ比較で得られるペアワイズ比較データの数は $N C_2$ であることから、被験者による比較の回数と時間を減らし負担を軽減できると考えられる。ここで、比較す

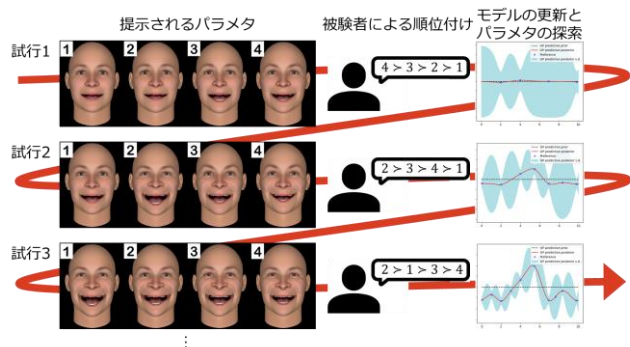


図1 提案法の流れの例. 比較するパラメタを4つの顔表情とし, 最も楽しそうと感じるパラメタを得る場合. $v > u$ は v の方が u よりも評価が高いことを示す.

るパラメタの数 N が多いほどペアワイズ比較データが多く得られる一方で, 一度の比較における被験者の負担も大きくなるため, 比較するパラメタの最適な数が明らかでないという課題がある. この課題を明らかにして提案法の有効性を確認するため, どんな表情を最も楽しそうと感じるかの表情認知モデルを構築し最適な表情を被験者ごとに得るタスクを用いた実験を行った. 精度指標は, 被験者に2枚のランダムなパラメタを提示した結果をモデルが正しく推定できた比率と, 被験者に手動で作成いただいた最も楽しそうと感じるパラメタとモデルが出力した最適値との距離の2つとした. このとき, 被験者が比較するパラメタの数を2, 4, 6, 8 として変えながらモデルの精度を求めた. 比較するパラメタの数を2とした場合が従来のペアワイズガウス過程選好学習に該当する. 結果, 比較するパラメタ数が2よりも4の場合に, 比較の回数や時間によらず高精度であった. このことから, 提案法が従来法より少ない被験者の負担でより最適なパラメタを得られることが確認された. また, モデルの構築にかかる時間が短くてよい場合は比較するパラメタの数が4, 時間が長くてよい場合は比較するパラメタの数が多いほど精度が高くなる傾向が見られた.

本研究の貢献は以下の通りである.

- ・リストワイズガウス過程選好学習を用いたベイズ最適化手法を提案した
- ・リストワイズガウス過程選好学習が, ペアワイズガウス過程選好学習よりも比較の回数や時間によらず高精度であることを実験において確かめた
- ・リストワイズガウス過程選好学習において, 適した比較パラメタ数を実験において明らかにした

以降, 2章で関連研究, 3章で提案法, 4章で実験, 5章で結果と考察, 6章で結論について述べる.

2. 関連研究

ブラックボックス関数を対象として最適化する手法には, 遺伝的アルゴリズム[4]とベイズ最適化[5]があ

る. 遺伝的アルゴリズムは, パラメタの変異と交差を行い, 評価の高いパラメタを選択する試行を繰り返して最適化を行う. ベイズ最適化は得たデータをもとにモデルを構築しながら次に得るデータを選ぶ試行を繰り返すことで最適化を行う. そのため, ベイズ最適化には少ない試行で効率的に最適化できるメリットがある. 本研究では, 個人のデータを収集する際に, 被験者の拘束時間や疲労の問題から得られるデータが少ない課題を解決するために, ベイズ最適化を用いた.

ベイズ最適化と関連する研究として, 能動学習[9]がある. いずれも得たデータをもとにモデルを構築しながら次に得るデータを選ぶ手法であるが, 目的が異なる. 能動学習の目的はモデルの構築であり, ベイズ最適化の目的は最適化である. 目的が異なるため, 次に得るデータを選ぶ基準も異なる. また, 能動学習の多くは既に収集されたデータのうち正解ラベルを付与すべきデータを選ぶものであり, 収集されたデータという離散的な空間を探索する. 一方でベイズ最適化は, 収集すべきデータを得る方法であり, 連続的な空間を探索するという差もある[10]. 今回のタスクは, 被験者にとって最適なパラメタを得るものであることから, ベイズ最適化を用いた.

人による主観評価を用いてベイズ最適化を行う場合, 主観評価を行う際に連続値としての評価が正確でない課題が生じる. 例えば, 提示された顔表情画像に対し, どのくらい楽しそうに見えるかを100点満点で評価しようとしても, 1試行前の評価に影響されるなどにより, 正確な評価は難しい. これを解決する手法として, 離散値としての評価から関数を推定するガウス過程順序回帰[11]やペアワイズ比較データから関数を推定するペアワイズガウス過程選好学習[8]がある. 前者は例えば, 提示された顔表情画像に対し, どのくらい楽しそうに見えるかを7段階で評価するなどの離散的な回答データから学習を行う. 後者は例えば, 提示された2枚の顔表情画像に対し, より楽しそうに見えるのはどちらかなどの比較データから学習を行う. その他, 学習結果を被験者に提示することで, モデルが正しく学習するよう被験者が恣意的に連続値として回答する研究[17]がある. また, 比較データを用いる方法は顔の好みのモデリング[6]や, 表情の表出度合いをモデリングする研究[7]などに使われており, 主観モデリングにおいて有効であることが確認されている. 本研究では, 被験者にとっては連続値や離散値としての評価よりも比較による相対的な評価の方が容易であると考え, 比較データから学習する手法を用いた.

3. 提案法

本研究では, 多変量パラメタ x が与えられたときの被

験者による評価値を返す関数を $f(x)$ とし、これを最適化するパラメタを得ることを目的とする。最適化の枠組みにはベイズ最適化[5]を利用する。ベイズ最適化は、その時点までに得られたデータを用いてガウス過程により関数 $f(x)$ の事後分布を推定する推定ステップと、その推定分布を用いて次の探索点 x_{new} を選ぶ選択ステップ、選択された点 x_{new} における関数値 $f(x_{new})$ に関する情報を（被験者に回答してもらうことなどにより）取得する、取得ステップを繰り返すことで最適化を行う。我々の提案する手法は選ばれた探索点 x_{new} の関数値 $f(x_{new})$ そのものの情報を取得することが必要な通常のベイズ最適化とは異なり、その関数値がある別の点の関数値として比較して大きい小さいかに関する情報しか取得できない場合であっても最適化を行うことが可能な手法である。以下に各ステップの詳細について説明する。

3.1. リストワイズ比較データ

提案するベイズ最適化手法の取得ステップにおいて、被験者は提示された N 個のパラメタ $X = \{x_i: i = 1, \dots, N\}$ について比較、すなわち評価の高い順に順位付けした結果を回答する。この回答結果は以下のリストワイズ比較データとして表現することができる。

定義(リストワイズ比較データ): 回答結果を元にパラメタ集合 X 中のパラメタを評価の高い方から記号 v, u, \dots, s, t で表す。また、パラメタ v の方がパラメタ u よりも評価が高いことを記号 $v > u$ で表す。回答結果から作成できるデータ $\mathcal{D}_{list} = \{v > u > \dots > s > t\}$ をリストワイズ比較データと呼ぶ。

このリストワイズ比較データは、以下のように $N C_2$ 個のペアワイズ比較データに展開できる。

$$\mathcal{D}_{pair} = \{v > u\} \cup \dots \cup \{v > t\} \cup \dots \cup \{u > s\} \cup \{u > t\} \cup \dots \cup \{s > t\}$$

すなわち、被験者の一度の回答から複数個のペアワイズ比較データを取得することができる。これにより被験者による比較の回数と時間を減らし負担を軽減できると考えられる。例えば、比較するリストの長さすなわち比較するパラメタの数 $N=4$ であれば、得られるペアワイズ比較データの数は $4C_2=6$ であり、 N が 2 である場合と比べて 6 倍のペアワイズ比較データが得られる。そのため、被験者による比較の回数は理想的には $1/6$ に減り、一度の比較にかかる時間が 2 倍に増えたとしても、被験者の比較回答に要する時間は $1/3$ に短縮されることが期待される。ただし、比較するパラメタの数 N が多いほどペアワイズ比較データが多く得られる一方で、比較を行う際の被験者の負担も大きくなる（図 2）ため、最適なパラメタ数はパラメタの数 N を変えて実験を行うことで明らかにする。




図 2 比較するパラメタを 8 つの顔表情とし、最も楽しそうと感じるパラメタを得る例。類似したパラメタが多く、早く正確に順位付けするのは容易でない。

3.2. ガウス過程選好学習による関数推定

次に推定ステップでは、ガウス過程選好学習 (GPPL) [8] により（ペアワイズ）比較データを用いて選好関係を表現する関数 f を推定する。GPPL では (i) 関数 f はガウス過程に従い、(ii) 選好関係 $v_k > u_k$ の生成確率は関数の出力値の差 $f(v_k) - f(u_k)$ の定数倍を入力とするプロビットモデルで表現されると仮定される。前節とは異なり、この時点までで観測された全ての入力パラメタの集合を $X = \{x_i: i = 1, \dots, n\}$ 、全てのペアワイズ比較データを、 $\mathcal{D} = \{v_k > u_k: k = 1, \dots, m\}$ とこの節では書くこととする。仮定 (i) より、関数の出力値 $\mathbf{f} = \{f(x)\}_{i=1}^n$ の事前確率は、下記の平均ゼロの多次元正規分布に従う。

$$\mathcal{P}(\mathbf{f}) = \mathcal{N}(\mathbf{f}; 0, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} \mathbf{f}^T \Sigma^{-1} \mathbf{f}\right)$$

ただし Σ は共分散行列であり、その第 (i, j) 成分がカーネル関数 \mathcal{K} を用いて $\mathcal{K}(x_i, x_j)$ で与えられる。カーネル関数には RBF カーネルや Matern カーネルなど様々なものが利用でき、実験においてはベイズ最適化で広く利用される Matern カーネルを利用した [5]。さらに仮定 (ii) により、ペアワイズ比較データの生成確率は、以下の式で表現される。

$$\mathcal{P}(\mathcal{D}|\mathbf{f}) = \prod_{k=1}^m \mathcal{P}(v_k > u_k | f(v_k), f(u_k)) = \prod_{k=1}^m \Phi(z_k)$$

ただし、 $z_k = \frac{f(v_k) - f(u_k)}{\sqrt{2}\sigma}$ であり、 $\Phi(z)$ は 1 次元標準正規

分布の累積分布関数 $\Phi(z) = \int_{-\infty}^z \mathcal{N}(\gamma; 0, 1) d\gamma$ である。上記の式とラプラス近似を用いることで、関数の出力値の事後確率 $\mathcal{P}(\mathbf{f}|\mathcal{D}) \propto \mathcal{P}(\mathcal{D}|\mathbf{f})\mathcal{P}(\mathbf{f})$ は下記の多次元正規分布で近似できることが導かれる [8]。

$$\hat{\mathcal{P}}(\mathbf{f}|\mathcal{D}) = \mathcal{N}(\mathbf{f}; \mathbf{f}_{MAP}, (\Sigma^{-1} + \Lambda_{MAP})^{-1})$$

ただし、 $\mathbf{f}_{MAP} = \arg\max_{\mathbf{f}} \{\log \mathcal{P}(\mathcal{D}|\mathbf{f})\mathcal{P}(\mathbf{f})\}$ であり、 Λ_{MAP} は

表 1 用いた表情に関するパラメタ

ID	Name
AU01	Inner Brow Raiser
AU02	Outer Brow Raiser
AU06	Cheek Raiser
AU07	Lid Tightener
AU10	Upper Lip Raiser
AU11	Nasolabial Deepener
AU12	Lip Corner Puller
AU13	Sharp Lip Puller
AU14	Dimpler
AU20	Lip Stretchers
AU25	Lips Parted
AU27	Mouth Stretch

表 2 平均顔の生成に用いた項目および設定値

項目	設定値
Racial Group	Any
Gender	Female
Random Variance – Symmetric Shape	None
Random Variance – Asymmetric Sape	None
Random Variance – Symmetric Color	None




図 3 左は女性の平均顔，中央は人がとれない不自然な表情，右は歯が突き出た表情の顔画像

第(i,j)成分が

$$\frac{\partial^2 \sum_{k=1}^m -\ln \Phi(z_k)}{\partial f(x_i) \partial f(x_j)}$$

で与えられる行列の \mathbf{f}_{MAP} における値を表す． \mathbf{f}_{MAP} は勾配法やニュートン法など任意の凸計画問題の数値最適化手法により求めることができる．これを用いると任意の点 x^* における関数値 f^* の事後分布は正規分布

$$\mathcal{P}(f^*|\mathcal{D}) = \int \mathcal{P}(f^*|\mathbf{f})\tilde{\mathcal{P}}(\mathbf{f}|\mathcal{D})d\mathbf{f} = \mathcal{N}(f^*; \mu^*, \Sigma^*)$$

で与えられる．ただし，平均と分散は

$$\mu^* = \mathbf{k}^{*T} \Sigma^{-1} \mathbf{f}_{MAP}$$

$$\Sigma^* = \mathcal{K}(x^*, x^*) - \mathbf{k}^{*T} (\Sigma^{-1} + \Lambda_{MAP})^{-1} \mathbf{k}^*$$

ただし， $\mathbf{k}^* = (\mathcal{K}(x^*, x_1), \dots, \mathcal{K}(x^*, x_n))^T$ である．この事後分布を用いて次のステップで探索点を決定する．

3.3. 獲得関数による探索点の決定

最後に選択ステップでは，推定した予測分布 $\mathcal{P}(f^*|\mathcal{D})$ を用いて定義される獲得関数により次の探索点を決定する．本研究では獲得関数には以下の式で表される Upper Confidence Bound を利用する．

$$\mu^* + \kappa \Sigma^*$$

ただし， κ は重みパラメタである．また，Expected Improvement (EI) など他の獲得関数を利用することも

可能である．この獲得関数を最大化するパラメタ x_{new} を次の探索点として利用する．

上記の手続きにより決定した探索パラメタ x_{new} に加えて，比較のためのパラメタを加えて作成するパラメタ集合 X を次の取得ステップに渡すことで選択ステップを終了する．パラメタ集合の作り方には，例えば次の 4 つなどが考えられる．

- Best: 探索パラメタ 1 つと，評価済のパラメタのうち評価が高い順に $N-1$ つ
- Rand: 探索パラメタ 1 つと，評価済のパラメタのうちランダムに $N-1$ つ
- Var: 探索パラメタ 1 つと，評価済のパラメタのうち探索パラメタから距離の遠い順に $N-1$ つ
- New: 評価済のパラメタのうち評価が最も高い 1 つと，seed を変え探索した同値を含まない $N-1$ つ

実験ではこれら 4 つの方法の性能を比較し，最適な方法を実験的に明らかにする．

以上の方法によりベイズ最適化の各ステップを行うことを繰り返すことで，関数 $f(x)$ を最適化するパラメタを得ることが可能となる．

4. 実験

提案法の有効性を確かめるため，どんな表情を最も楽しそうと感じるかの表情認知モデルを構築し最適な表情を被験者ごとに得るタスクを用いた実験を行った．

4.1. 設定

被験者には，図 2 のように様々な表情の顔画像を複数枚提示し，楽しそうと感じる順に顔画像の左上に記載した番号を回答いただくことを指定の回数繰り返していただいた．様々な表情の顔画像は，FaceGen Modeller[12]を用い，表情に関するパラメタから顔画像を生成した．表情に関するパラメタには，Action Unit と呼ばれる顔の表情動作の最小単位を用い，笑顔に関する 12 個[13]に絞って用いた（表 1）．各パラメタは，0.1 刻みで 0.0～1.0 の 11 段階とした．すなわち，探索空間の大きさは 11^{12} だった．なお，各パラメタが 1.0 で残りのパラメタが 0.0 の場合よりも，全てのパラメタが 0.3 の場合に楽しそうであるというデータをあらかじめ作成してモデルを学習してから，各被験者の回答データを用いて学習を行った．顔のモデルには，FaceGen Modeller において表 2 の条件で女性の平均顔を作成し用いた（図 3 左）．女性の平均顔としたのは顔の個人差および性差による影響を避けるためである．また，パラメタによっては人がとれない不自然な表情（図 3 中央）も存在するため，このような顔表情については最低順位として回答するよう被験者に指示した．ただし，FaceGen Modeller で生成した顔画像では，歯が唇から突き出てしまう（図 3 右）ことがあり，これ




図 4 実験環境．被験者は右のモニターを見て回答し，実験者は左のノートパソコンから操作した．

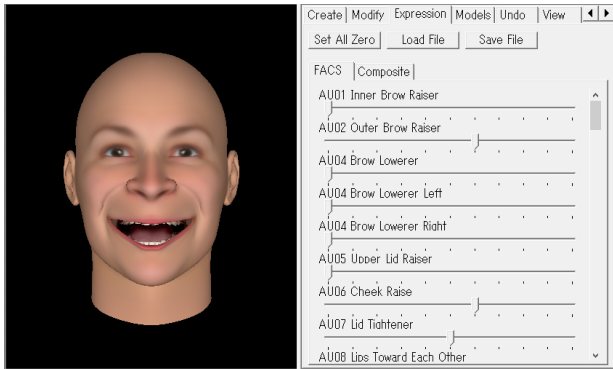


図 5 スライダーによりパラメータを調整する画面

については突き出していないものと想定して回答するよう指示した．被験者は各世代（～20代，30代，40代，50代，60代～）の男女を3人ずつ，計30人とした．実験は対面にて実施した．モニターに比較用の顔画像を提示し，被験者は口頭で比較結果を回答した（図4）．

評価指標には以下の2つを用いた．1つは，被験者に2枚のランダムなパラメータの顔画像を50回提示し，どちらがより楽しそうかを回答いただいた結果を正解とし，各試行時点で学習したモデルが正しく推定できた比率（以降，精度と呼ぶ）とした．もう1つは，被験者にとって最も楽しそうだと感じるパラメータを正解とし，各試行時点で学習したモデルが出力した最適値との距離（以降，距離と呼ぶ）とした．最も楽しそうだと感じるパラメータは，被験者が実験全体を通じて最も楽しそうだと感じたパラメータをもとに，Action Unitの値をスライダーによって調整いただくことで作成した（図5）．距離関数には，Action Unitごとの被験者の分散の逆数 w_i で重みづけした12個のパラメータの差の絶対値の合計を用いた．

$$\sum_{i=1}^{12} w_i |a_i - a'_i|$$

ここで， a_i は正解における i 番目のAction Unitのパラメータであり， a'_i は出力における i 番目のAction Unitのパラメータである．用いた2つの評価指標は，前者は

構築されたモデルの正しさを，後者はモデルが出力した最適値の正しさを測るものと解釈できる．

4.2. 実験 1

パラメータ集合の4つの作り方（3.3節）の比較を行い，最も精度の高い方法を以降の実験において用いた．このとき，比較するパラメータの数は4で固定した．

4.3. 実験 2

3.1節の通り，精度および被験者の負担の観点において比較するパラメータの最適な数を明らかにするため，以下の4つについて比較を行った．比較するパラメータの数を2とした場合が従来のペアワイズガウス過程選択学習に該当する．

- ・比較するパラメータの数 N を2とし，20回試行
- ・比較するパラメータの数 N を4とし，10回試行
- ・比較するパラメータの数 N を6とし，7回試行
- ・比較するパラメータの数 N を8とし，5回試行

このとき，比較するパラメータの選択手法はNewとし，評価済のパラメータのうち評価が最も高い1つと，seedを変え探索した同値を含まない $N-1$ つのパラメータを比較するものとした．

また，被験者の負担を主観的に測定するため，比較するパラメータ数ごとの大変さを7段階（1:全く大変ではない～7:非常に大変）で被験者に回答いただいた．

5. 結果と考察

本章では，2つの実験の結果と出力された最適値，およびそれらの考察について述べる．

5.1. 実験 1

結果は図6ようになった．結果を見ると，精度と距離でのいずれの評価においても，試行回数によらずNewが最も高精度だった．そのため，以降の実験ではNewを用いてパラメータ集合を作成した．特に，精度においては試行回数が3前後の場合に他の手法よりも大きく精度が向上しており，少ない試行において精度の高いモデルを構築できている．

また，試行回数が増えるにつれ，RandがNewの精度に近づいている．これは，ランダムに比較を行った方が最終的にモデル全体を正しく推定できると解釈できる．しかし，このためには試行回数が多く必要であるため，被験者の拘束時間や疲労の問題から得られるデータが少ない課題を解決する目的にはそぐわない．

5.2. 実験 2

結果は図7ようになった．結果を見ると，精度と距離でのいずれの評価においても，試行回数によらず，比較するパラメータの数 N が多いほど高精度となる傾向だった．比較するパラメータの数 N が多いと被験者が正確に比較を行えず，精度が下がることも考えられたが，そのような傾向は見られなかった．





図 6 実験 1（比較するパラメタの選択方法ごとの精度評価）結果．横軸は試行回数であり，縦軸は評価指標の値を示す．評価指標を精度としたものが左，距離としたものが右である．





図 7 実験 2（比較するパラメタの数ごとの精度評価）結果．横軸は試行回数であり，縦軸は評価指標の値を示す．評価指標を精度としたものが左，距離としたものが右である．


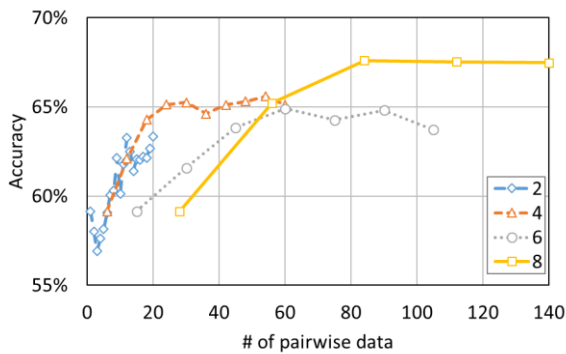


図 8 実験 2 結果について，各試行において得られたペアワイズ比較データの数を経横軸とした場合．縦軸は評価指標の値を示す．評価指標を精度としたものが左，距離としたものが右である．





図 9 実験 2 結果について，各試行にかかった時間を横軸とした場合．縦軸は評価指標の値を示す．評価指標を精度としたものが左，距離としたものが右である．

表 3 一度の試行にかかった時間

比較する パラメタ数	被験者平均 (秒)	標準偏差
2	8.4	2.6
4	16.5	3.9
6	39.7	10.6
8	73.0	31.8

表 4 大変さの 7 段階評価結果

比較する パラメタ数	被験者平均	標準偏差
2	1.76	1.26
4	2.06	1.11
6	3.41	1.33
8	4.41	1.82

実験 2 の結果について、各試行において得られたペアワイズ比較データ数を横軸とした場合の比較を行った (図 8)。結果を見ると、比較するパラメタの数 N でなく、得られたペアワイズ比較データの数によって精度が決まる傾向が見られる。例えば得られたペアワイズ比較データの数が 60 前後の場合に、比較するパラメタの数 N が 4, 6, 8 のいずれでも同程度の精度となっている。ただし、試行回数が少ない場合には学習が進んでおらず精度が低い。例えば得られたペアワイズ比較データの数が 30 前後の場合に着目すると、比較するパラメタの数 N が 4 のときよりも 8 のときに精度が低い。同様に、試行回数が多い場合には学習が停滞する。例えば得られたペアワイズ比較データの数が 80 前後の場合に着目すると、比較するパラメタの数 N が 6 のときよりも 8 のときに精度が高い。

ここで、比較するパラメタ数 N ごとの一度の試行にかかった時間は、表 3 のようになった。比較するパラメタ数 N が増えるに従い、指数的に増加している。これを考慮するため、実験 2 の結果について、各試行にかかった時間を横軸とした場合の比較を行った (図 9)。結果を見ると、まず、比較するパラメタ数が 2 よりも 4 の場合に、比較の回数や時間によらず高精度であった。次に、比較するパラメタ数 N が 4 以上の場合では、精度では、試行時間約 2 分 30 秒までは 4 枚、以降は 8 枚の場合に精度が高い。距離では、試行時間約 1 分までは 4 枚、約 3 分までは 6 枚、以降は 8 枚の場合に精度が高かった。

大変さの 7 段階評価結果については、表 4 のようになった。比較するパラメタ数 N が 2 から 4 で +0.3, 4 から 6 で +1.35 と、6 から大変さが大きく増加している。

5.3. 実験結果の考察

実験 2 において、比較するパラメタ数が 2 よりも 4 の場合に、比較の回数や時間によらず高精度であったことから、提案法が従来法より少ない被験者の負担で

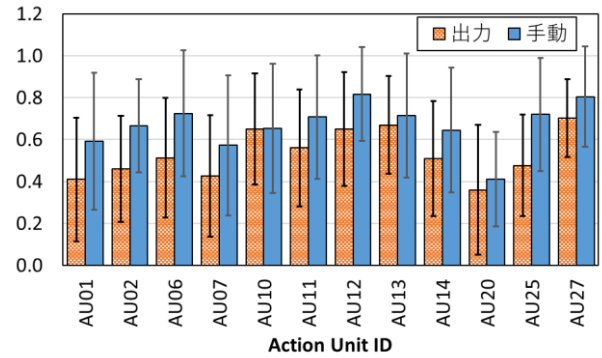


図 10 提案法が出力した最適値および被験者が手動で調整したパラメタの、被験者における平均値、バーは標準偏差を示す。




図 11 提案法が出力した最適値 (左) および被験者が手動で調整した (右) パラメタの、被験者における平均の顔表情。

より最適なパラメタを得られることが確認された。

また、この実験の設定においては、モデルの構築にかかる時間が短くてよい場合は比較するパラメタの数が 4、時間が長くてよい場合は比較するパラメタの数を多く設定することが有効であった。問題設定により精度面や時間面で最適なパラメタは変化しうると推測されるが、このパラメタ設定は今回とは別のタスクや設定で実験を行う際にも参考となる指針と考える。

5.4. 提案法が出力した最適値の考察

提案法が出力した最適値および被験者が手動で調整したパラメタの比較を行った。結果は図 10 のようになった。提案法の出力した最適値の方が被験者が手動で調整したパラメタよりも小さい傾向だが、Action Unit ごとの相対的な大小関係については類似している。提案法の出力した最適値および被験者が手動で調整したパラメタについて、顔表情として表示すると、図 11 のようになった。口角の上がり具合などの細部では差が見られるものの、顔全体の表情としては大きな差は無く感じられる。

各被験者が手動で調整したパラメタの顔表情は図 12 のようになった。口角と頬が上がるなどの共通する点もあるものの、その度合いと眉の上げ方や目の細め




図 12 各被験者が手動で調整したパラメタの顔表情

方などには差があり、最も楽しそうと感じる表情は人によって個人差が大きいことが見てとれる。

以上から、提案法は、最も楽しそうと感じる顔表情パラメタを被験者ごとに得るという、個人差の大きなタスクにおいて、個人差をうまく捉え、モデル化することができたと言える。

6. 結論

本研究では、リストワイズガウス過程選好学習を用いたベイズ最適化手法を提案した。本手法により一度の比較で複数のデータへの評価が得られ、被験者による比較の回数と時間を減らし負担を軽減できる。表情認知モデルを被験者ごとに構築し最適な表情を得る実験を通じ、提案法が従来手法より少ない被験者の負担でより高精度な主観モデルを構築できることを確認した。また、モデルの構築にかかる時間が短くてよい場合は比較するパラメタの数が 4、時間が長くてよい場合は比較するパラメタの数が多ほど精度が高くなる傾向が見られた。

参 考 文 献

- [1] Sahraoui Dhelim, et al. "A survey on personality-aware recommendation systems", Springer Artificial Intelligence Review, 2021.
- [2] Garima Sharma, et al. "A Survey on Automatic Multimodal Emotion Recognition in the Wild" Springer Advances in Data Science: Methodologies and Applications, 2020.
- [3] Hosana Kamiyama, et al. "Likability estimation for contact center agents by selecting annotators based on binomial distribution", Acoustical Science and Technology, 2020.
- [4] Sourabh Katoch, et al. "A review on genetic algorithm: past, present, and future", Springer Multimedia Tools and Applications volume, 2020.
- [5] Jasper Snoek, et al. "Practical bayesian optimization of machine learning algorithms." Advances in neural information processing systems (NIPS), 25, 2012.
- [6] Masashi Komori, et al. "Investigation of Facial Preference Using Gaussian Process Preference Learning and Generative Image Model", Springer Computer Information Systems and Industrial Management (CISIM), 2021.
- [7] Kazuaki Kondo, et al. "Siamese-structure Deep Neural Network Recognizing Changes in Facial Expression According to the Degree of Smiling", International Conference on Pattern Recognition (ICPR), 2021.
- [8] Wei Chu, et al. "Preference learning with Gaussian processes", ACM international conference on machine learning (ICML), 2005.
- [9] Punit Kumar, et al. "Active Learning Query Strategies for Classification, Regression, and Clustering: A Survey", Springer Journal of Computer Science and Technology, 2020.
- [10] Eric Brochu, et al. "A Tutorial on Bayesian Optimization of Expensive Cost Functions, with Application to Active User Modeling and Hierarchical Reinforcement Learning", arXiv preprint, arXiv:1012.2599 [cs.LG], 2010.
- [11] Wei Chu, et al. "Gaussian Processes for Ordinal Regression", Journal of machine learning research, 2005.
- [12] Singular Inversions, "FaceGen Modeller", <https://facegen.com/modeller.htm>, (accessed February 14 2022).
- [13] Paul Ekman, et al. "Facial action coding system", Environmental Psychology & Nonverbal Behavior, 1978.
- [14] Niranjana Srinivas, et al. "Gaussian Process Optimization in the Bandit Setting: No Regret and Experimental Design", International Conference on Machine Learning (ICML), 2010.
- [15] Bobak Shahriari, et al. "Taking the Human Out of the Loop: A Review of Bayesian Optimization", in Proceedings of the IEEE, vol. 104, no. 1, pp. 148-175, 2016.
- [16] Soyoung Rhim, et al. "Tracking and Modeling Subjective Well-Being Using Smartphone-Based Digital Phenotype", ACM Conference on User Modeling, Adaptation and Personalization (UMAP), 2020.
- [17] Fabio Colella, et al. "Human Strategic Steering Improves Performance of Interactive Optimization", ACM Conference on User Modeling, Adaptation and Personalization (UMAP), 2020.