

# ジオソーシャルデータを用いた夜間の賑わいに基づいた経路推薦

山下 桜生<sup>†</sup> 横山 昌平<sup>††,†††</sup>

<sup>†</sup> 東京都立大学 システムデザイン学部 〒191-0065 東京都日野市旭が丘6-6

<sup>††</sup> 東京都立大学大学院 システムデザイン研究科 〒191-0065 東京都日野市旭が丘6-6

<sup>†††</sup> 東京大学生産技術研究所 〒153-8505 東京都目黒区駒場4-6-1

E-mail: <sup>†</sup>yamashita-osei@ed.tmu.ac.jp, <sup>††</sup>shohei@tmu.ac.jp

**あらまし** 経路推薦は距離や時間だけに限らず、様々な尺度で行われている。特に観光目的の経路推薦は多く存在している一方で、主観に基づいた経路推薦は少ない。本研究では、夜間の外出時に暗い夜道を避けたい、賑やかな経路を通りたいというニーズを満たす経路推薦手法の提案を行う。賑やかさの評価は、FlickrのExif付き写真から行った。この写真を、Exifデータを利用することで屋内で撮影された写真と屋外で撮影された写真に分類し、屋外に分類された写真の明度から賑やかさを定義する。そして、それらの位置をクラスタリングすることで賑やかなエリアを抽出する。最後に、最短距離と長さ比率を使って経路推薦を行い、定性的に本手法の有効性を検証する。

**キーワード** ジオソーシャルデータ、地理情報、経路推薦、Flickr

## 1 はじめに

近年、スマートフォンやデジタルカメラなどのモバイルデバイスは広く普及しており、ユーザーはそれらを利用し、動画、写真、テキストといったデータを生成している。また、それらのデータをソーシャルメディア上にアップロードすることで、不特定多数の人々と共有することができる。ソーシャルメディアの例として、Twitter<sup>1</sup>、Facebook<sup>2</sup>、Instagram<sup>3</sup>、Flickr<sup>4</sup>などが挙げられ、これらソーシャルメディアのデータのことをソーシャルデータと呼ぶ。ソーシャルデータには人々の興味・関心のあるものや、出来事に対する感想などが含まれており、それらを活用する研究が進められている。

ソーシャルデータを活用した研究の例として、人口変化の予測の研究[1]がされている。また、位置情報に関するメタデータが付与されているソーシャルデータのことをジオソーシャルデータと呼び、それを活用した研究にリアルタイム地震予測の研究[2]がある。

また、スポット抽出も多く研究されており、特に観光スポット抽出の研究が盛んに研究されている。これに経路探索アルゴリズムを組み合わせることで、観光スポットの経路推薦が多く提案されている。例えば、新井ら[3]はTwitterユーザが観光スポットを訪れた際にツイートした情報からスコアを算出し、そのスコアを使って観光ルートを推薦する手法を提案した。また、酒井ら[4]はFlickrデータを活用し、ユーザが過去に撮影した情報を使うことで、撮影スポット推薦法に関してユーザの異なる地域での撮影行動を考慮することに有効性があることを示し、他の撮影者の過去の回遊行動を活用する方法を提案した。

しかし、主観に基づいた経路推薦に関する研究は少ない。本研究では、夜間の外出時に暗い夜道を避けたい、賑やかな経路を通りたいというニーズを満たす経路を推薦することを目的とする。以下、2節では関連研究を、3節では提案手法を、4節では実験と考察を、5節にまとめを述べる。

## 2 関連研究

最短経路探索としては、ダイクストラ法[5]やA\*アルゴリズム[6]などがある。これらのアルゴリズムは、ネットワークのコストに基づいて総コストが最小となる経路を探索するアルゴリズムである。

景観を考慮した経路推薦として、川俣ら[7]は景観要素を分類し、分類した景観を景観ベクトルとして定義することから、ドライブを楽しむことができる経路を推薦している。しかし、景観要素の分類は田園系、山林系、水辺系、都市系の4つであり、直接賑やかさを判別できる景観要素はない。また、景観要素の分類は土地被覆から行われているため、賑やかさを追加するのも難しい。さらに、この研究はドライブルートを想定しているのに対し、本研究では歩行による経路推薦を行うものである。そのため、土地被覆等の衛星写真によるデータで経路推薦を行うためには解像度が低すぎるという問題点もある。

Querciaら[8]はHappy, Quiet, Beautifulの3指標に適した経路を推薦する手法を提案している。この手法ではクラウドソーシングによりスコア付けされたデータを用いているが、この手法は時間による状況の変化がないものとしている点、賑やかさを指標としていない点が異なる。

安西ら[9]はクラウドソーシングを活用し、「美しい」、「にぎやかだ」、「歴史を感じる」の3つの指標で通りに対しての印象を調べ、雰囲気スコアを算出した。そして、検証した通りの風景画像を教師データとして深層学習を行い、雰囲気スコアを推定した。また、それに基づいて重みづけを行い、ダイクストラ

1: <https://www.twitter.com/>

2: <https://www.facebook.com/>

3: <https://www.instagram.com/>

4: <https://www.flickr.com/>

法で経路を導出している。しかし、印象を評価する際の通りのデータセットには Google Street View を利用しており、これには夜間のデータが含まれないため、夜間の賑やかさを評価することはできない。

### 3 提案手法

賑やかさの評価には、Flickr API から得られる Exif 付き写真の位置情報と、写真の明るさから行う。写真が撮影されたということは、Exif データに記載されている撮影地点・時間に人がいたということになり、賑わいの評価の指標になる。また、永江ら [10] は日本の 3 大都市圏を対象に、交通量に基づき定義される都心ゾーンを教師データとして夜間光による都心抽出を行い、両者の間に正の相関があることを明らかにしている。都心は都市の中枢であることから賑やかであり、明るさと賑やかさに関係があるといえる。また、賑やかなところは商業施設などが栄えており、明るいことは経験的にも明らかである。ただし、屋内は照明により明るいため、屋外の写真の明るさを賑わいを表す指標とする。写真の明るさは、明度のパーセンタイルから計算する。

本手法の流れを図 1 に示す。提案手法はデータ取得フェイズ、データ抽出フェイズ、賑やかなエリア計算フェイズの 3 つのフェイズの後に経路推薦を行う。データ取得フェイズでは Flickr API により Exif 付き写真を取得し、必要な特徴量が全て記載されているものを抽出する。データ抽出フェイズでは、写真の Exif データから、撮影時間が夜間であり、撮影された場所が屋外であるものを抽出し、撮り直し写真は除外する。次に、賑やかなエリア計算フェイズで写真を HSV 変換し、明度のパーセンタイルから賑やかさを求め、クラスタリングを行うことで賑やかなエリアを求める。最後に、長さ比率を使うことで経路推薦を行う。

データ取得フェイズについて 3.1 節に、データ抽出フェイズについて 3.2 節に、賑やかなエリア計算フェイズについて 3.3 節に、経路推薦について 3.4 節に示す。

#### 3.1 データ取得フェイズ

まず Flickr API を用いてアップロード期間と緯度経度の範囲を指定し、Exif データの付いている写真を取得する。Exif データとは、写真を撮影した際に付与されるメタデータのことである。例として、撮影された地点の緯度、経度、撮影したカメラのメーカーなどがある。

Exif データは写真によって含まれているデータが異なり、必要なデータが含まれていないこともある。そのため、収集した Exif 付き写真のうち、表 1 に示すデータを全て含む写真のみを使用する。

また、Flickr API の仕様上、緯度経度を使用した一度のクエリで取得できるデータ数は 4000 件程度であるため、本研究では取得したい領域と日付を分割し、複数回クエリを実行することで指定した範囲の全データを取得した。

表 1 必要なデータ名とその意味

データ名	意味
latitude	緯度
longitude	経度
owner	撮影者 ID
Make	メーカー名
ExposureTime	露光時間
FNumber	F 値
ISO	ISO 感度

#### 3.2 データ抽出フェイズ

次に、3.1 節で抽出した写真に対して、撮影時間が夜間の写真を抽出する。夜間の定義は本研究では、日本において一年間を通して暗い時間帯である 19:00 ~ 5:00 とし、Exif データに記載されている撮影時間を基に抽出する。

次に、撮り直し写真の除外を行う。撮り直しの多さと賑やかさは無関係であるため、同一撮影者による同一地点で繰り返し撮影された写真は撮り直しと判定し、1 枚を除いて除外する。同一撮影者の判定は Exif データの撮影者 ID から、同一地点の判定は Exif データの緯度と経度から行う。

得られた写真に対し、写真が撮影された地点が屋内か屋外かの分類をする。Flickr API は撮影された写真が屋内か屋外かを指定して収集することができるが、緯度経度を同時に指定して収集することが仕様上できない。そのため、Exif データに含まれる特徴量を使用し、教師あり学習で屋内か屋外かを分類する。分類に使用した特徴量は表 2 に示す。これらの特徴量の内、ExposureTime, FNumber, ISO は写真の明るさに関わる基本的なパラメータであることから選定した。また、Make はスマートで撮影されたものかどうかで傾向が大きく異なることから選定した。

分類データには東京 23 区で撮影された写真の内、2019 年にアップロードされた写真を使用した。この写真は全部で 70720 枚であり、夜間に撮影されたものはその内の 11878 枚、さらに撮り直しを除くと 4903 枚であった。そこにラベル付けを行った結果、屋内の写真が 3050 枚、屋外の写真が 1853 枚であった。なお、屋内か屋外かの判定は、写真内に空が写っていれば屋外、写っていないければ屋内とした。

このデータに対し、約 7 割である 3432 枚の写真を教師データ、残りの 1471 枚の写真を評価データとして 5 分割交差検定法を実施した。本研究では、表 2 に示す特徴量の内、Make を One-hot 表現するため、学習モデルには説明変数が多くても学習・評価を高速に行えるランダムフォレストを使用した。その結果の分類精度を、表 3 に示す。

このデータを教師データとして、2018 年、2017 年、2016 年のデータに対して、屋外で撮影されたか、屋内で撮影されたかの予測を行った。夜間の東京 23 区で撮影され、撮り直しを除外した、屋外で撮影されたと予測されたデータ数は全部で 11446 枚であり、内訳を表 4 に示す。これに教師データを加えた 13624 枚のデータを経路推薦に使用する。

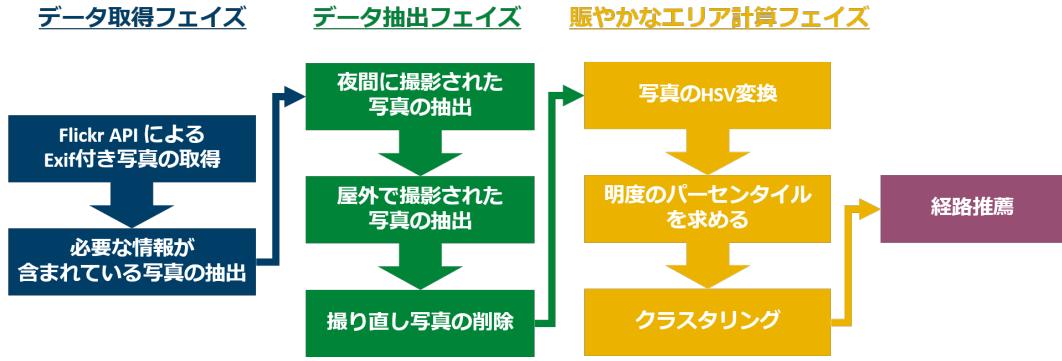


図 1 提案手法の流れ

表 2 屋内・屋外の分類に使用する特徴量

データ名	意味
Make	メーカー名
ExposureTime	露光時間
FNumber	F 値
ISO	ISO 感度

表 3 屋内・屋外の分類精度

評価尺度	結果
Recall	72.4%
Precision	64.0%
F 値	67.9%

表 4 夜間の東京 23 区で撮影され、撮り直しを除外し、屋外で撮影されたと予測された各年の写真の枚数

期間	枚数
2016-01-01 ~ 2016-12-31	2791
2017-01-01 ~ 2017-12-31	3298
2018-01-01 ~ 2018-12-31	5357

### 3.3 賑やかなエリア計算フェイズ

次に、賑やかなエリアを求める。賑やかさは写真の明るさから求める。本研究では写真を Hue (色相), Saturation (彩度), Value (明度) を表す HSV 色空間に変換し、明度のパーセンタイルの値から明るさを求める。明度は 0 ~ 255 までの値をとるため、これを正規化した値を賑やかさとする。

パーセンタイルの値はばらつきが大きいことが望ましいため、パーセンタイルを変化させたときの分散が大きいものを使用する。3.2 節で説明した、東京 23 区で撮影され、2019 年にアップロードされた写真にラベル付けを行い、屋外と判定した写真 1853 枚に対してパーセンタイルを 5 ~ 95 まで 10 ずつ変化させたときの分散を調べた。その結果を表 5 に示す。表の通り、分散が最も大きくなるのは 75 のときであったため、本研究では明度の 75 パーセンタイルの値を正規化した値を賑やかさとする。

例として、75 パーセンタイルの値が 25 の写真と明度のヒストグラムを図 2 に、158 の写真と明度のヒストグラムを図 3 に示す。図 2 は累積頻度が対数関数的に増加していることが分かる。75 パーセンタイルの値は 25 であったため、正規化して

表 5 東京 23 区で撮影され、2019 年にアップロードされた写真にラベル付けを行い、屋外と判定した写真 1853 枚に對して  $x$  パーセンタイルの  $x$  を 5 ~ 95 まで 10 ずつ変化させたときの分散

$x$	分散
5	260.317
15	663.418
25	1094.108
35	1594.294
45	2066.340
55	2402.129
65	2679.430
75	2930.831
85	2771.692
95	2021.112

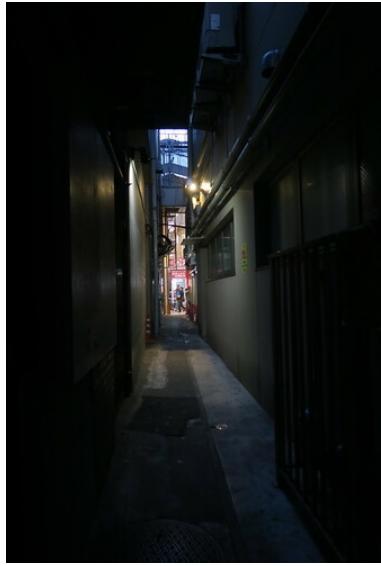
0.098 をこの地点での賑やかさとする。一方で、図 3 は累積頻度が線形的に増加していることが分かる。75 パーセンタイルの値は 158 であったため、正規化して 0.620 をこの地点の賑やかさとする。

以上で求めた賑やかな地点に対してクラスタリングを行う。本研究では賑やかな地点が集中している地点を求めたいため、クラスタリング手法には DBSCAN [11] を使用する。DBSCAN は密度ベースのクラスタリング手法であり、ある距離以内の点の数から、その領域をクラスタと判定するアルゴリズムである。

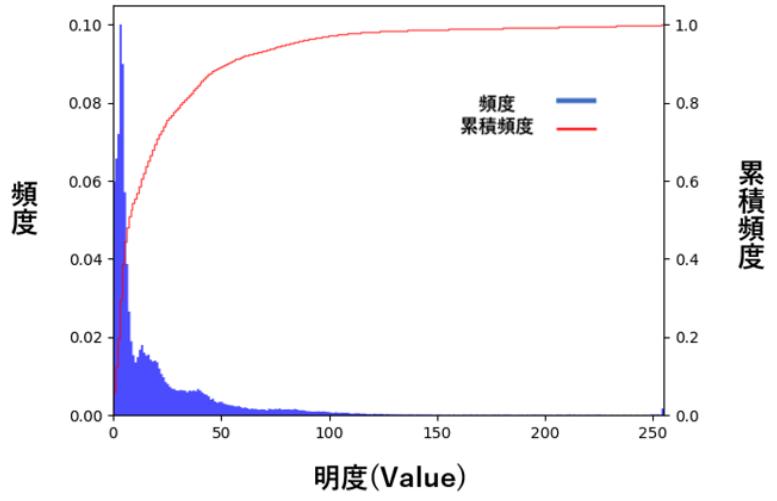
新宿駅近辺の賑やかなエリアを DBSCAN により求めた図を図 4 に示す。外れ値が黒色、各クラスタのクラスタ中心が赤色、後で説明する疑似クラスタ中心が黄色、それ以外の同じ色が同じクラスタを形成していることを示す。また、クラスタ中心は賑やかな地点の重みを考慮した重心位置とした。すなわちクラスタ内に含まれる賑やかな地点が  $n$  個あり、 $i$  番目の賑やかさが  $w_i$  とすると、クラスタ中心の  $x$  座標と  $y$  座標は式 1 の通りである。なお、距離は緯度経度を平面直角座標に直して計算し、求まったクラスタ中心の位置を再び緯度経度座標系に直す。

5 : Photo by cat\_in\_136 (<https://www.flickr.com/photos/27992339@N00/31872954747/>) / CC BY-NC-SA 2.0

6 : Photo by Jason Scott-Taggart ([https://www.flickr.com/photos/jason\\_scott-taggart/49025241838/](https://www.flickr.com/photos/jason_scott-taggart/49025241838/)) / CC BY-NC-SA 2.0



(a) 写真

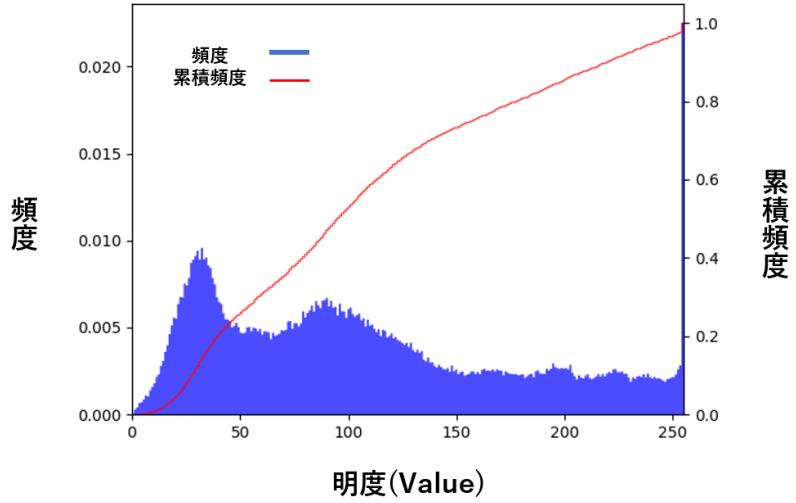


(b) 明度のヒストグラム

図 2 75 パーセンタイルの値が 25 の写真<sup>5</sup> と明度のヒストグラム



(a) 写真



(b) 明度のヒストグラム

図 3 75 パーセンタイルの値が 158 の写真<sup>6</sup> と明度のヒストグラム

$$(x, y) = \left( \frac{\sum_{i=1}^n x_i w_i}{\sum_{i=1}^n w_i}, \frac{\sum_{i=1}^n y_i w_i}{\sum_{i=1}^n w_i} \right) \quad (1)$$

本研究では、道路ネットワークのデータに OpenStreetMap<sup>7</sup> (OSM) を使用した。OSM はオープンデータの地理情報を作成するプロジェクトであり、道路などの地理情報データを誰でも利用することができる。この道路ネットワークは  $G = (V, E)$  で表現され、 $V$  が道路ノード集合、 $E$  が道路エッジ集合を表す。ここで道路ノード  $v_i \in V$  は交差点や道路の終点を表すが、これはクラスタ中心とは一致しないため、クラスタ中心に最も近い道路ノードを疑似クラスタ中心として経路推薦に利用する。

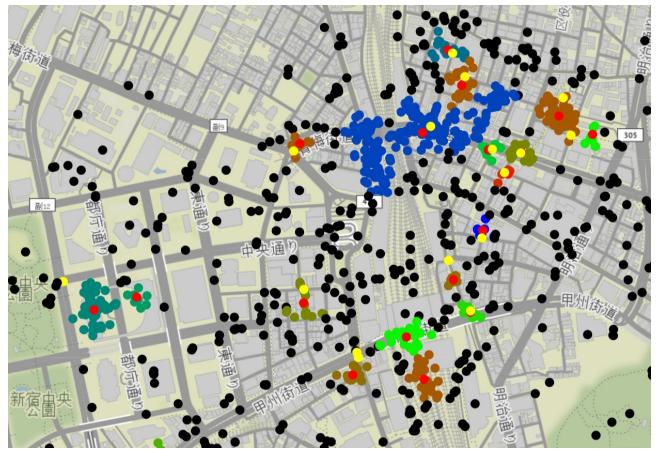


図 4 新宿駅近辺に対して DBSCAN を行った図<sup>8</sup>

7 : <https://www.openstreetmap.org/>

8 : Leaflet — Map tiles by Stamen Design, under CC BY 3.0. Data by OpenStreetMap, under CC BY-SA.

表 6 新宿駅近辺で  $f$  を 1.0 ~ 2.0 まで 0.1 ずつ変化させたときに推薦される経路の距離と賑やかさの関係

$f$	経路長 (m)	賑やかさ	経路長当たりの賑やかさ
1.0	1403.490	12.906	0.0091956
1.1	1421.004	41.906	0.0294903
1.2	1571.621	59.675	0.0379700
1.3	1571.621	59.675	0.0379700
1.4	1946.438	127.963	0.0657420
1.5	2102.426	156.806	0.0745833
1.6	2201.894	165.971	0.0753763
1.7	2307.550	169.792	0.0735803
1.8	2487.104	177.367	0.0713145
1.9	2592.760	181.186	0.0698816
2.0	2801.838	184.802	0.0659574

### 3.4 経路推薦

最後に経路推薦を行う。まず、疑似クラスタ中心と経路推薦の出発地点、到着地点をノードとし、その間の最短距離をエッジとするグラフを作成する。次に、出発地点から到着地点までの最短距離を基準に、どの程度の回り道を許すかを示す長さ比率の設定を行う。出発地点から到着地点までの最短距離を  $d$ 、長さ比率を  $f$ 、その経路長を  $Length$  として、式 2 を満たす経路を隣接行列から全て求める。

$$Length \leq f \times d \quad (2)$$

求めた経路に対して、疑似クラスタ中心にクラスタ内の賑やかさの総和がコストとして含まれているとし、その総和を経路の賑やかさとして求める。そして、求めた経路の中で最も賑やかさが大きい経路を推薦する。ただし、同じ経路を辿るような経路は不適切であると考えられるため、そのような経路は除外した。

## 4 実験と考察

本手法を用いて、新宿駅近辺と渋谷駅近辺で長さ比率  $f$  を変化させたときに推薦される経路の距離と賑やかさの関係を調べた。4.1 節に新宿駅近辺について、4.2 節に渋谷駅近辺についての実験結果と考察を示す。

### 4.1 新宿駅近辺

新宿駅近辺で、長さ比率  $f$  を 1.0 ~ 2.0 まで 0.1 ずつ変化させたときに推薦される経路の距離と賑やかさの関係を表 6 に示し、そのときの経路の一部を図 5 に示す。

全体を通して  $f$  が増えると推薦される経路が変わり、より多くの賑やかなエリアを経由していることが分かる。距離当たりの賑やかさは、 $f = 1.0$  から 1.1 になるとき、1.3 から 1.4 になるときに大きく増えている。 $f = 1.0$  は最短経路を指し、この例では最短経路が賑やかなエリアを通る経路となっているが、最短経路は賑やかなエリアに寄る余裕はないため、賑やかさは小さい。 $f = 1.1$  からは賑やかなエリアを探すため、賑やかさがかなり大きくなる。

表 7 渋谷駅近辺で  $f$  を 1.0 ~ 2.0 まで 0.1 ずつ変化させたときに推薦される経路の距離と賑やかさの関係

$f$	経路長 (m)	賑やかさ	経路長当たりの賑やかさ
1.0	1183.847	0.0	0.0
1.1	1183.847	0.0	0.0
1.2	1318.924	22.071	0.0167338
1.3	1318.924	22.071	0.0167338
1.4	1318.924	22.071	0.0167338
1.5	1666.069	30.455	0.0182795
1.6	1846.974	35.306	0.0191155
1.7	1969.532	56.098	0.0284829
1.8	2043.957	64.482	0.0315478
1.9	2231.948	82.757	0.0370783
2.0	2358.080	108.325	0.0459380

$f = 1.3$  から 1.4 になるときに賑やかさが大きく増えていることについての考察と本手法の評価を行う。図 5 から分かるように、 $f = 1.3$  までは駅の南側を通っていた経路が、 $f = 1.4$  以降は駅の北側を通る経路へと大きく変更されている。これは、駅の北側の大きな青色のクラスタによるものであり、このクラスタの賑やかさは他のクラスタに比べて大きいため、他の経路よりも優先して推薦されていると考えられる。この青色の大きなクラスタは、夜間に営業している店が多いエリアであることから、定性的に本手法の有効性が示された。

### 4.2 渋谷駅近辺

渋谷駅近辺で、長さ比率  $f$  を 1.0 ~ 2.0 まで 0.1 ずつ変化させたときに推薦される経路の距離と賑やかさの関係を表 7 に示し、そのときの経路の一部を図 6 に示す。

4.1 節での結果と同じく、 $f$  が増えると推薦される経路が変わり、より多くの賑やかなエリアを経由していることが分かる。しかし、 $f$  が 1.0 と 1.1、1.2 と 1.3 と 1.4 の場合に経路長と賑やかさが同じになっており、推薦されている経路が同じことが分かる。

そこで、 $f$  を変えても同じ経路が推薦されることについての考察を行う。図 6 の  $f = 1.0, 1.2$  付近には賑やかなエリアがないことが分かる。本手法では最短経路を基に、寄ることができます賑やかなエリアを求めているため、最短経路付近に賑やかなエリアがない場合は、本手法を適用することができないことが分かる。

## 5 おわりに

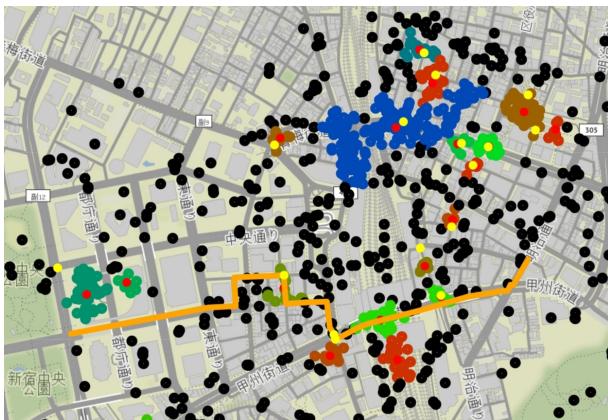
本論文では、夜間の賑わいに基づいた経路推薦手法の提案を行った。Flickr の Exif 付き写真から、夜間に屋外で撮影された写真を求め、その写真の明度の 75 パーセンタイルの値を正規化した値を賑やかさとした。また、得られた賑やかさの位置情報を用いて、DBSCAN でクラスタリングを行い、得られたクラスタを賑やかなエリアとした。抽出したクラスタのクラスタ中心に最も近い道路ネットワーク上のノードを疑似クラスタ中心として扱い、出発地点、到着地点、疑似クラスタ中心の最短経路長からなるグラフから、長さ比率を使って経路を探査した。



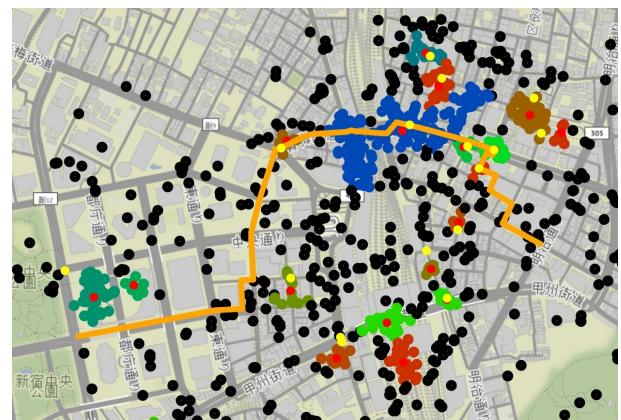
(a)  $f = 1.0$  (最短経路)



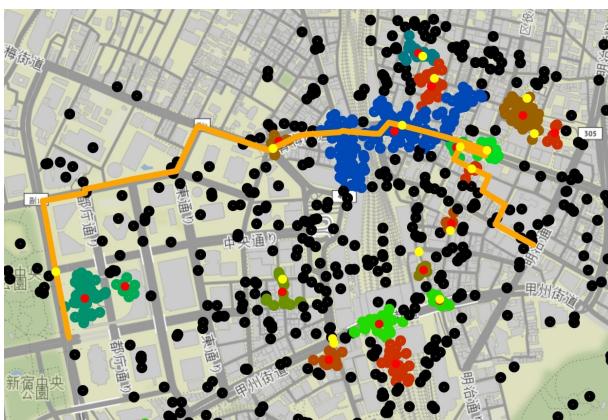
(b)  $f = 1.1$



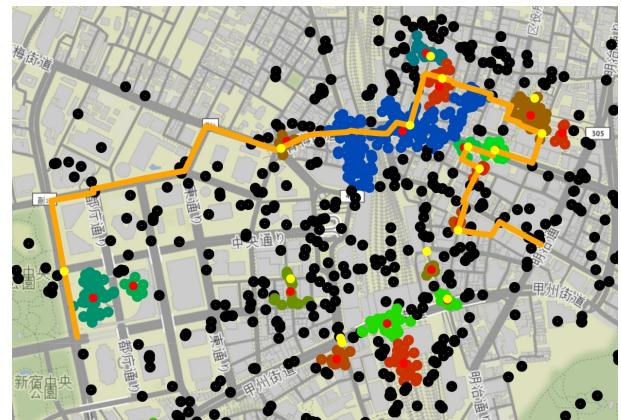
(c)  $f = 1.3$



(d)  $f = 1.4$



(e)  $f = 1.6$



(f)  $f = 2.0$

図 5 新宿駅近辺で長さ比率  $f$  を  $1.0 \sim 2.0$  まで変化させたときに推薦される経路の一部<sup>8</sup>

探索した経路の内、疑似クラスタ中心にクラスタ内の賑やかさの総和があるとして、最も賑やかさが大きい経路を推薦した。

新宿駅近辺と原宿駅近辺で実証実験を行った結果、影響の大きいクラスタがあるエリアが、夜間に営業している店が多いエリアであることから、本手法の有効性を確認した。また、条件によっては適切な経路を推薦できないことも確認した。

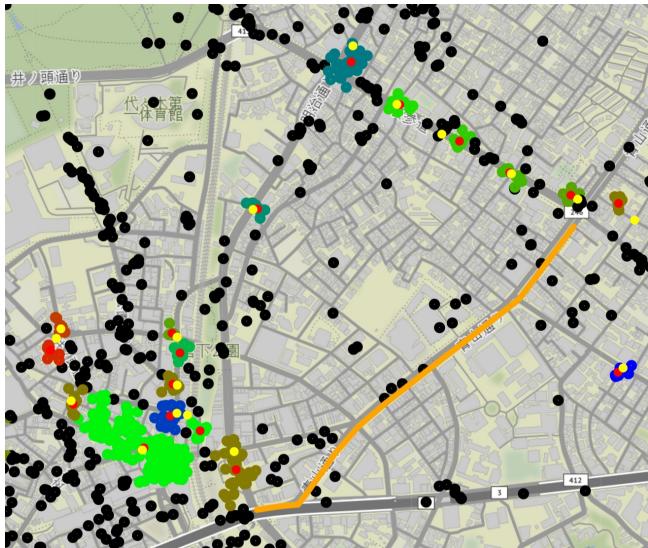
今後の課題として、次のようなことが挙げられる。

- 撮影時期の偏りの考慮
- ジオタグの精度

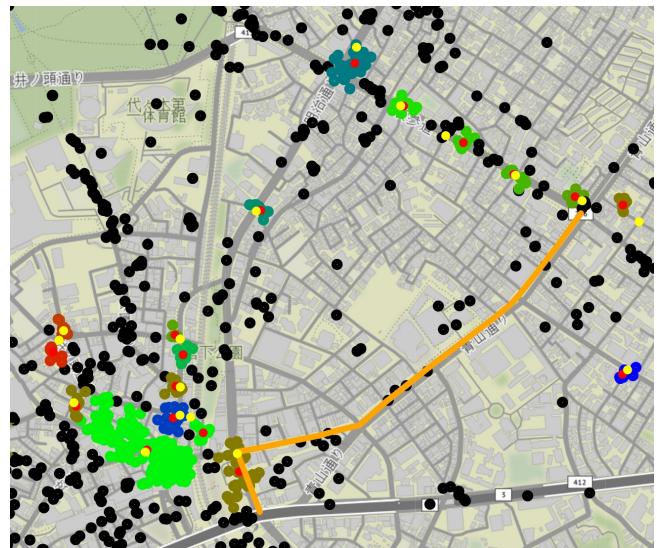
- 屋内・屋外の判定手法の精度向上
- データがないエリアで経路推薦を行う方法
- クラスタの形の考慮

本研究では 2016 ~ 2019 年のうち、条件を満たすデータを全て使用した。しかしイベントの開催などにより、通常は賑やかでないエリアで一時的に頻繁に写真が撮影されることがあるため、これを考慮する必要がある。

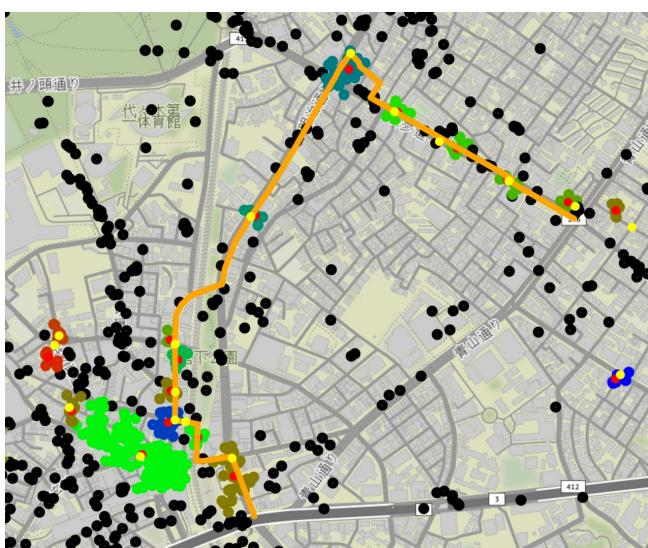
また、本研究で使用した緯度経度の情報はスマホやカメラの GPS により求めたものである。しかし、GPS による測位は誤



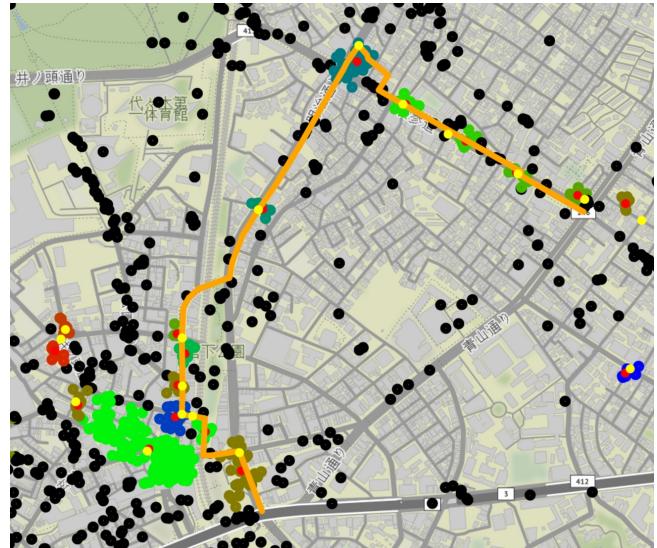
(a)  $f = 1.0$  (最短経路)



(b)  $f = 1.2$



(c)  $f = 1.5$



(d)  $f = 2.0$

図 6 渋谷駅近辺で長さ比率  $f$  を  $1.0 \sim 2.0$  まで変化させたときに推薦される経路<sup>8</sup>

差を含むことがあるため、それを考慮する必要がある。また本手法では、クラスタ中心に最も近い道路ネットワーク上のノードを調べる際にも誤差が発生しているため、これも考慮する必要がある。

さらに本研究では屋内・屋外を Exif から判定したが、屋内・屋外の判定手法に関する研究は数多くされており、色の特徴やテクスチャ、エッジなどを特徴量とするものがある [12]。また、既存のサービスとして Microsoft の Computer Vision API などが挙げられる。これらの手法やサービスを利用することで、屋内・屋外の分類精度向上が期待できる。

また、本手法は Flickr データが十分にあるエリアでないと使用することができないという問題点があるが、他のデータを使用することで改善ができると考えられる。例として Google Maps Platform の Places API により求められる、店の営業情報やレビューなどである。

また、経路推薦を行う際にクラスタ中心を経由することで経

路推薦を行っているが、特定の方向に長いクラスタなどがある場合、短さ方向にクラスタ中心を経由してしまう可能性がある。この場合、賑やかなエリアを非効率的に通過してしまうことになるため、クラスタの形も考慮する必要がある。

今後はこれらの問題を考慮することで、賑やかさに基づいた経路推薦手法の提案を行っていく。

## 謝 詞

本研究の一部は JSPS 科研費 19K11982 の助成を受けたものです。

## 文 献

- [1] 塚田涼太郎, 浩森, 石渡祥之佑, 豊田正史, 梅本和俊, 商海川, 是津耕司. 未来のイベントに言及するマイクロブログ投稿を用いた人口変化の予測. 第 13 回データ工学と情報マネジメントに関するフォーラム, 2021.

- [2] Takeshi Sakaki, Makoto Okazaki, and Yutaka Matsuo. Earthquake shakes twitter users: real-time event detection by social sensors. In *Proceedings of the 19th international conference on World wide web*, pp. 851–860, 2010.
- [3] 新井晃平, 新妻弘崇, 太田学. Twitter を利用した観光ルート推薦の一手法. 第 7 回データ工学と情報マネジメントに関するフォーラム, 2015.
- [4] 酒井勇人, 熊野雅仁, 木村昌弘. Flickr データに基づいた インタラクティブ観光スポット推薦システム. 人工知能学会第二種研究会資料, Vol. 2016, No. AM-14, p. 05, 2016.
- [5] Edsger W Dijkstra, et al. A note on two problems in connexion with graphs. *Numerische mathematik*, Vol. 1, No. 1, pp. 269–271, 1959.
- [6] Rina Dechter and Judea Pearl. Generalized best-first search strategies and the optimality of a. *Journal of the ACM (JACM)*, Vol. 32, No. 3, pp. 505–536, 1985.
- [7] 川俣光司, 奥健太. 景観クラスタリングに基づく景観アウェアルート推薦システム. 第 10 回データ工学と情報マネジメントに関するフォーラム, 2018.
- [8] Daniele Quercia, Rossano Schifanella, and Luca Maria Aiello. The shortest path to happiness: Recommending beautiful, quiet, and happy routes in the city. In *Proceedings of the 25th ACM conference on Hypertext and social media*, pp. 116–125, 2014.
- [9] 安西崇, 村山太一, 矢田俊太郎, 若宮翔子, 荒牧英治. ならまちハッピーマップ: クラウドソーシングと深層学習による街の雰囲気に基づく経路探索手法の提案. 第 13 回データ工学と情報マネジメントに関するフォーラム, 2021.
- [10] 永江大右, 中村太一, 紀伊雅敦. 夜間光データを用いた都心抽出方法に関する研究. 土木学会論文集 D3 (土木計画学), Vol. 74, No. 5, pp. I\_505–I\_512, 2018.
- [11] Martin Ester, Hans-Peter Kriegel, Jörg Sander, Xiaowei Xu, et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In *kdd*, Vol. 96, pp. 226–231, 1996.
- [12] ZheHang Tong, Dian xi Shi, Bingzheng Yan, and Jing Rui Wei. A review of indoor-outdoor scene classification. 2017.