

# SNS ユーザの支持情報を用いた ファッションブランド間の関係性の分析

大野 航生<sup>†</sup> 今井 哲郎<sup>‡</sup>

<sup>†</sup> 広島市立大学情報科学部 〒731-3194 広島県広島市安佐南区大塚東 3 丁目 4-1

<sup>‡</sup> 広島市立大学大学院情報科学研究科 〒731-3194 広島県広島市安佐南区大塚東 3 丁目 4-1

E-mail: <sup>†</sup> d20033@e.hiroshima-cu.ac.jp, <sup>‡</sup> imai@hiroshima-cu.ac.jp

**あらまし** これまでファッションブランドは、ショップ店員・インフルエンサーなどの専門家による主観的な分類がなされてきた。しかしこれらは、アイテムのデザインなどファッションの作り手側からの視点が色濃く反映され、そのアイテムを身に着けているのがどのようなユーザなのかなど、ユーザ側からの視点が欠けたものになることがしばしば起こる。そこで本研究では SNS ユーザのファッションブランド支持情報を用いた客観的な根拠に基づいた分類を行うことで、ファッションブランド間の関係性の多面的な表現を試みた。本研究では、コーディネート投稿 SNS である WEAR の人気 1 万ユーザのプロフィール欄の「お気に入りブランド」と「よく着用するブランド」をそのユーザのブランド支持情報とみなし、ユーザによる支持の共起頻度に基づいてブランド間の階層クラスタリングを実施した。また比較対象である専門家による分類として、ブランド紹介サイト High-Brands.com における各ブランドの属性情報を用いて階層クラスタリングを実施した。これら 2 つの分類の結果、いくつもの異なるクラスが表れることが確認された。

**キーワード** ファッション, ブランド, SNS, 階層クラスタリング, 可視化, WEAR

## 1. はじめに

昨今、急激な EC サイトでの取引の増加[1]や Instagram などの SNS の発展に伴い、ファッションブランドについて、そのブランドの名前さえ知っていれば価格や売っている場所など、ほぼ全ての情報が手に入れられるようになり、簡単にそのブランドが出すアイテムを見ることができるようになっている。これにより、ブランド名を認知しているということに関しての重要度は増し、SNS ではブランドを紹介するような投稿も増えている。ただ多くの場合においてブランドはお気に入り一つを見つけたらこと足りるものではなく、短期的にはその日の気分や天候や外出先、長期的にはライフステージや社会的地位に応じて複数のブランドを使い分けることが多い。よって膨大な数のブランドの中からその時々ニーズに合わせた複数のお気に入りブランドを見つける必要がある。

したがって視覚的情報である画像を用いた探索支援に関する研究が多く行われている[2][3]。しかし現状の探索支援の問題点はアイテムの情報を用いた絞り込み検索が主流であることである。例をあげるとファッション通販サイトである ZOZOTOWN では「色」「値段」「トップスなどのカテゴリ」などのアイテムの情報で絞り込み検索を行うことができるが、ファッションブランドを探索する際はユーザ側からの視点としてその人の情報（好み、その人がおしゃれだと思ふ価値観など）を考慮した探索支援が必要であると考えられる。

またこれまでファッションブランドは、ショップ

店員・インフルエンサー・雑誌編集者などの専門家によって主観的なラベルが付けられ、分類がなされてきた。例をあげると、専門家により運営されているブランド紹介サイトである High-Brands.com[4]では表 1 に示すようなブランドに関する属性として、21 属性が用意され、これらの属性を用いて各ブランドにラベル付けをし、分類を行っている。ただなぜそのような分類になったのかという根拠が不明瞭なことが多いため、ユーザにとってラベルや分類の意味を理解することがしばしば難解となる。またこのような専門家による分類・ラベル付けは、アイテムのデザインなどファッションの作り手側からの視点が色濃く反映され、そのアイテムを身に着けているのがどのようなユーザなのかなど、ユーザ側からの視点が欠けたものになることがしばしば起こる。

本稿の目的を図 1 に示す。青色のユーザが橙色のユーザのように見られたいという要求があるとき、同じブランドを着用することで橙色のユーザに近づくというアプローチを取ることがある。そのためにはユーザのカテゴリを表現するようなファッションブランドを明らかにすることが求められる。そこで本稿では、ブランドを着ている人で特徴づけ、各ブランドを支持する SNS ユーザの情報を用いたファッションブランドの分析・可視化を行う。

本稿の構成は以下の通りである。まず 2 節でユーザとブランド間の関係性に着目した関連研究を紹介する。3 節ではユーザの支持情報を用いたファッションブランドの分析・可視化手法を提案する。4 節では本稿の提案手法の出力結果を報告し、専門家による分析結果

の紹介と比較を行う．5節ではまとめと今後の課題を述べる．

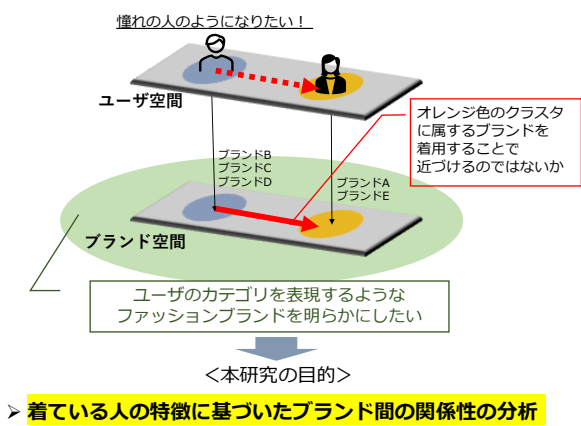


図 1 研究の目的

表 1 High-Brands.com で紹介されている属性

カジュアル	セレカジ	コンサバ	トラッド	アメカジ	ヴィンテージ	ミリタリー
ワーク	ストリート	スポーティー	原宿系	サーフ	アウトドア	エスニック
モード	サロン系	エレガント	フォーマル	お兄系	きれいめ	ロック

2. 関連研究

金光[5]はブランドと消費者の関係性を「ブランドの絆」と捉え、またブランド同士の関係性を測定するためのネットワークモデルとして、消費者とブランドの2部グラフから「ブランドパワー」を測定するモデルを提案している．また金光[6]は文献[5]の発展研究として消費者とブランドの間にライフスタイルを凝集したカテゴリを媒介ノードと仮定し3部構造モデルにまで拡張した手法を提案している．文献[5][6]ではブランド間の関係性を測定するために、ブランド間の関係性の相対的な指標として「ブランドパワー」を定義しているが、その際に消費者のブランド認知データに基づき分析を行っている点とそれに加えてメディアによる情報を用いてブランドを分析している点において意義のある研究である．

またブランドの類似度を測る手法として、コーディネート投稿 SNS である WEAR のタグを利用した手法も提案されている．Hashimoto ら[7]は各ブランドに対してそのブランドのアイテムを用いた投稿についているタグの出現頻度を用いてベクトル化し、そのベクトルを用いてブランド間の類似度を測る手法を提案している．タグはコーディネートに対するユーザの印象であり、そのような客観的情報を用いてファッションブランドを分析するという点において意義のある研究で

ある．

また脇田ら[8]では「年齢」「性別」「身長」「よく着るブランド」の4項目から深層学習を用いたモデルを作成しブランド推薦手法を提案している．

これら紹介した従来研究はアンケートによるブランド選択、ユーザの SNS の投稿内容、身長などのユーザの特徴、といったより客観的根拠に基づいてブランドを特徴づけ、分析を行っている手法であり、ファッションブランドを分析する上での客観的情報の重要性が示唆されている．これらに対し本稿では客観的情報としてユーザが実際にブランドを好み、着用している、すなわち支持しているデータを用いた分析を行い、ブランドを特徴づける．つまりブランドを支持するユーザの集合でブランドを特徴づけ、客観的根拠に基づいた分析、およびそこから得られる類似性の可視化に取り組む．

3. 手法

本節では、ユーザの支持情報を用いたファッションブランドの分析、可視化手法について述べる．

3.1. ユーザのブランド支持情報

本稿で用いるユーザによるブランド支持情報は図 2 のような2部グラフで表される．




図 2 各ユーザの支持ブランドの例

図 2 の例において、ユーザの支持ブランド集合  $S_{Brand}$ 、ブランドの支持ユーザ集合  $S_{User}$  はそれぞれ表 2、表 3 のように表される．

表 2 ユーザの支持ブランド集合  $S_{Brand}$  の例

ユーザ名	支持ブランド
ユーザ V	ブランド A, ブランド B
ユーザ W	ブランド C, ブランド D
ユーザ X	ブランド A, ブランド C
ユーザ Y	ブランド B, ブランド E
ユーザ Z	ブランド B

表 3 ブランドの支持ユーザ集合  $S_{User}$ 

ブランド名	支持ユーザ
ブランド A	ユーザ V, ユーザ X
ブランド B	ユーザ V, ユーザ Y, ユーザ Z
ブランド C	ユーザ W, ユーザ X
ブランド D	ユーザ W
ブランド E	ユーザ Y

また  $S_{User}$  について、ユーザがそのブランドを支持していれば 1、支持していなければ 0 という形で変換し、 $V_{User}$  と表す。図 2 の例では  $V_{User}$  は表 4 のように表される。

表 4 支持ユーザベクトル  $V_{User}$ 

	ブランドA	ブランドB	ブランドC	ブランドD	ブランドE
ユーザV	1	1	0	0	0
ユーザW	0	0	1	1	0
ユーザX	1	0	1	0	0
ユーザY	0	1	0	0	1
ユーザZ	0	1	0	0	0

$V_{User}(A)$

本稿で使用するデータに関する記号を表 5 にまとめる。

表 5 記号について

$S_{Brand}(X)$	ユーザ X の支持ブランド集合
$S_{User}(A)$	ブランド A の支持ユーザ集合
$V_{User}(A)$	$S_{User}(A)$ を表す 2 値変数ベクトル
$C_A$	ブランド A の投稿コメントデータ

### 3.2. 凝集型階層クラスタリング

ファッションブランドのクラスタリングを行うために、ユーザのブランド支持情報を用いて、凝集型階層クラスタリングを実施し、デンドログラムを作成した。凝集型階層クラスタリングでは 1 つの対象だけから成るクラスタがある初期状態から、クラスタ間の距離(非類似度)に基づき、最も距離の近いクラスタを逐次的に併合し、全ての対象が 1 つのクラスタに併合されるまで繰り返すことで階層構造を得る[9]。

またクラスタリングにおいて、ユーザのブランド支持情報から得られるブランド間の共起関係に着目した。本稿においては、あるユーザがともに 2 つのブランドを支持している場合、その 2 つのブランドは共起しているとみなす。そして共起の強さが強いほど、その 2 つのブランドは似ていると捉えることができる。この共起の強さは、2 つの集合間の類似度によって評価することができ、具体的には共起頻度、Jaccard 係数、Simpson 係数などが知られている[10]。それぞれについ

て具体的には、ブランド A、ブランド B の支持ユーザ集合を  $S_{User}(A)$ 、 $S_{User}(B)$  としたときそれぞれ次式で表すことができる。

$$(\text{共起頻度}) = |S_{User}(A) \cap S_{User}(B)|$$

$$(\text{Jaccard 係数}) = \frac{|S_{User}(A) \cap S_{User}(B)|}{|S_{User}(A) \cup S_{User}(B)|}$$

$$(\text{Simpson 係数}) = \frac{|S_{User}(A) \cap S_{User}(B)|}{\min(|S_{User}(A)|, |S_{User}(B)|)}$$

これら 3 つを比較したとき、共起頻度は単独での支持ユーザ数が多いほど類似度が高くなってしまいう問題があり、また Jaccard 係数は単独での支持ユーザ数が多いほど、どのブランドとも類似度が低くなってしまいう問題がある。それに対し Simpson 係数については分母に要素数の最小値をとることで、差集合の要素数による影響をさげ、相対的に共通要素を重視した手法である。したがって、今回は Simpson 係数を用いて類似度の計算を行った。

またクラスタ間の距離(非類似度)を測る手法として、いくつかの手法が提案されているが[9]、今回は群平均法を用いた。具体的にはブランド A、ブランド B の距離  $d(A, B)$  が与えられたとき、クラスタ  $C_1$ 、クラスタ  $C_2$  の距離  $d(C_1, C_2)$  は次式で表される[11]。ここで距離とはクラスタ間の共起していない度合いを表す値であり、本稿では  $1 - (\text{類似度})$  とした。

$$d(C_1, C_2) = \frac{1}{|C_1||C_2|} \sum_{A \in C_1} \sum_{B \in C_2} d(A, B)$$

これは 2 つのクラスタの要素間の距離の平均値である。全てのクラスタが単一の対象で構成された状態から、このクラスタ間の距離が最小になるクラスタを再帰的に併合することで階層構造を得る。

### 3.3. ブランド間ネットワーク図の作成

ブランド間の類似性を視覚的に把握するための可視化として 3.2 節の Simpson 係数を用いて計算した類似度を用いてブランド間ネットワーク図を作成した。ネットワーク図の作成にはネットワーク可視化・分析ツールである Cytoscape(ver 3.9.1)を用いた。またネットワークのレイアウトにはバネモデルに基づく Prefuse Force Directed Layout アルゴリズムを用い、ブランド間の類似度が高いほどノードが近くに、類似度が低いほどノードが遠くに配置されるようにした。

### 3.4. ユーザの投稿コメントデータを用いたラベル付け

専門家がファッションブランドを分類する際に用いるラベルは主観的なものである。例をあげると表 1 で示したように High-Brands.com では 21 個のラベルが用意されている。これらをブランドに対するラベルとして利用したとき、各ブランドに対して適用されたラベルの根拠が不明瞭であり、ユーザはラベルを見たときにブランドの特徴を理解することが必ずしも容易ではない。加えて専門家によるラベル付けはブランドのアイテムの特徴によるラベルに偏りがちであり、支持しているユーザの特徴は反映されにくい。そこで本稿では、実際にそのブランドを好んでいる、または着用している人の特徴や SNS 上での発言を利用する。具体的には投稿コメントデータを tf-idf を用いて計算した上位語をラベルとして適用する。手順としては、まずブランド A の投稿コメントデータ  $C_A$  について Mecab を用いて形態素解析を行い、名詞と形容詞と動詞のみを取り出し、多重集合  $C'_A$  に変換する。ここで多重集合とは要素の重複を許容した集合概念である。各ブランドに対する多重集合  $C'_A, C'_B \dots$  の各要素  $c'_a, c'_b \dots$  に対し tf-idf 値を計算する。具体的には次式で表される。ここで idf の計算式についてはいくつか定義されているが、今回は Python の TfidfVectorizer を用いて計算を行った。

$$\text{tf-idf 値} = \text{tf} \cdot \text{idf}$$

$$\text{tf} = \frac{(C'_A \text{ における要素 } c'_a \text{ の出現頻度})}{(\text{文書 } C'_A \text{ における全単語の出現頻度の和})}$$

$$\text{idf} = \log \frac{(\text{全文書数}) + 1}{(\text{単語 } c'_a \text{ を含む文書数}) + 1} + 1$$

最後に  $C'_A, C'_B \dots$  の各要素  $c'_a, c'_b \dots$  がもつ tf-idf 値の上位語 5 つをブランドのラベルとして適用する。

### 3.5. 実データについて

本稿では、ユーザのブランド支持情報、および投稿コメントデータとしてファッションコーディネート投稿 SNS である WEAR のデータを用いた。図 3 に示す WEAR 人気 10,000 ユーザのプロフィール欄の「お気に入りブランド」と「よく着用するブランド」の和集合を取ったものをそのユーザの支持ブランド集合  $S_{Brand}$  とする。ここで「よく着用するブランド」に加えて「お気に入りブランド」も含めて支持情報としたのは「好んではいるが、頻繁には着ない」ようなブランドもユーザの支持が得られていると考えたためである。また

これは 2021 年 10 月 20 日に取得した。また本稿では分析対象のブランドとして、ブランドを支持する 100 名以上であり、かつ High-Brands.com 掲載の 82 ブランドに限定した。

また本稿でのブランド A の支持ユーザベクトル  $V_{User}(A)$  は 10,000 次元からなる 2 値変数ベクトルである。

最後に 3.4. 節で使用した投稿コメントデータ  $C$  についてである。WEAR ではユーザが自分のコーディネート写真を投稿する際に、「どのブランドを着用しているのか」と「そのコーディネートを解説するようなコメント」も一緒に投稿している(図 4)。そこで  $C$  は WEAR で各ブランドに対して、そのブランドのアイテムを用いた投稿の人気コーディネート 135 件のコーディネート紹介コメントを収集した(2021 年 11 月 30 日時点)。ブランド A に対し 135 件収集されたコメントを結合したものが  $C_A$  である。



図 3 WEAR プロフィール



図 4 WEAR の投稿とコーディネート紹介コメント

## 4. 評価

### 4.1. 結果

3.2. 節で述べたブランドの支持ユーザ集合  $S_{User}$  を用いた階層クラスタリングにより出力されたデンドログラムを図 6 に示す。ここでデンドログラムとは、各終端ノードが各対象を指し、併合されてできたクラスタ



を非終端ノードで表した 2 分木である．またデンドログラムの横軸は併合されたときのクラスタ間の非類似度(距離)を表す[9]．デンドログラムを作成する際の色分けの距離閾値はクラスタが 10 個になるように 0.93 にした．また距離 0.0 でつながっているブランド対が 21 対発見されたが、これは一つのブランドを支持する人は必ずもう一つブランドも支持しているという関係である．

次に 3.3.節で述べたブランド間ネットワーク図を図

5 に示す．ネットワーク図の各ブランドに対するノードの色は図 6 のデンドログラムで発見された色を付与している．‘UNIQLO’、‘GU’、‘NIKE’のように多くのブランドと高い類似度を持つブランドが中心に配置された一方で、他の多くのブランドが周辺に配置される結果となった．また図 5 左上あたりに桃色のクラスタ、左下辺りに橙色のクラスタを発見することができたが、すべてのクラスタが近くに配置されるようなネットワーク図は得られなかった．

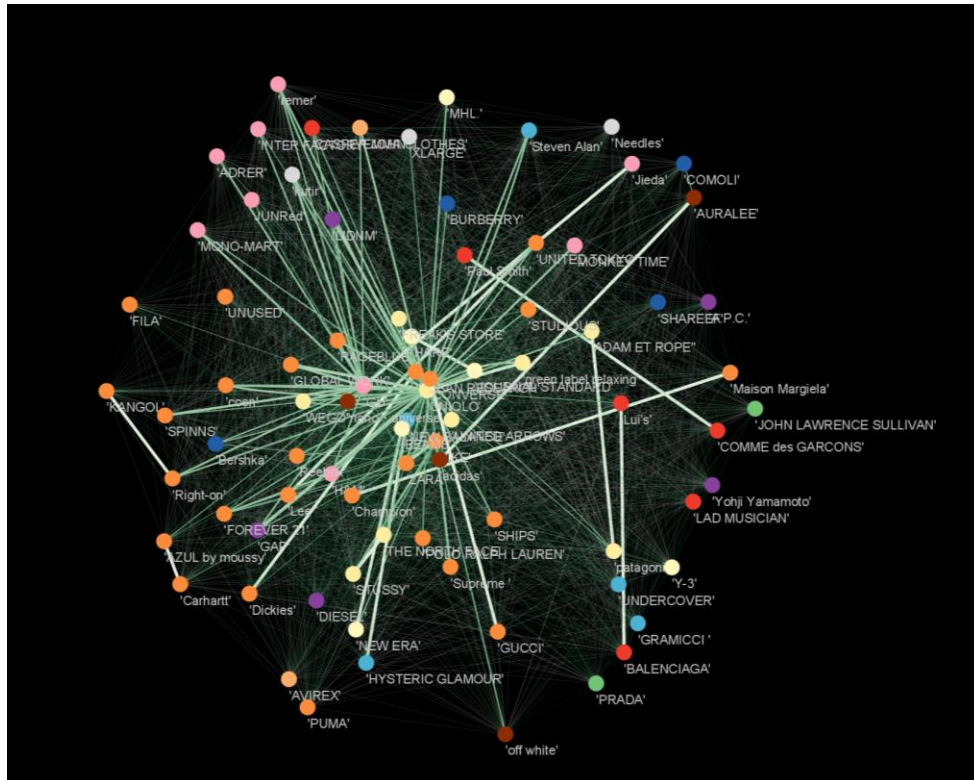


図 5 ブランド間ネットワーク図

図 6 に登場するクラスタに対して、3.4.節で述べた投稿コメントデータ  $C$  を用いて tf-idf 値を計算し、上位語をラベルとして適用した結果を表 7 に示す．これらについては、「上品」など着用する人の特徴や理想像を示した要素や、「カーディガン」、「マフラー」などのアイテム名の要素、「デート」のような、どの場面でそのブランドを着用しているかを示した要素など、一目見ただけでそのクラスタに属するブランドがどのようなブランドなのかということが理解できるようなラベルが発見された．また図 6 のデンドログラムにはここで作成したラベルを付与してある．

## 4.2. 専門家による分析手法

本節では、本稿の手法であるユーザの支持情報を用いた客観的なファッションブランドの分類方法の比較

手法として、専門家による主観的な分析手法を示す．本稿では専門家の見解としてブランド紹介サイトである High-Brands.com を採用した．本サイトはショップ店員などで運営されているサイトであり、専門家の意見としては適していると判断した．High-Brands.com では、ファッションブランドに対して表 1 に示したような属性を 21 個用意されており、例えば「モード」はユニークで個性的なファッションスタイルとして紹介されている．

High-Brands.com では、これら 21 属性を用いて、表 6 に示すような形でブランドの特徴づけをしている．そこで 3.2. 節で述べた手法の支持ユーザ集合  $S_{User}$  の代わりにこの属性集合を用いてデンドログラムを作成した．その結果を図 7 に示す．デンドログラムを作成する際の色分けの距離閾値はクラスタが 10 個になるよ

うに 0.68 にした。

また専門家による分類にラベル付けをするため表 6 に示される各ブランドに対する属性情報をクラスタごとに用いて tf-idf 値を計算した結果を表 8 に示す。これは図 7 中で発見されたクラスタに上から順に tf-idf 値を計算した結果である。例を挙げると、クラスタ①' に対しては「スポーティー」というラベルが適用されていることがわかる。また図 7 のデンドログラムにはここで作成したラベルを付与してある。

表 6 High-Brands.com での属性集合の例

ブランド名	属性
DAIRIKU	カジュアル,トラッド,アメカジ,ストリート
TTT MSW	カジュアル,トラッド,原宿系,モード
OUR LEGACY	カジュアル,トラッド,エレガント
Comme des GARCONS	モード,サロン

#### 4.3. ユーザの支持情報による分類と専門家による分類との比較

図 6 に示したユーザの支持情報を用いたデンドログラムと図 7 に示した High-Brands.com の属性情報を用いたデンドログラムを比較する。図 6 では、古着を好んで着用する人たちの間で特に支持されているブランド同士(例えば図 6 中のクラスタ①における「Maison Margiela」,「Champion」,「CONVERSE」)でクラスタを形成していることが確認された。またハイブランドやメゾンブランドと呼ばれるような価格の高いブランド同士(例えば図 6 中のクラスタ⑧における「COMME des GARCONS」と「BALENCIAGA」), ミドルブランドやファストファッションブランドのような比較的の手に取りやすい価格のブランド同士(例えば図 6 中のクラスタ⑤における「H&M」,「GU」,「MONO-MART」), 大手セレクトショップの出すオリジナルブランド同士(例えば図 6 中のクラスタ③における「JOURNAL STANDARD」と「BEAMS」)でクラスタを形成していることが確認された。これについてはそもそもユーザの財政状況によりブランド選択が大きく左右されると考えられ、ユーザ本来の趣向のみによる支持や選択ではなく、自分の買える範囲で好きなブランド選択を行い、購買しているため価格の影響が強く反映されているのだと考えられる。また図 7 では High-Brands.com の属性情報を用いたため、アイテムの特徴による分類が行われていた。High-Brands.com ではブランドのアイテムの特徴や、ブランドのルーツに基づき属性を割り当てた分類を行っているため、同じ外見や特徴のアイテムを出すブランドは、価格が異なっても同じ属

性と分類される。つまりユーザ側の購買状況や資金力は考慮されていない分類である。したがって図 6 のユーザのブランド支持情報を用いた分類と図 7 の High-Brands.com の専門家による属性の分類を比較したときに、大きく違う結果が得られたのだと考えられる。このことから本稿での分類ではユーザの好みや資金力などのユーザの特徴による分類を行うことができたといえる。

また「UNUSED」,「URBAN RESEARCH」,「UNITED TOKYO」の組のようにいずれのデンドログラムでも同一クラスタ内に現れるブランドも見られた一方、「JOHN LAWRENCE SULLIVAN」と「JUNRed」のように図 7 の専門家による結果では低い非類似度で結合しているのにもかかわらず、図 6 のユーザの支持情報による結果では異なるクラスタに属しているブランドが多く発見された。

これらのことより、従来の専門家によるブランドの表現では得られなかったブランドの特徴が本稿の分析によって得られたと考えられる。

#### 5. まとめ

本稿ではユーザの支持情報を用いたブランドの分析・可視化を実施した。特にユーザの支持情報を用いたデンドログラムから得られるブランド間の関係性は興味深いものが得ることができた。4.3.節での比較によりわかったように、購買、支持、選択、趣向の違いを検討し、データとして反映させ、どのようにブランド間の類似性を測るかも今後の課題である。

また類似性に関する分析としては不十分である点も多い。例えば本稿の結果をブランド探索支援システムに応用した場合、従来の探索支援システムと比べ、ユーザの満足度が高くなるかどうかは未知数である。また現状では WEAR 人気ユーザ 1 万人のなかでも支持の多いブランドについてのみを分析対象としたが、ブランドの数は無数にあり、支持の少ないようなニッチなブランドも含め、それらの関係性をどのように分析するのかについても今後の課題である。

可視化に関する課題も多い。今回得ることを目標としていたブランド間マップとしては、図 6 のデンドログラムのクラスタリング結果を反映したものであったが、プロットされた点がまばらになってしまい、目標としていたマップを得ることができなかった。次元圧縮は様々な手法を組み合わせるなど、提案されている手法は様々あり、本稿の対象であるファッションブランドと、ユーザの支持情報に適した手法を発見し、どのように実装するのかも今後の課題である。

表 7 投稿コメントデータ  $C$  を用いた図 6 中のクラス  
タに対するラベル

クラスタ①		クラスタ②		クラスタ③	
要素	tf-idf値	要素	tf-idf値	要素	tf-idf値
古着	0.263	馴染み	0.209	生地	0.192
パーカー	0.192	おっさん	0.164	マフラー	0.167
コーデュロイ	0.098	デート	0.164	上品	0.159
マフラー	0.095	寒い	0.151	万能	0.156
ワイド	0.093	土日	0.135	着心地	0.134
クラスタ④		クラスタ⑤		クラスタ⑥	
要素	tf-idf値	要素	tf-idf値	要素	tf-idf値
身長	0.142	お洒落	0.229	国内	0.333
青色	0.128	マフラー	0.196	限定	0.235
ステッチ	0.128	トレンド	0.169	切り替え	0.215
モヘア	0.127	モノトーン	0.163	気軽	0.181
革靴	0.122	幅広い	0.144	遊び	0.162
クラスタ⑦		クラスタ⑧		クラスタ⑨	
要素	tf-idf値	要素	tf-idf値	要素	tf-idf値
お洒落	0.279	優しい	0.256	モモンガ	0.352
オリーブ	0.207	デート	0.156	パジャマ	0.257
パーカー	0.155	モノトーン	0.124	それなり	0.196
実用	0.148	生地	0.115	楽ちゃん	0.176
ミックス	0.142	デビュー	0.107	柔らか	0.156
クラスタ⑩					
要素	tf-idf値				
タートルネック	0.311				
気軽	0.282				
着心地	0.225				
綺麗	0.169				
ストーリー	0.155				

表 8 High-brands.com の属性情報を  
用いた図 7 中の  
クラスタに対するラベル

クラスタ ①'		クラスタ ②'		クラスタ ③'	
要素	tf-idf値	要素	tf-idf値	要素	tf-idf値
スポーティー	0.518	カジュアル	0.476	お兄系	0.618
アメカジ	0.387	フォーマル	0.399	カジュアル	0.412
カジュアル	0.386	ストリート	0.397	きれいめ	0.367
ヴィンテージ	0.324	原宿系	0.355	サロン	0.301
ストリート	0.322	セレカジ	0.318	ヴィンテージ	0.231
クラスタ ④'		クラスタ ⑤'		クラスタ ⑥'	
要素	tf-idf値	要素	tf-idf値	要素	tf-idf値
カジュアル	0.496	アウトドア	0.541	アメカジ	0.554
モード	0.495	ワーク	0.439	カジュアル	0.554
きれいめ	0.442	サロン	0.398	ストリート	0.462
アメカジ	0.331	アメカジ	0.363	アウトドア	0.413
コンサバ	0.246	モード	0.363		
クラスタ ⑦'		クラスタ ⑧'		クラスタ ⑨'	
要素	tf-idf値	要素	tf-idf値	要素	tf-idf値
サロン	0.413	モード	0.599	エスニック	0.519
アメカジ	0.373	サロン	0.567	モード	0.461
トラッド	0.333	カジュアル	0.368	原宿系	0.343
エレガント	0.313	ストリート	0.245	スポーティー	0.308
カジュアル	0.311	トラッド	0.197	セレカジ	0.308
クラスタ ⑩'					
要素	tf-idf値				
カジュアル	0.457				
サロン	0.418				
モード	0.381				
ストリート	0.317				
コンサバ	0.227				




図 6 ブランドの支持ユーザ集合  $S_{Brand}$  を用いたデンドログラム




図 7 High-Brands.com の属性情報を用いたデンドログラム

## 参 考 文 献

- [1] 経済産業省 商務情報政策局, “情報経済課産業経済研究委託事業 (電子商取引に関する市場調査報告書)”, 2021.
- [2] Si Liul, Jiashi Feng, Zheng Song, Tianzhu Zhang Hanqing Lu, Changsheng Xu, Shuicheng Yan, “Hi, Magic Closet, Tell Me What to Wear!”, MM’12: Proceedings of the 20th ACM international conference on Multimedia, pp. 619-628, 2012.
- [3] Andreas Veit, Balazs Kovacs, Sean Bell, Julian McAuley, Kavita Bala, Serge Belongie, “Learning Visual Clothing Style with Heterogeneous Dyadic Co-occurrences”, International Conference on Computer Vision (ICCV), 2015.
- [4] High-Brands.com ~ハイブランド.com~, <https://high-brands.com>, 閲覧日: 2022 年 1 月 8 日
- [5] 金光淳, “ブランド・パワー測定とブランド・ポートフォリオのための ネットワーク・モデル”, 京都マネジメント・レビュー(12), pp. 151-160, 2007.
- [6] 金光淳, “ライフスタイル・カテゴリーのペルソナ化を利用した三部グラフモデル——ハイ・ファッション・ブランドの選択構造”, 京都マネジメント・レビュー(20), pp. 93-109, 2012.
- [7] Natsuki Hashimoto, Marie Katsurai, Ryosuke Goto, “A Visualization Interface for Exploring Similar Brands on a Fashion E-Commerce Platform”, Proceedings of 2021 International Conference on Web Services (ICWS2021), pp. 642-644, 2021.
- [8] 脇田夕嘉, 奥健太, 川越恭二, “深層学習を用いたファッションブランドの推薦システムに向けて: 予備解析”, DEIM 2016, 2016.
- [9] 神嶋敏弘, “データマイニング分野のクラスタリング手法(1)-クラスタリングを使って見よう!-”, 人工知能学会誌 2003 年 1 号, pp. 59-65, 2003.
- [10] 松尾豊, 友部博教, 橋田浩一, 中島秀之, 石塚満, “Web上の情報からの人間関係ネットワークの抽出”, 人工知能学会誌 2005 年 1 号, pp. 46-56, 2005.
- [11] 元田造, 津本周作, 山 高平, 沼尾正行, “データマイニングの基礎”, オーム社, 2006.