

チラシ媒体通販における商品の販売数予測

福島 航平[†] 大島 裕明^{††}

[†] 兵庫県立大学 大学院応用情報科学研究科 〒650-0047 兵庫県神戸市中央区港島南町 7-1-28

^{††} 兵庫県立大学 大学院情報科学研究科 〒650-0047 兵庫県神戸市中央区港島南町 7-1-28

E-mail: [†]{aa17c507,ohshima}@ai.u-hyogo.ac.jp

あらまし 本研究では、チラシ媒体通信販売において、ある商品の販売数がどの程度になるかを予測する手法を提案する。過去の販売履歴データを基にしたニューラルネットワークモデルの学習を行うことで提案手法を構築する。チラシ媒体通販においては、実際にどの程度注文されるかをあらかじめ予測して、商品の調達を行う必要がある。特に、仕入数量が実際の注文数に対して少ない場合には、緊急で入荷する必要が生じるため大変なコストとなるという問題がある。そのため、実務的に適切な調達計画を行うための手法を検討する。

1 はじめに

販売予測は企業の施策を決定する上で重要な意味を持ち、各業界で様々な手法が検討されている。一般的に販売予測は、ある条件で商品を販売した場合の予測販売数量を出力する手法を構築する。しかし、企業の販売形態によっては、単純に販売数量を予測するだけではなく、実販売数になるべく下回らないうえで、過剰に予測しすぎない予測値を出力するような欠品率（予測が実販売数を下回る割合）を考慮した実務的な手法が必要な場合がある。生活協同組合（以下、生協）におけるチラシ媒体通信販売は、消費者に毎週チラシが配布され、週毎に注文が行われるという販売形態である。そのような販売形態において、生協に商品を納品するサプライヤはその週に配布されるチラシ媒体に掲載された商品がどの程度注文されるかをあらかじめ予測し商品調達を行う必要がある。生協におけるチラシ媒体通信販売では、どの程度の売上が見込めるかといった予測販売数量である計画数と呼ばれるものが、あらかじめサプライヤに提供されている。その計画数は、媒体内での商品が掲載される位置や大きさ、掲載されるページ内の他の商品との関係といった紙面特有の特徴が増減の大きな要因であると考えられている。計画数はそのような要因を考慮して販売予測が行われており、サプライヤはその計画数に応じて商品の調達を行っている。本研究では、生協におけるチラシ媒体通信販売での欠品率を考慮した実務的な販売予測の手法を検討する。手法の構築にあたって、まずは単純に販売数量を予測するモデルを構築した。次に、欠品率を考慮した予測販売数量を出力するモデルを構築し、単純に販売数量を予測をするモデルとの予測結果の比較を行った。

2 関連研究

売上予測は様々な業界で行われてきており、その手法についても多岐に渡る。近年は Qi ら [6] の研究のように深層学習を用いたニューラルネットワークの売上予測モデルを構築する手法が多く研究されている。また、深層学習を用いたニューラルネットワークの予測モデルの構築以外にも張ら [9] のように、

アパレル企業の過去の売上データを非定常的な時系列データとして、ある期間の売上を逐次 SARIMA モデルを用いて分析するような研究も行われている。そして、品目（靴やコートなど）によって SARIMA モデルの精度は異なり、品目によって予測可能性に差があることが確認されている。というように、扱う商品の種類によって予測モデルの精度を比較するというも行われている。他にも、Gevorgyan ら [2] は相関分析や回帰分析、フーリエ変換等を用いて過去の販売データを分析して予測モデルを構築したり、また Liang ら [5] は、XGboost や LightGBM アルゴリズムを用いて、過去の販売データを分析し、予測モデルを構築する手法を提案している。一つの手法での予測だけでなく複数の手法を組み合わせた結果の平均をとるような予測の方法の研究として Dong ら [1] の研究がある。インターネット通信販売の販売データに基づく売上数量の予測において、LR (Linear regression), XGBoost, LightGBM の 3 つの手法の予測値の平均を最終的な予測値とすることで、個別手法の予測結果より良い予測精度が得られたというように、複数の手法を組み合わせた結果の平均をとるような予測の方法 (Model Fusion) による予測精度の向上といったことも提案されている。従来の手法を改善し、予測精度を改善する手法の研究として、Ji ら [4] の研究がある。ARIMA モデルの残差をバックプロパゲーションニューラルネットワークで学習させ、フィットさせることで、構築した予測モデルは、ARIMA モデル単体での場合より予測精度が向上した。この研究の結果では、ARIMA モデルとバックプロパゲーションニューラルネットワークを組み合わせで構築したモデルは、ARIMA モデル単体での予測結果と比較して、平均誤差が 10.4% 減少と予測精度を向上させている。売上予測において、過去のデータを基準に予測を行う際、新しく販売する商品についてはその過去のデータがない為、予測が難しい。今井ら [8] は、新商品発売時の売り上げ分析について試供品の利用率やその頻度から予測するモデルを構築した。また、商品の売り上げ分析時には消費財か耐久消費財かでモデルが分かれることが多いが、消費財の中でも、個人が使用するものと家庭や家族用に使用するものでモデルを分けることでより精度の高いモデルを構築した。実務的な観点で販売予測モデル




図 1 週別合計売上金額の推移

の運用を考える研究も行われており、深層学習を用いたニューラルネットワークの予測モデルの構築後は、そのモデルの更新のタイミングや、その更新に必要な学習データの期間の決定等、予測精度を維持する工夫が必要であるが、予測モデルの再学習のサイクルの研究がある。谷本ら [7] は、モデルの更新頻度と予測精度の間にはトレードオフの関係にあり、大量予測モデルを運用する際は、定期更新よりも精度劣化状況を監視し、精度劣化が確認された時点でモデルの更新を行う方が高い精度で運用できると報告している。売上予測モデルの構築を行い、売り上げの予測が行われるようになると、実務的には予測モデルの入力と出力の関係から、価格シミュレーション等を行う必要が出てくることがある。伊藤ら [3] は処方的価格最適化を用いた粗利改善の研究を行った。そこでは、機械学習によって複数商品の売上予測式を構築し、そこから売上と価格の複雑な関係を明らかにし、その予測式に基づいて、最適化問題を構築した。その最適化問題は、二項二次計画法 (BQP) の一例として定式化できることを提示し、半正定値計画法 (SDP) 緩和を用いた高速な近似アルゴリズムを用いた手法によるシミュレーションと実小売店データを用いた実験により、実用的な計算時間で数十から数百の商品の最適価格を同時に導き出し、それらの商品の粗利益を約 30% 改善する可能性があることを示している。

3 販売データと販売予測問題の定義

本研究に用いるデータは、ある生協のチラシ媒体通信販売の過去の販売データである。

3.1 販売データの分析

生協の販売形態として、1 週間毎に消費者へとチラシ媒体が配布され、注文が行われる。この注文とチラシ配布のサイクルが 1 年を通して行われ、1 年で 52 週販売が行われている。このように週次でチラシの配布と注文が行われることから、販売データの販売数の単位も、1 つの商品が 1 週で売り上げられた合計となっている。本研究で利用した販売データ全体 (3 年分) の売上金額を週毎に集計したものが、図 1 である。週毎の平均売上金額は、16,867 千円となっており、合計売上金額が最小の週は 2019 年 12 月 5 週で、1,569 千円、合計売上金額が最大の週は、2018 年 12 月 3 週で、62,034 千円である。

表 1 商品カテゴリ別レコード数、平均販売単価

カテゴリ名	レコード数	平均販売単価 (円)
化粧品	1,004	1,559
キッチン消耗	902	542
生活用品	825	3,262
耐久消費財	633	1,993
衣料・身の回り品	589	3,061
水回り用品	584	912
キッチン用品	461	1,175
家庭消耗品	378	632
衛生・介護用品	364	803
ボディケア	237	628
趣味娯楽	160	1,464
洗剤	150	680
オーラルケア	124	616
寝具	8	5,847
その他雑貨	6	298

また、週毎の販売データ数は、平均 40 レコードであり、最小レコード数は、2018 年 12 月 5 週の 6 レコードであり、最大レコード数は、2019 年 11 月 4 週の 82 レコードである。年末年始は、例年販売商品数が少なくなる傾向にある。データセット全体のレコード数は、6,425 レコードであり、1 レコードあたりの平均売上金額は 414 千円、最大売上金額は、11,907 千円、最小売上金額は 298 円である。1 レコードあたりの平均販売数量は 581 点、最大販売数量は 26,580 点、最小販売点数は 1 点である。1 レコード辺りの平均販売単価は、1,560 円、最大販売単価は、31,000 円、最小販売単価は 90 円である。販売されている商品の種類 (カテゴリ) については、雑貨全般が含まれている。表 1 はカテゴリの一覧とその平均単価である。データセット内で最も多く販売されている商品カテゴリは、化粧品の 1,004 レコードであり、次にキッチン消耗が 902 レコード、生活用品が 825 レコード、耐久消費財が 633 レコード、衣料・身の回り品が 589 レコードと続いており、販売されている商品は主に、家庭内で使用されるものである。カテゴリ別の平均単価は、寝具が 5,847 円と一番高価なカテゴリであり、次に生活用品 (主にスリッパ等) が 3,262 円である。低価格帯のカテゴリはキッチン消耗が 542 円、その他雑貨 (飾り付け用シール等) が 298 円である。このように繰り返し使用する耐久消費財と、消耗品で平均単価が異なっている。

それぞれのアイテムの価格帯は、表 2 及び図 2 にあるように 1,000 円以下の価格帯までの累積構成比率が約 57% であり、2,000 円以下が約 86%、10,000 円以下が約 99% である。このことから、販売されている商品の大半が 2,000 円以下の商品である。

上記で述べた商品カテゴリや販売単価以外の販売データの各特徴をまとめたものが表 6 である。

3.2 計画数の特徴

生協の販売データの特色として、生協がサプライヤに提供している予測販売数量である計画数という特徴がある。これは、具体的な方法は開示されていないが、販売が予定されている商




図2 価格帯別レコード数及び累積構成比率グラフ

表2 価格帯別レコード数及び累積構成比率表

価格帯 p (円)	レコード数	累積構成比率 (%)
$0 < p \leq 100$	16	0.25
$100 < p \leq 500$	1,161	18.32
$500 < p \leq 1,000$	2,457	56.56
$1,000 < p \leq 2,000$	1,872	85.70
$2,000 < p \leq 3,000$	475	93.09
$3,000 < p \leq 4,000$	90	94.49
$4,000 < p \leq 5,000$	102	96.08
$5,000 < p \leq 10,000$	178	98.85
$10,000 < p \leq 20,000$	48	99.60
$20,000 < p \leq 100,000$	26	100.00

表3 計画数と実販売数の統計量 (単位: 個)

計画数の平均	620.7
実販売数の平均	581.2
計画数の標準偏差	1,251.9
実販売数の標準偏差	1,640.9
計画数-実販売数の平均絶対誤差	227.9
計画数-実販売数の0の数	34

品毎に販売予測数量が設定されている。つまり、計画数は、生協の販売予測数量ということになるが、その計画数がサプライヤが事前に商品を調達する際の数量の目安となっている。

その計画数について、実際に注文があった実販売数と比較して統計量を確認すると表3のようになっている。計画数と実販売数の平均値を比較すると、計画数の方が大きいことがわかる。計画数と実販売数の販売数量の平均絶対誤差は227.9とそれぞれの平均値と比較しても、計画数と実販売数の差が大きいことがわかる。その計画数と実販売数との差について、差の大きさ毎の分布についてまとめると、表4より、-600から600の範囲に5,828件と全体の90.7%以上が分布しており、更に、表5からわかるように、-200から200の範囲に、約69.1%が分布している。また図3図4から、データが0以上に多く分布していることから、実販売数よりも少し大きく計画数が設定されていることが確認できる。

3.3 販売予測問題の定義

生協の販売データを用いた販売予測について、一般的な販売予測と欠品率を考慮した実務的な販売予測を、

表4 計画数と実販売数の差 (x) のヒストグラム
-3,000 から 3,000 (単位: 個)

範囲	データ件数
$-3,000 \leq x < -2,400$	6
$-2,400 \leq x < -1,800$	23
$-1,800 \leq x < -1,200$	59
$-1,200 \leq x < -600$	166
$-600 \leq x < 0$	1,987
$0 \leq x < 600$	3,841
$600 \leq x < 1,200$	253
$1,200 \leq x < 1,800$	55
$1,800 \leq x < 2,400$	11
$2,400 \leq x \leq 3,000$	6
データ個数合計	6,407

表5 計画数と実販売数の差 (x) のヒストグラム
-200 から 200 (単位: 個)

範囲	データ件数
$-200 \leq x < -160$	109
$-160 \leq x < -120$	172
$-120 \leq x < -80$	172
$-80 \leq x < -40$	333
$-40 \leq x < 0$	722
$0 \leq x < 40$	1,232
$40 \leq x < 80$	654
$80 \leq x < 120$	429
$120 \leq x < 160$	345
$160 \leq x \leq 200$	274
データ個数合計	4,442




図3 計画数と実販売数の差のヒストグラム
範囲-3,000:3,000 (単位: 個)




図4 計画数と実販売数の差のヒストグラム
範囲-200:200 (単位: 個)

- 販売数量予測問題
 - 欠品率を考慮した販売数量予測問題
- という2つの問題として定義する。
- 販売数量予測問題では、数量の予測を行うモデルを構築する。

表 6 販売データの特徴一覧

特徴名	例	詳細
媒体番号	A	チラシ媒体の種類を示す区分
ロケーション	上段	掲載ページ内の位置の区分
価格パターン	通常価格	価格の種類を示す区分（特別価格、年間最安値など）
ブランド	プライベート	ブランドの種類を示す区分
仕入先名	丸藤	商品の販売元
部門コード	日用消耗	商品の分類（日用消耗、雑貨など）
ライン G	ペーパー類	部門コードの下層項目（ペーパー類、耐久消費財など）
ライン	ティッシュペーパー	ライン G の下層項目（ティッシュペーパー、防災用品など）
サブライン	ボックスティッシュ	ラインの下層項目層項目（ボックスティッシュ、避難グッズなど）
品種	レギュラー 160 組	サブラインの下層項目（レギュラー 160 組、備蓄用など）
販売価格	258	消費者への販売価格
掲載枠数	0.9	チラシ媒体上の掲載の大きさ
ページ数	41	掲載されているページの番号
計画数	900	人間が予測した販売数量
年	2018	販売された年
月	4	販売された月
週	1	販売された週、月の中で第何週目に該当するか

入力を将来の販売データとしたとき、その販売データの商品が何個売れるかを出力する販売数量の予測モデルを構築する。計画数を含む訓練データで学習した予測モデルと、計画数を含まない訓練データで学習した予測モデルとの精度の比較を行う。

欠品率を考慮した販売数量予測問題では、経済的損失を考慮した実務的な予測を行うモデルを構築する。こちらは、アプリケーション的な問題であるが、実際の販売数量の予測等を行う際には、理想な出力としてアイテムの物理的な大きさや、発注から仕入までのリードタイム、返品可否等、全ての経済的利益を反映したものとなっていることが望ましい。しかし、それらを全て反映することは難しい。単純にモデルの予測販売数量が、実販売数とどれだけ近いかを評価とする場合。モデルの予測が実販売数を下回る場合でも、実販売数にどれだけ近いかが重要となる。しかし、実際の業務では、経済損失の観点から実販売数に近い数字でも予測が実販売数を下回るよりは、ある程度数量の差があっても、実販売数を上回る方が良い予測といえる。これは、商品の再手配や短いリードタイムでの納品など、人的コストが余分に発生するよりは、ある程度余剰在庫を持つ方が効率的だと考えられるからである。したがって、実販売数にできるだけ近いが少し実販売数を上回るように予測し、かつ、余剰となる金額を少なく予測するモデルを構築できるかが重要となる。そのような予測に取組む際は次の2点を考慮する必要がある。1点目は、欠品率をどれだけ小さくできるか、2点目は、金額的に実販売数を上回る部分をどれだけ小さく抑えることができるか。といった点である。しかし、上記2点はトレードオフの関係にあるため、欠品と余剰のそれぞれの損失をどの程度許容できるのかを判断する指標となるようなモデルの構築が必要となる。

4 ニューラルネットワークを用いた販売予測手法

販売予測モデルの構築手法としては、ニューラルネットワー

クを用いた方法が考えられる。

4.1 販売数量予測のモデル構築方法

予測販売数量を出力するモデルの構築方法として、過去の実販売データを用いて、ニューラルネットに学習を行うことで、販売予測モデルを構築することが考えられる。この際に、いくつかの損失関数を用いて、モデルを構築し、それぞれのモデルにおいて予測販売数量と実販売数との平均絶対誤差（MAE）及び予測販売金額と実販売金額の平均絶対誤差（MAE）を求めて評価を行う。また、モデルの予測数量と計画数との性能を比較することで計画数を上回る性能が得られたかどうか検証を行う。

次に、学習に用いるニューラルネットワークの各層の構成について述べる。中間層は全結合層と活性化関数 relu を組み合わせた層とする。出力層はサイズを 1 とする。Optimizer には Adam を利用する。また、モデルの学習時には、EarlyStopping を用いて過学習を防止する。また入力データはミニバッチとして取り出し、学習の停滞が起こりにくくする。今回はバッチサイズ 256 でデータを取り出しニューラルネットワークへの入力を行う。入力データの前処理について、量的な特徴については標準化し、カテゴリカルな特徴については one-hot エンコーディングを行うが、月や週などの周期性を持つ特徴については、三角関数を各特徴に適用し、周期性を表現する。

4.2 欠品率を考慮した販売数量予測モデル構築方法

欠品率を考慮した販売数量予測を実現する方法として、ニューラルネットワークに学習を行う際に、損失関数において工夫を考える。例えば、欠品となるように予測したときに損失が大きくなるように損失関数に重みを持たせることで、欠品率が小さくなるような予測を行うモデルが構築できると考える。そして、工夫した損失関数の重みを変動させて複数のモデルを構築し、それぞれのモデルの欠品率と予測売上金額と実売上金額の平均絶対誤差の2点を評価する。これにより、欠品率を下げるこ

と過剰に予測されることのトレードオフの関係において、サブライヤが許容できるリスクに応じて、どの重みを用いるかという選択肢を示すことができると考える。

5 PyTorch を用いた実装

本章では本研究で構築した販売予測モデルの実装について述べる。

まず、データセットのそれぞれの特徴においてニューラルネットワークモデルに学習を行うデータの前処理を以下のように行った。データの前処理としては、カテゴリカルな特徴を one-hot エンコーディングし、量的な特徴の標準化を行った。カテゴリカルな特徴を one-hot エンコーディングを行った際の各特徴の次元数は、媒体番号が 10 次元、ロケーションが 3 次元、価格パターンが 6 次元、ブランドマークが 3 次元、仕入先名が 3 次元、部門コードが 2 次元、ライン G は 9 次元、ラインは 6 次元サブラインが 13 次元、品種が 12 次元に変換され、合計 67 次元となった。量的な特徴は、訓練データで変換式を作成し、訓練データ、検証データ及び評価データの標準化を行った。量的な特徴の数は、販売価格、掲載枚数、ページ数、計画数、年、月、週の 8 つの特徴を標準化した。週と月の特徴は三角関数を使用して変換し、それぞれ \sin と \cosine の 2 つずつの、循環性を持った特徴となるように変換を行った。各データセットのレコード数は、訓練データ 5,783 レコード (2017 年 3 月から 2019 年 11 月)、検証データが 172 レコード (2019 年 12 月)、評価データが 470 レコード (2020 年 1 月から 2020 年 3 月) となった。上記の期間で分割した訓練データと検証データと評価データが、データ前処理後のカテゴリカルな特徴と量的な特徴を合わせて、76 次元のサイズとなった。

5.1 販売数量予測問題における実装

上述したデータセットを用いて、各問題の実験を行うためのニューラルネットワークの実装を行った。まずは販売数量予測問題の実験のために行ったニューラルネットワークの実装について述べる。本研究の実験では PyTorch の `torch.nn`, `torch.optim`, `Dataset`, `DataLoader` を用いてニューラルネットワークの構築と学習を行った。ニューラルネットワークの構成は、中間層が 1 層と出力層が 1 層の 2 層とし、中間層は全結合層と活性化関数を `torch.nn.ReLU` を用いて訓練データのサイズを入力サイズとし、256 次元の出力を行うものとし、出力層は入力が 256 次元で出力が 1 次元となる全結合層となるように設定を行った。また、`EarlyStopping` をエポック数を 150, `patience` が 10 となるように実装し、ニューラルネットワークの学習時において過学習が起これにくくなるよう考慮した。活性化関数については、`torch.optim` の Adam を使用し、実験時の学習の進捗によって学習率の調整を行った。損失関数については、`torch.nn` の `L1Loss` を使用し販売数量の平均絶対誤差 (MAE) と売上金額の平均絶対誤差 (MAE) の二つの損失関数を用いてそれぞれモデルを構築した。また、学習時には訓練データをミニバッチに分割して、学習を行った。ミニバッチデータの作

成は `torch.utils.data` の `DataLoader` を用いてバッチサイズが 256 となるようにデータの分割を行った。上記のようにニューラルネットワークに学習を行った。予測モデルの評価方法としては、販売数量の平均絶対誤差 (MAE) と売上金額の平均絶対誤差 (MAE) と欠品率を評価関数とした。また、訓練データに計画数を含めて学習したモデルと含まずに学習を行ったモデルの予測性能の評価を行った。

5.2 欠品率を考慮した販売数量予測問題における実装

欠品率を考慮した販売数量予測問題における実装として、2 点の評価関数を用いて予測性能の評価を行った。1 点目が欠品率、2 点目が売上金額の平均絶対誤差 (MAE) とした。1 点目を評価する為に損失関数を設定する場合、損失関数に重みを持たせて、予測が実販売数を下回った場合に損失が大きくなるようにする。実際には、モデルの予測 $y(p_i)$ と実販売数 $y(t_i)$ の差を E とした場合、 E が 0 未満のときに E に重み w を掛けて損失が大きくなるように損失関数 (CustomLoss) を設定した。

$$E = y(p_i) - y(t_i)$$

$$CustomLoss = \frac{1}{n} \sum_{i=1}^n \begin{cases} w \cdot |E| & (E < 0) \\ E & (E \geq 0) \end{cases}$$

この損失関数は評価関数の 2 点目の売上金額の平均絶対誤差 (MAE) を評価する場合でも E が負となった際に $|E|$ に w を掛けることで、MAE と同じような損失を返すものと考え、 E が負の場合に損失が大きくなるような MAE に工夫をした損失関数として用いた。

6 実験とその評価

本章では前章で述べた実装により行った実験内容とその評価について述べる。

6.1 販売数量予測問題における実験

まず、問題の 1 つ目である販売数量予測問題において、販売数量の平均絶対誤差を損失関数として予測モデルの構築を行い、評価を行った。ニューラルネットワークの学習の経過は図 5 のようになり、100epoch で学習が終了した。結果は販売数量の平均絶対誤差が 234.3、売上金額の平均絶対誤差が 181,211、欠品率が 0.468 となった。また評価データの計画数の販売数量の平均絶対誤差については、246.3 であり、売上金額の平均絶対誤差が 196,334、欠品率が 0.423 であった。

次に、販売数量の平均絶対誤差を損失関数として訓練データに計画数を含めてニューラルネットワークを学習を行った。学習経過は図 6 のようになり、53epoch で学習が終了した。結果は販売数量の平均絶対誤差が 213.6、売上金額の平均絶対誤差が 170,408、欠品率が 0.555 となった。

次に損失関数を売上金額の平均絶対誤差としてニューラルネットワークの学習を行い、予測モデルの構築を行った。まず、計画数を含めない訓練データでニューラルネットワークの学習を行った。




図 5 学習経過，損失関数が販売数量 MAE，計画数を除いた訓練データ




図 8 学習経過，損失関数が売上金額 MAE，計画数を含む訓練データ




図 6 学習経過，損失関数が販売数量 MAE，計画数を含む訓練データ




図 7 学習経過，損失関数が売上金額 MAE，計画数を除いた訓練データ

計画数を含まないデータセットでの学習の経過は，図 7 のように，69epoch で学習が終了した。結果は販売数量の平均絶対誤差が 209.4，売上金額の平均絶対誤差が 162,796，欠品率が 0.474 となった。

次に損失関数を売上金額の平均絶対誤差として計画数を含む訓練データでニューラルネットワークの学習を行った。学習の経過は図 8 のようになり，65epoch で学習が終了した。結果は販売数量の平均絶対誤差が 213.9，売上金額の平均絶対誤差が 165,250，欠品率が 0.585 となった。

ここまでの販売数量予測問題において構築したモデルの結果を比較すると，表 7 にあるように，販売数量の平均絶対誤差と売上金額の平均絶対誤差では，損失関数を売上金額 MAE として計画数を除いた訓練データを用いて構築した予測モデルが，計画数の性能を上回ったが，欠品率においては，構築した予測モデルは計画数の性能を上回っていない結果となった。

表 7 販売数量予測問題における予測結果の比較

訓練データ	損失関数	販売数量	売上金額	欠品率
		平均絶対誤差	平均絶対誤差	
	「計画数」	246.3	196,334	0.423
計画数除く	販売数量 MAE	234.3	181,211	0.468
計画数除く	売上金額 MAE	209.4	162,796	0.474
計画数含む	販売数量 MAE	213.6	170,408	0.555
計画数含む	売上金額 MAE	213.9	165,250	0.585

6.2 欠品率を考慮した販売数量予測問題における実験

問題の 2 つ目として，欠品率を考慮した販売数量予測の実験を行った。ここでは，ニューラルネットワークの学習時に損失関数を CustomLoss として予測モデルの構築を行った。訓練データは計画数を含んだものとし，ニューラルネットワークの出力が売上金額となるようにした。また，評価関数は，欠品率と売上金額 MAE の 2 つとした。CustomLoss の重み w を 1.5 から 6.0 まで変動させて，予測モデルを構築し，欠品率と売上金額 MAE の 2 つの評価関数の出力値をグラフに示した。

表 8 にあるように，前節で構築した損失関数を売上金額 MAE として計画数を含んだデータで学習を行ったモデルは，損失関数に重みを持たせること無く，学習を行ったと考えることができ，欠品率が 0.585，売上金額 MAE が 165,250 であった。計画数の欠品率は 0.423，売上金額 MAE が 196,334 である。このことから，損失関数を売上金額 MAE とした場合，ニューラルネットワークの学習時に，モデルの予測が正解よりプラスに予測されてもマイナスに予測されても損失の大きさとしては同じとして学習し予測を行うが，計画数は，ある程度予測が正解を上回るように予測をしていると考えられる。その結果，売上金額 MAE を損失関数として学習したモデルは，単純に正解と予測の差を小さくするモデルとなっており，計画数よりも売上金額 MAE が小さく，しかし，欠品率が高く予測される状態となっていると考えられる。

そして，損失関数を CustomLoss として欠品時に，損失を大きくする重み w を 2.5 として，ニューラルネットワークの学習を行った結果は，欠品率が 0.385 で，売上金額 MAE が 172,621 となった。これは，損失関数を CustomLoss として学習したモデルが計画数の欠品率と売上金額 MAE 両方の評価関数で性能が上回っていると評価できる。

表 8 CustomLoss の重みと予測結果の欠品率, 売上金額 MAE

重み	欠品率	売上金額 MAE
計画数	0.423	196,334
1	0.585	165,250
1.5	0.509	163,685
2	0.455	166,162
2.5	0.385	172,621
3	0.349	180,341
4	0.300	194,336
5	0.260	205,691
6	0.226	218,322




図 9 CustomLoss の重みと予測結果の欠品率, 売上金額 MAE グラフ

表 9 販売数量予測と欠品率を考慮した販売数量予測結果の比較

訓練データ	損失関数	販売数量 平均絶対誤差	売上金額 平均絶対誤差	欠品率
「計画数」		246.3	196,334	0.423
計画数除く	販売数量 MAE	234.3	181,211	0.468
計画数除く	売上金額 MAE	209.4	162,796	0.474
計画数含む	販売数量 MAE	213.6	170,408	0.555
計画数含む	売上金額 MAE	213.9	165,250	0.585
計画数含む	CustomLoss, $w = 2.5$	227.7	180,415	0.323
計画数含む	CustomLoss, $w = 3.0$	229.7	180,341	0.349
計画数含む	CustomLoss, $w = 4.0$	228.2	194,336	0.300

さらに, 図 9 にあるように損失関数の重みを 1.5 から 6.0 までの範囲で変動させた結果は, 欠品率が下がると売上金額 MAE が上がるというトレードオフの関係となった。

この場合, 経済的損失を考慮すると, 重み w が 2.5 から 4 の間の, 欠品率及び売上金額 MAE が計画数の欠品率及び売上金額 MAE を下回る範囲で重みを選択するのが妥当だと考えられるが, サプライヤがどの程度リスクを許容できるかによって, 適切な重みを選択することが望ましい。

また, 販売数量予測問題で構築したそれぞれのモデルの予測結果と比較すると表 9 のようになり, 損失関数を販売数量 MAE や売上金額 MAE とした場合と比較して, CustomLoss とした場合は欠品率がより小さく予測される結果となった。

7 ま と め

本研究では, 生協におけるチラシ媒体通販の過去の販売データを用いて, 将来の販売予定データにおける販売数予測を行うモデルをニューラルネットワークを用いて構築した。生協がサプライヤに提供する販売予測数量である計画数を, 販売データ

と共に予測モデルに入力し, 欠品率と売上金額の平均絶対誤差が計画数の欠品率と売上金額の平均絶対誤差よりも小さくなるような, 欠品率を考慮した実務的な予測モデルの構築を行い, サプライヤが商品調達を行う際の経済的損失を小さくできる可能性が示唆された。

謝 辞

本研究は JSPS 科研費 JP21H03775, JP18H03244 の助成を受けたものです。ここに記して謝意を表します。

文 献

- [1] Doudou Dong, Rui He, and Guixi Xiong. Foreign commodity sales forecast based on model fusion. In *Proceedings of the 2019 4th International Conference on Big Data and Computing (ICBDC)*, pp. 185–188, 2019.
- [2] Rita Gevorgyan. Development and implementation of the model for sales volume forecasting for the brewing company. In *Proceedings of the 2nd International Conference on Business and Information Management (ICBIM)*, pp. 149–153, 2018.
- [3] Shinji Ito and Ryohei Fujimaki. Optimization beyond prediction: Prescriptive price optimization. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 1833–1841, 2017.
- [4] Shenjia Ji, Hongyan Yu, Yinan Guo, and Zongrun Zhang. Research on sales forecasting based on arima and bp neural network combined model. In *Proceedings of the 2016 International Conference on Intelligent Information Processing (ICIIP)*, pp. 1–6, 2016.
- [5] Yunxin Liang, Jiyu Wu, Wei Wang, Yujun Cao, Biliang Zhong, Zhenkun Chen, and Zhenzhang Li. Product marketing prediction based on xgboost and lightgbm algorithm. In *Proceedings of the 2nd International Conference on Artificial Intelligence and Pattern Recognition (AIPR)*, pp. 150–153, 2019.
- [6] Yan Qi, Chenliang Li, Han Deng, Min Cai, Yunwei Qi, and Yuming Deng. A deep neural framework for sales forecasting in e-commerce. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*, pp. 299–308, 2019.
- [7] 谷本啓, 本橋洋介. モデルのライフサイクルを考慮した大量予測モデル管理手法の検討. 人工知能学会全国大会, pp. 1–4, 2015.
- [8] 今井秀之, 山岡俊樹. 日用品市場における新製品売上予測モデルの構築. 日本感性工学会論文誌, Vol. 10, No. 2, pp. 63–71, 2011.
- [9] 張瀚天, 村井諒, 佐々木健佑, 片山茜, 善甫啓一, 中林紀彦. アパレル業の売上予測における時系列モデルの適応条件の検討. 人工知能学会全国大会, pp. 1–4, 2016.