

深層畳み込みニューラルネットワークを用いたレーザ超音波可視化試験における欠陥検出と位置推定

小西 裕貴[†] 田島 賢哉[†] 加藤 毅[†] 斎藤 隆泰[†]

[†] 群馬大学大学院理工学府 〒 376-8515 群馬県桐生市天神町 1-5-1

あらまし 機械材料や土木構造物などの健全性を評価する方法として、非接触で検査を行うレーザ超音波可視化試験 (LUVT) が注目されている。LUVT により、超音波を可視化した画像を検査することで欠陥を検出することができる。本研究では、深層学習を利用した LUVT 画像の自動検査を試みた。提案法は、欠陥の有無のみならず、位置まで特定することができる。本稿では、実データを使って実施した性能評価の結果を報告する。

キーワード LUVT, Deep learning, Convolutional neural network, Defect detection

1 緒 言

近年、構造物の老朽化などが社会問題になっている。構造物の健全性を評価する方法の一つに超音波を用いた非破壊検査法がある。本研究では、非接触で検査を行うレーザ超音波可視化試験 (LUVT) に注目した。LUVT では、超音波を可視化した画像から欠陥を検出することができる。しかし、一つ一つ検査員が確認するには時間と労力がかかり、見落としのリスクも伴う。

一方、近年の深層学習における画像認識の性能は飛躍的に向上しており、様々な分野での適用可能性が見出されてきた [4]。画像の分類問題などに対しては、畳み込みニューラルネットワーク (CNN) がよく用いられる。CNN は、畳み込み層、プーリング層、全結合層から構成されており、画像解析において最も成功した方法である。また、分類のみならず、物体の位置を推定したり、画像の領域を切り出したりするモデルなど多くの拡張と発展を遂げており、急速な進化を続けている。

本研究では、CNN を使って、計算機に LUVT 画像における欠陥からの散乱波形を自動的に学習させることで、LUVT 検査を自動化することを試みた。開発したアルゴリズムは、欠陥の有無のみならず、位置まで特定することができる。筆者らは、そのアルゴリズムがどれほどの検出性能を所持しているか調査するため、実データを使った計算機実験を実施した。本稿では、アルゴリズムの詳細に加えて、評価実験の結果も報告する。

2 関連する研究

CNN は画像解析において最も成功した枠組みであり [4], [5], LUVT 画像の解析にも有用であると期待できる。典型的には、CNN は、複数の層を積み上げて構成する。それらの層は複数のブロックにまとめることができ、CNN はブロックの連鎖となっている。最後のブロックは 1 個もしくは複数の全結合層からなる。それ以外のブロックは、複数の畳み込み層およびプーリング層からなる。CNN において、RGB 画像はサイズ (画像の幅 × 画像の高さ × 3) からなる階数 3 のテンソルで表現され

る。畳み込み層は畳み込みフィルターを使って、入力テンソルの局所領域の特徴を表現した同じ画像サイズのテンソルに変換する。入力層以外のテンソルは特徴マップと呼ばれる。プーリング層は特徴マップの画像サイズを小さくし、画像の位置ずれへの頑健性を高める。最後のブロックの全結合層は抽出した特徴マップから予測を行う。

LUVT 画像に含まれる欠陥を検出する問題は、一般画像解析における物体検出タスクと類似性があり、物体検出タスクのために開発されたアプローチを LUVT 画像の解析に流用することが可能である。既存の物体検出のアルゴリズムは 2 段階アプローチ [1], [2] と 1 段階アプローチ [6], [7] に分類できる。2 段階アプローチでは、第 1 段階で多くの領域候補を推定する。第 2 段階で候補それぞれをスクリーニングして、対象の物体の検出結果とする。2 段階アプローチの物体検出の精度は高いものの、計算量が重いという短所を抱えている。1 段階アプローチは、パイプラインを単一のニューラルネットワーク (NN) にまとめることで、計算量の問題は解決した。本研究でも、単一の NN だけで欠陥の有無の予測から欠陥に位置の推定まで行えるようにアルゴリズムを設計した。

3 データセット

NN の訓練と性能評価に必要な LUVT 画像セットは次のようにして獲得した。欠陥のある SUS 平板にレーザを照射し、各時刻の超音波伝搬の様子を画像に変換することで LUVT 画像を得た。図 1 に欠陥あり・なし画像を示す。図 1(a) は欠陥無しの画像であり、超音波は時間を追うごとに等方性に広がっている。図 1(b) は欠陥ありの画像であり、欠陥からの散乱超音波が欠陥に当たって周辺で反射した波が発生している。欠陥あり画像に関しては、欠陥位置を上下左右に移動させた試験も行っている。これらの画像は超音波を欠陥の真上から照射した場合である。図 1(c), (d) は、欠陥の角度を超音波に対して 45 度回転させたときの画像と探触子を欠陥の中心から少しずらした場合の画像である。図 1(a), (b) とは違い、明確に反射が起こらず、欠陥の有無を視認しにくくなっている。これらの画像は

画像上部から超音波を発生して一番下まで到達する間の画像になっており、およそ 520 ステップからなる。LUVT 画像は 14 種類の条件で表 1 のように収集した。

欠陥の有無を学習したり、予測性能を評価したりするためには、訓練および性能評価に用いる画像 1 枚 1 枚に欠陥の有無に関する正解ラベルを付与する。超音波が欠陥に当たってから欠陥によって発生した散乱波の波面が消えるまでの間を欠陥ありの正解ラベルを付与し、それ以外の画像には欠陥無しの正解ラベルを付与した。欠陥の有無に加えて、位置の推定のための学習を行ったり、推定精度を評価したりするために、欠陥の位置情報に関しても、それぞれの欠陥あり画像に正解データとして与えた。提案する方法の性能を評価するために 2 種類のデータセットを表 1 のように構成した。それぞれデータセット 1、およびデータセット 2 と呼ぶ。データセット 1 に含まれる欠陥ありの画像は図 1(b) のような超音波の波形が欠陥に対して垂直に当たっている 10 種類の条件に限定した。データセット 1 に含まれる画像の枚数は 5,214 枚である。そのうち欠陥あり画像は 1,775 枚、欠陥なし画像は 3,439 枚含まれている。データセット 2 は、データセット 1 に、欠陥の角度を超音波に対して 45 度回転させたときの 2 系列と接触子を欠陥の中心から少しずらした 2 種類の条件の追加した 14 種類になっている。データセット 2 に含まれる画像の枚数は 7,257 枚、そのうち欠陥あり画像は 2,413 枚、欠陥なし画像は 4,844 枚である。

NN の性能評価では、データセットを、訓練データ、検証データ、テストデータと呼ばれる 3 個の排他的な部分集合に分割する必要がある。訓練データは、NN の学習に用いられる。NN の学習には、利用者が調整しなくてはならないハイパーパラメータがいくつかある。ハイパーパラメータの値のいくつかの候補を使って NN を訓練データで学習し、検証データを使って、どのハイパーパラメータの値が最も高性能となるか検証する。検証データにおいて良好であったハイパーパラメータの値を学習結果として、テストデータの性能評価に用いる。データセット 1 では、訓練データ 6 種類、検証データ 2 種類、テストデータ 2 種類とし、データセット 2 では、訓練データ 8 種類、検証データ 3 種類、テストデータ 3 種類とした。

4 予測モデル

まず、開発した NN の概略を述べる。開発した NN は、汎用の物体検出モデルを簡素化したモデルとなっている。CNN を使った典型的な識別器のバックボーンは、畳み込み層とプーリング層からなる多数のブロックの連鎖からなっており、入力画像をこのバックボーンに通すことで、画像の特徴マップを計算する。開発したモデルでも、同様なバックボーンを使って特徴マップを計算する。カテゴリ分類を行う CNN は、そのようなバックボーンに識別ヘッドと呼ばれる層を付加することで、分類タスクを行えるようにしている。本研究の目標は、欠陥の有無の予測のみならず、欠陥の位置を推定することも含まれている。この 2 つの目標を同時に実現するために、本研究では、図 2 のように、識別ヘッドに加えて回帰ヘッドと呼ばれる層を装

着した。また、バックボーンには ResNet34 [3] を用いた。

本研究の場合、欠陥の有無を予測させると同時に、欠陥の位置も推定させたい。この目標を達成するために、次に述べる、分類タスクのための誤差項と回帰タスクのための誤差項の和で目的関数を構成した。すべての訓練データに対して、識別ヘッドの出力と欠陥の有無との矛盾をクロスエントロピー損失関数で評価する。分類タスクのための誤差項は、それらのクロスエントロピー損失の平均とした。欠陥のある画像に対して、回帰ヘッドの出力と欠陥の位置との誤差を二乗誤差損失関数で評価する。回帰タスクのための誤差項は、二乗誤差損失の平均とした。

次に、モデルの詳細を述べる。入力画像 I をバックボーンに通すことで得られる特徴を $\Psi(I; \theta) := [\Psi_1(I; \theta), \dots, \Psi_{d-1}(I; \theta), 1]^T \in \mathbb{R}^d$ とおく。ただし、 θ はバックボーンに含まれている重みパラメータである。識別ヘッドと回帰ヘッドは、それぞれ、重みパラメータ $\mathbf{W}^c := [\mathbf{w}_{1,c}, \mathbf{w}_{2,c}]$ および $\mathbf{W}^r := [\mathbf{w}_{x,r}, \mathbf{w}_{y,r}]$ を使って、2 種類の 2 次元の出力信号 $(\mathbf{W}^c)^T \Psi(I; \theta)$ および $(\mathbf{W}^r)^T \Psi(I; \theta)$ に変換する。

訓練用画像数を N とし、 $I^{(1)}, \dots, I^{(N)}$ を訓練用画像とする。各画像 $I^{(n)}$ には、クラスラベル $c^{(n)} \in \{1, 2\}$ を与える。 N_+ を欠陥のある訓練用画像の数、 $N_- := N - N_+$ を欠陥のない訓練用画像の数とする。一般性を失わずに、訓練用画像順番を $c^{(1)} = \dots = c^{(N_+)} = 1$, $c^{(N_++1)} = \dots = c^{(N)} = 2$ と並び替える。開発した深層 NN の重みパラメータは $(\theta, \mathbf{W}^c, \mathbf{W}^r)$ となり、これらの値を目的関数が最小化されるように調整する。

前述の目的関数 $R(\theta, \mathbf{W}^c, \mathbf{W}^r)$ は識別に関する誤差項と回帰に関する誤差項の線形結合で構成した：

$$R(\theta, \mathbf{W}^c, \mathbf{W}^r) = \frac{1}{N} \sum_{n=1}^N \text{CE}((\mathbf{W}^c)^T \Psi(I^{(n)}; \theta); c^{(n)}) + \frac{1}{N_+} \sum_{n=1}^{N_+} \|(\mathbf{W}^r)^T \Psi(I^{(n)}; \theta) - \ell^{(n)}\|^2. \quad (1)$$

ただし、 $\ell^{(n)} := [x^{(n)}, y^{(n)}]^T$ はアノテーションによって与えた欠陥位置の (x, y) 座標である。 $\text{CE}(\cdot; c) : \mathbb{R}^2 \rightarrow \mathbb{R}$ はクロスエントロピー損失関数を表す：

$$\text{CE}(\mathbf{s}; c) := \log \left(\sum_{j=1}^2 \exp(s_j - s_c) \right). \quad (2)$$

この目的関数 R の最小化によって、識別ヘッドと回帰ヘッドのパラメータを最適化し、同時に特徴抽出を行うバックボーンも欠陥検出と位置特定に適合するようにチューニングできる。

入力画像のサイズは 224×224 とした。データ拡張には、Resize, Crop, Shift, Scale, Rotate を行い、色や輝度に関する拡張としては、Brightness, Contrast, Hue-Saturation-Value を変化させた。さらに、ノイズへの対策として正規雑音を加えた。また、波形の形に注目させる目的で彩度変換も追加した。最適化手法には Adam を用いた。バッチサイズは 256 とした。初期の学習率は 10^{-3} に設定し、30 エポック学習させた。10 エポックまでは識別ヘッドと回帰ヘッドのみ学習させた。11 エ




図 1 Examples of LUVT images

表 1 Dataset 1 and dataset 2

画像系列	角度	欠陥位置	欠陥有り画像数	欠陥無し画像数	データセット 1	データセット 2
1	0°	欠陥無し	0	582	✓	✓
2	0°	中央	219	281	✓	✓
3	0°	右	272	228	✓	✓
4	0°	左	271	229	✓	✓
5	0°	上	179	343	✓	✓
6	0°	右上	180	342	✓	✓
7	0°	右左	180	343	✓	✓
8	0°	下	157	364	✓	✓
9	0°	右下	158	364	✓	✓
10	0°	左下	159	363	✓	✓
11	-45°	中央	221	302		✓
12	+45°	中央	220	300		✓
13	0°	探触子が右	87	413		✓
14	0°	探触子が左	390	390		✓




図 2 Proposed model

ポックからは学習率を 10^{-4} に変更した。バックボーンに用いた ResNet34 の最後尾のブロックも学習させた。21 エポックからはモデル全体を学習させた。




図 3 Learning curves

5 実験結果

本研究で開発した自動検査アルゴリズムがどれほど欠陥の有無を予測できるか、また、どれほど正確に欠陥の位置を予測できるか、調査するために、3 節で述べた実データを用いた評価実験を行った。訓練データを使って開発した CNN モデルを訓練し、検証データにおけるクロスエントロピー損失の平均も二乗誤差損失の平均も十分に小さくなっていることを確認した。

このようにして得られた CNN モデルをテストデータに適用して、性能評価を行った。5.1 節にて、前節の方法で実際に最適化が問題なく動作したことを示す。5.2 節にて、欠陥の有無の予測性能を報告し、5.3 節にて、欠陥の位置の推定精度を報告する。

表 2 Confusion matrices

(a) Dataset 1				(b) Dataset 2			
		Annotation				Annotation	
		P	N			P	N
Prediction	P	374	52	Prediction	P	515	53
	N	2	593		N	63	869

5.1 学習過程

交差エントロピー損失値と二乗誤差損失値を各反復でモニターした。それらの損失値は、それぞれ、式 (1) の第 1 項と第 2 項で与えられる。データセット 1 に適用したときの値を図 3(a),(b) にプロットした。両方の損失項は十分減少しているため、学習はおおむね成功しているといえる。図 3(c),(d) は検証セットにおける目的関数値と、検出の有無の正解率を示す。それぞれ 0 と 1 に近づいているので、過整合もしていないことが確認できた。

5.2 分類性能

ここでは、本研究で開発した自動検査アルゴリズムがどれほど欠陥の有無を予測できるか調査した結果を報告する。テストデータの真陽性数 (TP)、偽陽性数 (FP)、偽陰性数 (FN)、真陰性数 (TN) を計数した。データセット 1 およびデータセット 2 における混同行列を表 2 に示す。データセット 1 では偽陰性数は 2 個しかなく非常に少なかった。このことから、超音波が傷に垂直に照査されたときは、検出漏れの危険は十分小さいといえる。偽陽性数に関しては、データセット 1 でもデータセット 2 でも大きな違いはなかった。正解率 $(TP + TN) / (TP + FP + FN + TN)$ で比較すると、データセット 1 では 94.7 %、データセット 2 では 92.3 % となった。データセット 2 のほうが難しい問題にもかかわらず正解率に大きな差異がなかった理由は、より多くの訓練データを利用することができたからと推察できる。

5.3 位置予測性能


ここでは、欠陥の位置の推定精度を報告する。位置予測誤差は、アノテーションした欠陥位置と予測位置との画像上のユークリッド距離で評価した。データセット 1 およびデータセット 2 における予測誤差を、それぞれ図 4 にプロットした。特に欠陥有無の予測に関して偽陰性であった画像データにおいて、欠陥位置の推定誤差は大きくなった。

6 結 論

本研究では、非破壊検査のために LUVT 画像から自動的に欠陥を検出し、位置同定をできる計算論的な方法論を開発した。その方法は、深層 NN をもとにしており、効果的な特徴を抽出できる CNN の能力を利用している。識別ヘッドと回帰ヘッドを CNN に装備させることで、欠陥検出器と位置推定器を統合して同時に学習するための方法を確立した。実データで評価実験を実施し、開発したアルゴリズムの有効性を確認した。

謝辞：本研究の一部は、公益財団法人セコム科学技術振興

(a) Dataset 1



(b) Dataset 2




図 4 Histograms of position estimation errors

財団一般研究助成により実施された。また、JSPS 科研費 19K04661 の助成を受けた。

文 献

- [1] Ross Girshick. Fast r-CNN. In *2015 IEEE International Conference on Computer Vision (ICCV)*. IEEE, December 2015.
- [2] Kaiming He, Georgia Gkioxari, Piotr Dollar, and Ross Girshick. Mask r-CNN. In *2017 IEEE International Conference on Computer Vision (ICCV)*. IEEE, October 2017.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, June 2016.
- [4] Eisuke Ito, Takaaki Sato, Daisuke Sano, Etsuko Utagawa, and Tsuyoshi Kato. Virus particle detection by convolutional neural network in transmission electron microscopy images. *Food and Environmental Virology*, 10(2):201–208, January 2018.
- [5] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1(4):541–551, December 1989.
- [6] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C. Berg. SSD: Single shot multibox detector. In *ECCV*, 2016.
- [7] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, June 2016.